ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN & TRUYỀN THÔNG

LUẬN VĂN TỐT NGHIỆP ĐẠI HỌC
NGÀNH KHOA HỌC MÁY TÍNH

Đề tài

KAGI: CẢI TIẾN PHÂN LỚP ẢNH VĂN HOÁ PHI VẬT THỂ VỚI MẠNG HỌC SÂU ĐỒ THỊ VÀ MÔ HÌNH KAN

(KAGI: IMPROVING INTANGIBLE CULTURAL HERITAGE IMAGE CLASSIFICATION THROUGH KAN-ENHANCED GRAPH DEEP LEARNING)

Sinh viên: Trần Minh Hiểu
Mã số: B2207521
Khóa: 48
Giảng viên hướng dẫn: TS. Mã Trường Thành

Cần Thơ, 12/2025

ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN & TRUYỀN THÔNG

LUẬN VĂN TỐT NGHIỆP ĐẠI HỌC
NGÀNH KHOA HỌC MÁY TÍNH

Đề tài

KAGI: CẢI TIẾN PHÂN LỚP ẢNH VĂN HOÁ PHI VẬT THỂ VỚI MẠNG HỌC SÂU ĐỒ THỊ VÀ MÔ HÌNH KAN

(KAGI: IMPROVING INTANGIBLE CULTURAL HERITAGE IMAGE CLASSIFICATION THROUGH KAN-ENHANCED GRAPH DEEP LEARNING)

Giảng viên hướng dẫn
TS. Mã Trường Thành

Sinh viên thực hiện
Trần Minh Hiểu
Mã số: B2207521
Khóa: 48

Cần Thơ, 04/2026

ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM
Độc lập – Tự do – Hạnh phúc

XÁC NHẬN CHỈNH SỬA LUẬN VĂN THEO YÊU CẦU CỦA HỘI ĐỒNG

Tên luận văn (tiếng Việt và tiếng Anh): KAGI: Cải tiến phân lớp ảnh văn hóa phi vật thể với mạng học sâu đồ thị và mô hình KAN (KAGI: Improving Intangible Cultural Heritage image classification through KAN-enhanced graph deep learning).

Họ tên sinh viên: Trần Minh Hiểu Mã SV: B2207521

Mã lớp: DI22Z6A1

Đã báo cáo tại hội đồng ngành: Khoa học máy tính

Ngày báo cáo: 16/12/2025

Hội đồng báo cáo gồm:

1. PGS. TS. Phạm Nguyên Khang	Chủ tịch hội đồng
2. TS. Nguyễn Tí Hon	Uỷ viên
3. TS. Mã Trường Thành	Thư ký

Luận văn đã được chỉnh sửa theo góp ý của Hội đồng.

Cần Thơ, ngày 31 tháng 12 năm 2025
Giảng viên hướng dẫn
(Ký và ghi rõ họ tên)

Mã Trường Thành

NHẬN XÉT CỦA GIẢNG VIÊN

Cần Thơ, ngày ..... tháng ..... năm 2026
(Ký và ghi rõ họ tên)

LỜI CẢM ƠN

Trước hết, tôi xin bày tỏ lòng biết ơn sâu sắc đến Trường Công nghệ thông tin và Truyền thông, Đại học Cần Thơ, nơi đã tạo điều kiện thuận lợi và môi trường học tập năng động để tôi được tiếp cận, nghiên cứu và phát triển kiến thức trong lĩnh vực công nghệ thông tin. Các học phần đại cương, cơ sở ngành và chuyên ngành bổ ích đã giúp tôi tích lũy đượcnền tảng kiến thức vững chắc, cũng như rèn luyện được khả năng tư duy logic, sáng tạo và kỹ năng làm việc chuyên nghiệp.

Đặc biệt, tôi xin gửi lời cảm ơn chân thành và sâu sắc nhất đến TS. Mã Trường Thành, người đã luôn tận tình hướng dẫn, đồng hành và định hướng cho tôi trong suốt quá trình thực hiện đề tài. Thầy không chỉ giúp tôi củng cố kiến thức chuyên môn mà còn truyền cho tôi tinh thần nghiên cứu nghiêm túc, kiên nhẫn và cầu tiến trong học thuật. Những góp ý quý báu cùng sự chỉ bảo tận tâm của thầy là nguồn động lực to lớn giúp tôi vượt qua những khó khăn để hoàn thiện đề tài luận văn tốt nghiệp một cách tốt nhất.

Tôi cũng xin gửi lời tri ân đến toàn thể quý thầy cô trong Trường Công nghệ Thông tin và Truyền thông, những người đã tận tâm giảng dạy, truyền đạt kiến thức quý báu cho tôi trong suốt những năm học vừa qua. Sự cống hiến, tâm huyết và tinh thần trách nhiệm của quý thầy cô đã giúp tôi không ngừng trưởng thành trong cả kiến thức chuyên môn lẫn tư duy nghiên cứu.

Cuối cùng, tôi xin gửi lời cảm ơn sâu sắc đến gia đình và bạn bè, những người luôn ở bên cạnh, chia sẻ, động viên và khích lệ tinh thần trong suốt quá trình học tập và hoàn thiện luận văn. Sự yêu thương và ủng hộ của mọi người là điểm tựa vững chắc giúp tôi có thêm nghị lực để hoàn thành tốt chặng đường học tập này.

Tôi xin chân thành cảm ơn!

Cần Thơ, ngày 10 tháng 04 năm 2026

Người viết

Trần Minh Hiểu

MỤC LỤC

DANH MỤC HÌNH ẢNH iii

DANH MỤC BẢNG BIỂU v

DANH MỤC TỪ VIẾT TẮT vii

ABSTRACT viii

TÓM LƯỢC ix

I. PHẦN GIỚI THIỆU 1

1. Đặt vấn đề 1
2. Những nghiên cứu liên quan 1
3. Mục tiêu đề tài 3
4. Đối tượng và phạm vi nghiên cứu 3
5. Phương pháp nghiên cứu 4
6. Bố cục quyển báo cáo 4

II. PHẦN NỘI DUNG 6

CHƯƠNG 1. MÔ TẢ BÀI TOÁN 6

1. Mô tả chi tiết bài toán 6
   1.1. Bài toán phân lớp dữ liệu ICH 6
   1.2. Ứng dụng Web 6
2. Vấn đề giải pháp liên quan đến bài toán 7
   2.1. Mạng noron tích chập (CNN) 7
   2.2. Mô hình embedding câu (Sentence Transformer) 8
   2.3. Đặc trưng MFCC của âm thanh 10
   2.4. Đồ thị đa phương thức (MG) 11
   2.5. Mạng noron đồ thị (GNN) 12
   2.6. Mạng Kolgomorov-Arnold (KAN) 14
   2.7. Thang đo độ chính xác 15
   2.8. Framework web 16

CHƯƠNG 2. THIẾT KẾ VÀ CÀI ĐẶT GIẢI PHÁP 18

1. Thiết kế hệ thống 18

1.1. Mô hình CNN baseline 20
1.2. Mô hình MGAT + FastKAN/MLP 21
2. Cài đặt giải pháp 29
2.1. Thu thập dữ liệu 29
2.2. Tiền xử lý dữ liệu 30
CHƯƠNG 3. KIỂM THỬ VÀ ĐÁNH GIÁ 34
1. Giao diện sản phẩm 34
2. Kết quả thực nghiệm 39
2.1. Các thông số cho huấn luyện và kiểm thử 39
2.2. Kết quả kiểm thử trên các mô hình CNN baseline 42
2.3. Kết quả kiểm thử trên mô hình CNN + MGAT + FastKAN/MLP với toàn bộ phương thức 46
2.4. Kết quả kiểm thử trên mô hình CNN + MGAT + FastKAN/MLP với hai phương thức (hình ảnh và văn bản) 50
2.5. Kết quả kiểm thử trên mô hình CNN + MGAT + mô hình phân lớp truyền thống với toàn bộ phương thức 54
3. Thảo luận chung về các kết quả thực nghiệm 56
III. PHẦN KẾT LUẬN 58
1. Kết quả đạt được 58
2. Hướng phát triển 58
TÀI LIỆU THAM KHẢO 59

DANH MỤC HÌNH ẢNH

Hình 1. Minh hoạ kiến trúc cơ bản của CNN 7
Hình 2. Minh hoạ kiến trúc cơ bản của SBERT 9
Hình 3. Các kiến trúc đồ thị đa phương thức phổ biến 11
Hình 4. Minh hoạ kiến trúc cơ bản của GNN 12
Hình 5. Minh hoạ kiến trúc cơ bản của GAT 13
Hình 6. Minh hoạ kiến trúc cơ bản của KAN 14
Hình 7. Luồng xử lý tổng quát của hệ thống khi triển khai thành ứng dụng . 18
Hình 8. Kiến trúc của mô hình CNN baseline 20
Hình 9. Kiến trúc tổng quát của mô hình CNN backbone + MGAT + FastKAN/MLP 21
Hình 10. Ví dụ về cách xây dựng đồ thị và dự đoán nhãn khi dùng mô hình CNN backbone + MGAT + FastKAN/MLP 22
Hình 11. Kiến trúc chi tiết của Extract Features Layers 23
Hình 12. Kiến trúc của Share Projection Layer 24
Hình 13. Kiến trúc của Edge Weights Layer sử dụng cơ chế Attention 25
Hình 14. Kiến trúc của GAT Layers với cơ chế Weighted Message Passing . . 26
Hình 15. Kiến trúc bộ phân lớp bằng FastKAN và MLP 27
Hình 16. Số lượng video theo từng lớp 29
Hình 17. Biểu đồ thể hiện số lượng mẫu có ảnh, văn bản và âm thanh theo từng lớp trong tập Train 32
Hình 18. Biểu đồ thể hiện số lượng mẫu có ảnh, văn bản và âm thanh theo từng lớp trong tập Val 33
Hình 19. Biểu đồ thể hiện số lượng mẫu có ảnh, văn bản và âm thanh theo từng lớp trong tập Test 33
Hình 20. Giao diện trang chủ – Khu vực nhập liệu, thêm và hoàn tất tải tệp lên 34
Hình 21. Giao diện trang chủ – Khu vực hiển thị kết quả 34
Hình 22. Giao diện modal cho phép thêm tệp tin đa phương thức 35
Hình 23. Giao diện hiển thị trạng thái tải tệp và nội dung mô tả thành công . 35
Hình 24. Giao diện hiển thị kết quả dự đoán với mô hình backbone MobileNetV3 Small 36
Hình 25. Giao diện công cụ trực quan hóa đồ thị cho mô hình MGAT + FastKAN/MLP 36

Hình 26. Giao diện danh sách nút cho phương thức hình ảnh 37
Hình 27. Giao diện danh sách nút cho phương thức văn bản 37
Hình 28. Giao diện danh sách nút cho phương thức âm thanh 38
Hình 29. Giao diện hiển thị đồ thị tương tác 38
Hình 30. Biểu đồ thống kê tổng số từ vựng trên tập Train 41
Hình 31. Biểu đồ thống kê số lượng từ (Min, Avg, Max) trên tập Train 41
Hình 32. Biểu đồ thể hiện hiệu năng của 6 mô hình CNN baseline 45
Hình 33. Biểu đồ thể hiện kết quả kiểm thử trung bình của tất cả các mô hình CNN backbone + MGAT + FastKAN/MLP trên toàn bộ phương thức 49
Hình 34. Biểu đồ thể hiện kết quả kiểm thử trung bình của tất cả các mô hình CNN backbone + MGAT + FastKAN/MLP trên hai phương thức 53
Hình 35. Biểu đồ thể hiện kết quả kiểm thử trung bình của các mô hình truyền thống (sử dụng đặc trưng từ DenseNet121 + MGAT + FastKAN) 55

DANH MỤC BẢNG BIỂU

Bảng 1. Phân bố số lượng mẫu dữ liệu cho từng tập 32
Bảng 2. Thống kê số lượng tham số của các mô hình CNN Baseline 39
Bảng 3. Thống kê số lượng tham số của mô hình CNN backbone + MGAT + FastKAN/MLP 40
Bảng 4. Classification report của ResNet18 trên CNN baseline 42
Bảng 5. Classification report của RegNetX400MF trên CNN baseline 42
Bảng 6. Classification report của MobileNetV3 Large trên CNN baseline . . 43
Bảng 7. Classification report của MobileNetV3 Small trên CNN baseline . . 43
Bảng 8. Classification report khi kiểm thử DenseNet121 trên CNN baseline 43
Bảng 9. Classification report khi kiểm thử ShuffleNet V2 1.0x trên CNN baseline 44
Bảng 10. Kết quả kiểm thử trung bình của tất cả các mô hình CNN baseline . 45
Bảng 11. Classification report của FastKAN(1) và MLP(2) trên toàn bộ phương thức với backbone ResNet18 46
Bảng 12. Classification report của FastKAN(1) và MLP(2) trên toàn bộ phương thức với backbone RegNetX400MF 46
Bảng 13. Classification report của FastKAN(1) và MLP(2) trên toàn bộ phương thức với backbone MobileNetV3 Large 47
Bảng 14. Classification report của FastKAN(1) và MLP(2) trên toàn bộ phương thức với backbone MobileNetV3 Small 47
Bảng 15. Classification report của FastKAN(1) và MLP(2) trên toàn bộ phương thức với backbone DenseNet121 47
Bảng 16. Classification report của FastKAN(1) và MLP(2) trên toàn bộ phương thức với backbone ShuffleNetV2 1.0x 48
Bảng 17. Kết quả kiểm thử trung bình của tất cả các mô hình CNN backbone + MGAT + FastKAN/MLP trên toàn bộ phương thức 49
Bảng 18. Classification report của FastKAN(1) và MLP(2) trên hai phương thức với backbone ResNet18 50
Bảng 19. Classification report của FastKAN(1) và MLP(2) trên hai phương thức với backbone RegNetX400MF 51
Bảng 20. Classification report của FastKAN(1) và MLP(2) trên hai phương thức với backbone MobileNetV3 Large 51
Bảng 21. Classification report của FastKAN(1) và MLP(2) trên hai phương thức với backbone MobileNetV3 Small 51

Bảng 22. Classification report của FastKAN(1) và MLP(2) trên hai phương thức với backbone DenseNet121 52
Bảng 23. Classification report của FastKAN(1) và MLP(2) trên hai phương thức với backbone ShuffleNetV2 1.0x 52
Bảng 24. Kết quả kiểm thử trung bình của tất cả các mô hình CNN backbone + MGAT + FastKAN/MLP trên hai phương thức 53
Bảng 25. Kết quả kiểm thử trung bình của các mô hình truyền thống (sử dụng đặc trưng từ DenseNet121 + MGAT + FastKAN) 55

DANH MỤC TỪ VIẾT TẮT

STT	Từ viết tắt (Abbreviation)	Từ viết đầy đủ (Origin word)
1	ICH	Intangible Cultural Heritage (Di sản văn hóa phi vật thể)
2	MG	Multimodal Graph
3	GNN	Graph Neural Network
4	MGNN	Multimodal Graph Neural Network
5	GAT	Graph Attention Network
6	MGAT	Multimodal Graph Attention Network
7	KAN	Kolgomorov-Arnold Network
8	MFCC	Mel-Frequency Cepstral Coefficients
9	MLP	Multi-Layer Perceptron
10	SL	Số lượng

ABSTRACT

In the era of digital transformation, automatic classification of intangible cultural heritage (ICH) data plays an important role in cultural preservation and promotion. However, traditional CNN-based methods that rely only on image data still face many limitations, especially when dealing with multimodal data and high similarity in costumes, rituals, and festival contexts. To address these issues, I proposes a deep learning architecture that combines a Graph Attention Network on a multimodal graph (MGAT) with FastKAN (Kolmogorov–Arnold Network). The proposed architecture enables joint learning and integration of three data modals, including image, text, and audio, within a shared representation space. Experimental results on a collected ICH dataset show that the proposed method outperforms baseline models, with the DenseNet121 + MGAT + FastKAN configuration achieving an accuracy of 94.35%. In addition, lightweight models such as MobileNetV3 Small and ShuffleNetV2 1.0x also show improvements of more than 8%. The use of FastKAN allows the model to learn complex nonlinear relationships more effectively than traditional MLPs. Furthermore, this study develops and deploys a web-based system called ICH Predictor, which supports data lookup and visualization of the ICH classification process, enhancing the practical applicability of the proposed approach.

Keywords: Intangible Cultural Heritage, Multimodal Classification, Graph Neural Networks, MGAT, FastKAN, Deep Learning.

TÓM LƯỢC

Trong kỷ nguyên chuyển đổi số, việc tự động phân lớp dữ liệu di sản văn hóa phi vật thể (ICH) đóng vai trò quan trọng trong công tác bảo tồn và quảng bá giá trị văn hóa. Tuy nhiên, các phương pháp CNN truyền thống chỉ khai thác dữ liệu hình ảnh vẫn còn nhiều hạn chế, đặc biệt khi phải xử lý dữ liệu có tính đa phương thức và mức độ tương đồng cao về trang phục, nghi thức cũng như bối cảnh lễ hội. Nhằm khắc phục những hạn chế này, tôi đề xuất một kiến trúc học sâu kết hợp Graph Attention Network trên đồ thị đa phương thức (MGAT) với FastKAN (mạng Kolmogorov–Arnold). Kiến trúc này cho phép khai thác và tích hợp đồng thời ba nguồn dữ liệu gồm hình ảnh, văn bản và âm thanh trong một không gian biểu diễn chung. Kết quả thực nghiệm trên tập dữ liệu ICH thu thập được cho thấy phương pháp đề xuất đạt hiệu quả cao hơn so với các mô hình so sánh, trong đó cấu hình DenseNet121 + MGAT + FastKAN đạt độ chính xác 94.35%. Đồng thời, các mô hình gọn nhẹ như MobileNetV3 Small và ShuffleNetV2 1.0x cũng ghi nhận mức cải thiện trên 8%. Việc tích hợp FastKAN giúp mô hình học được các quan hệ phi tuyến phức tạp hiệu quả hơn so với MLP truyền thống. Bên cạnh đó, đề tài còn xây dựng và triển khai hệ thống web ICH Predictor, hỗ trợ tra cứu và trực quan hóa quy trình phân lớp dữ liệu ICH, góp phần nâng cao khả năng ứng dụng thực tế của mô hình đề xuất.

Từ khóa: Di sản văn hóa phi vật thể, Phân loại đa phương thức, Mạng noron đồ thị, MGAT, FastKAN, Học sâu.

I. PHẦN GIỚI THIỆU

1. Đặt vấn đề

Trong kỷ nguyên Web3, sự trỗi dậy của các giao thức mạng xã hội phi tập trung như Lens Protocol đã mở ra một chương mới cho quyền sở hữu dữ liệu và khả năng tương tác không cần tín thác. Khác với các nền tảng tập trung truyền thống, hệ sinh thái mạng xã hội phi tập trung cho phép người dùng thực hiện các hoạt động kinh tế và xã hội đồng thời thông qua các thực thể số như tài khoản NFT, bài đăng hay hành vi thu thập dữ liệu. Tuy nhiên, tính mở và cơ chế khuyến khích kinh tế của Web3 cũng trở thành mục tiêu của các cuộc tấn công giả mạo Sybil. Việc một cá nhân hoặc tổ chức tạo lập hàng loạt tài khoản ảo nhằm thao túng thuật toán quản trị, trục lợi từ các chương trình tặng thưởng mã thông báo hay làm sai lệch chỉ số uy tín đang trở thành một thách thức nghiêm trọng, đe dọa đến tính bền vững của toàn bộ hệ sinh thái.

Đặc điểm cốt lõi của dữ liệu trên mạng xã hội phi tập trung là tính đa quan hệ và sự phụ thuộc lẫn nhau giữa các thực thể trên chuỗi khối. Một tài khoản giả mạo hiện đại không chỉ đơn thuần sao chép thông tin hồ sơ mà còn xây dựng các mạng lưới tương tác phức tạp để ngụy trang hành vi. Mỗi thực thể trong mạng lưới này tồn tại dưới dạng một tập hợp các đặc trưng đa chiều: từ dữ liệu tĩnh như tên người dùng và tiểu sử, dữ liệu hành vi xã hội như theo dõi và tương tác, đến các đặc trưng tài chính đặc thù như phí gas, quyền đồng sở hữu và lịch sử giao dịch. Những hạn chế của các phương pháp phân loại truyền thống như mạng nơ-ron đa tầng hay mạng nơ-ron tích chập là chỉ tập trung vào các đặc trưng độc lập, từ đó bỏ sót các cấu trúc liên kết ẩn và sự tương đồng về hành vi trong không gian đồ thị siêu đặc.

Trước những thách thức trên, nghiên cứu này đề xuất phương pháp phát hiện tài khoản Sybil thông qua quy trình học biểu diễn đồ thị đa tầng kết hợp mạng nơ-ron đồ thị (GNN). Đề tài xây dựng một cấu trúc đồ thị bốn tầng nhằm khai thác triệt để các mối quan hệ từ cấp độ nhận diện đến các ràng buộc tài chính giữa các ví sở hữu. Bằng cách ứng dụng bộ mã hóa tự động đồ thị (GAE) trong giai đoạn học không giám sát, mô hình có khả năng nén và trích xuất những đặc trưng nhúng mang tính đại diện cao trong bối cảnh thiếu hụt nhãn dữ liệu thực tế.

Điểm đột phá của nghiên cứu nằm ở việc thực hiện thực nghiệm so sánh giữa các kiến trúc đồ thị tiên tiến như PNA và mô hình phân lớp tách rời. Việc kết hợp khả năng tổng hợp thông tin đa dạng của kiến trúc PNA cùng tính ổn định của các mô hình học máy truyền thống trong không gian nhúng hứa hẹn sẽ mang lại hiệu quả phân lớp vượt trội, khắc phục hiện tượng sụp đổ thông tin do quá trình làm mịn quá mức trên các đồ thị Web3 quy mô lớn. Kết quả của nghiên cứu không chỉ đóng góp về mặt thuật toán mà còn cung cấp một công cụ hữu hiệu trong việc bảo vệ tính minh bạch và an toàn cho các nền tảng mạng xã hội phi tập trung thế hệ mới.

2. Những nghiên cứu liên quan

Những năm gần đây, việc khai thác dữ liệu đa phương thức đang trở thành xu hướng chủ đạo. Sự kết hợp giữa thông tin đặc trưng từ hình ảnh, âm thanh và ngữ

nghĩa văn bản giúp máy tính "hiểu" dữ liệu ICH một cách trọn vẹn hơn. Tuy nhiên, thách thức lớn nhất vẫn nằm ở việc mô hình hóa sự tương tác phức tạp giữa các phương thức dữ liệu khác nhau.

Trong lĩnh vực phân loại ICH, Qin và cộng sự [4] đã chỉ ra rằng các phương pháp truyền thống thường chỉ tập trung vào đặc trưng thị giác mà bỏ qua các mô tả văn bản đi kèm. Để khắc phục, nhóm tác giả đề xuất mô hình MICMLF (Multimodal Attention and Hierarchical Fusion) áp dụng cho bài toán phân loại ảnh di sản (từ 2 tập dữ liệu là New Year Print và Clay Figurine). Mô hình này sử dụng cơ chế chú ý đa phương thức (Multimodal Attention) để tập trung vào các vùng ảnh và từ khóa quan trọng, kết hợp với hợp nhất phân cấp (Hierarchical Fusion) để nắm bắt các tương tác giữa hình ảnh và văn bản. Kết quả thực nghiệm cho thấy sự vượt trội so với các phương pháp đơn phương thức. Tuy nhiên, giới hạn của nghiên cứu này là chưa khai thác được đặc trưng của âm thanh.

Để giải quyết bài toán biểu diễn dữ liệu phức tạp hơn, hướng tiếp cận dựa trên đồ thị đang nhận được sự quan tâm lớn. Trong bài khảo sát toàn diện của Peng và cộng sự [14] về học máy trên đồ thị đa phương thức (Learning on Multimodal Graphs), các tác giả khẳng định rằng đồ thị là cấu trúc dữ liệu tự nhiên nhất để biểu diễn các mối quan hệ không đồng nhất. Việc xem mỗi đối tượng dữ liệu là một đỉnh trong đồ thị cho phép mô hình nắm bắt được cấu trúc topo và sự phụ thuộc lẫn nhau giữa các nguồn thông tin. Mặc dù vậy, đa số các kiến trúc GNN hiện nay vẫn sử dụng mạng Perceptron đa lớp (MLP) tại các nút để xử lý đặc trưng. Điều này dẫn đến hạn chế về "hộp đen" (khả năng giải thích kém) và hiệu quả tham số chưa tối ưu khi mô hình hóa các hàm phức tạp trong dữ liệu văn hóa.

Nhằm khắc phục nhược điểm của MLP, Liu và cộng sự [12] đã giới thiệu một kiến trúc đột phá mang tên Kolmogorov-Arnold Network (KAN). Thay vì sử dụng hàm kích hoạt cố định tại các nút như MLP, KAN đặt các hàm kích hoạt có thể học được trên các cạnh. Kiến trúc này không chỉ giúp giảm số lượng tham số đáng kể mà còn cung cấp khả năng giải thích minh bạch hơn về mặt toán học. Tuy nhiên, tiềm năng của việc kết hợp KAN vào các mô hình đồ thị đa phương thức (Multimodal Graph + KAN) để xử lý dữ liệu video văn hóa quy mô lớn vẫn là một hướng đi mới mẻ và chưa có nhiều công bố khoa học.

Tại Việt Nam, các nghiên cứu nền tảng như PhoBERT của Nguyễn Quốc Đạt và cộng sự [13] đã giải quyết tốt bài toán xử lý ngôn ngữ tự nhiên tiếng Việt. Song, các hệ thống tích hợp đa phương thức chuyên sâu cho ICH vẫn chưa được khai thác nhiều. Đa phần các nghiên cứu hiện tại chỉ dừng lại ở việc xử lý riêng lẻ hình ảnh hoặc văn bản, chưa có một phương pháp, kiến trúc thống nhất để đồng bộ hóa và học biểu diễn từ cả video, âm thanh và văn bản tiếng Việt.

Tóm lại, từ các phân tích trên, có thể thấy khoảng trống nghiên cứu nằm ở hai điểm chính: (1) Sự thiếu hụt các mô hình xử lý video văn hóa kết hợp cả ba luồng thông tin (thay vì chỉ ảnh và text như MICMLF); và (2) Chưa có sự ứng dụng các kiến trúc mới như KAN vào GNN để tối ưu hóa hiệu năng và khả năng giải thích. Đây chính là động lực để đề xuất mô hình đồ thị đa phương thức kết hợp GNN

(GAT) và KAN.

3. Mục tiêu đề tài

Mục tiêu của đề tài là nghiên cứu và xây dựng hệ thống phân loại video, hình ảnh, văn bản và âm thanh văn hoá phi vật thể bằng việc tận dụng mô hình đồ thị đa phương thức kết hợp với mạng KAN. Đề tài hướng tới việc cải tiến kết quả phân lớp bằng cách cho mô hình học các mối quan hệ phức tạp giữa thông tin hình ảnh, văn bản (phụ đề) và âm thanh. Kết quả nghiên cứu sẽ cung cấp cơ sở thực nghiệm cho việc ứng dụng các kiến trúc mạng noron thế hệ mới (KAN) vào bài toán phân lớp dùng đồ thị đa phương thức. Các kết quả cụ thể mà đề tài hướng đến bao gồm:

- **Thu thập và tiền xử lý dữ liệu đa phương thức:** Thu thập dữ liệu video và phụ đề tương ứng từ nền tảng Youtube thuộc các chủ đề văn hóa đặc trưng như: Vía bà chúa xứ Núi Sam, Nghề đan tre, Nghề dệt chiếu, Lễ hội nghinh Ông,... Thực hiện các kỹ thuật tiền xử lý bao gồm: cắt video thành các đoạn ngắn (video segments), đồng bộ hóa phụ đề, và lọc bỏ những mẫu dữ liệu nhiễu hoặc không liên quan đến nội dung văn hóa để xây dựng bộ dữ liệu huấn luyện và kiểm thử.
- **Xây dựng và đánh giá mô hình đơn phương thức (baseline):** Xây dựng mô hình baseline chỉ để phân loại chỉ sử dụng dữ liệu hình ảnh. Sử dụng các kiến trúc mạng noron tích chập (CNN) phổ biến đã được huấn luyện trên tập ImageNet (như ResNet, RegNet,...) làm bộ trích xuất đặc trưng nền tảng (backbone). Tiến hành đóng băng (freeze) các tham số của backbone và huấn luyện tầng phân lớp (classifier) để đánh giá hiệu quả khi chỉ dùng hình ảnh. Kết quả này đóng vai trò là mốc so sánh và là thành phần trích xuất đặc trưng cho mô hình đồ thị đa phương thức.
- **Xây dựng và đánh giá mô hình MGNN kết hợp KAN:** Xây dựng mô hình đồ thị đa phương thức sử dụng mạng noron đồ thị (GNN), cụ thể hơn là Graph Attention Network (GAT). Tận dụng backbone hình ảnh đã thử nghiệm ở giai đoạn (2) để tận dụng đặc trưng hình ảnh giàu thông tin. Xây dựng các tầng GAT để học mối quan hệ ngữ nghĩa giữa hình ảnh, văn bản, và âm thanh. Đồng thời tích hợp bộ phân lớp bằng KAN để tăng tính biểu diễn phi tuyến, với kỳ vọng đạt được độ chính xác cao hơn, ngoài ra đề tài cũng sẽ tiến hành thử nghiệm trên mạng MLP và mô hình máy học truyền thống để có nhiều góc nhìn so sánh trực quan.
- **Triển khai hệ thống trên nền tảng web:** Xây dựng ứng dụng web để minh họa kết quả nghiên cứu. Hệ thống cho phép người dùng tải lên video, hình ảnh, văn bản và âm thanh. Đầu ra của hệ thống là nhãn chủ đề văn hóa được dự đoán bởi mô hình, kèm theo độ tin cậy của dự đoán, giúp người dùng có thể kiểm chứng hiệu quả của mô hình.

4. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu của đề tài là các mô hình học sâu đa phương thức dựa trên kiến trúc đồ thị, bao gồm các cơ chế tổng hợp thông tin giữa hình ảnh, văn bản và âm thanh. Cốt lõi của đề tài là tìm hiểu, xây dựng và đánh giá các mô hình GNN

(đặc biệt là GAT) kết hợp với các kiến trúc mới như KAN (FastKAN), cùng với MLP và các mô hình máy học truyền thống trong vai trò bộ phân lớp. Đề tài hướng đến việc khảo sát cách các phương thức dữ liệu khác nhau có thể được biểu diễn và liên kết trong một cấu trúc đồ thị thống nhất để phục vụ nhiệm vụ phân loại văn hoá phi vật thể.

Phạm vi nghiên cứu được giới hạn trong phạm vi dữ liệu video văn hoá được thu thập từ YouTube, tập trung vào các chủ đề như lễ hội dân gian và nghề thủ công truyền thống tại Việt Nam. Từ các video này, nghiên cứu chỉ khai thác ba loại dữ liệu chính: (1) khung hình trong video, (2) văn bản phụ đề hoặc mô tả, và (3) đặc trưng âm thanh. Các phân tích, thử nghiệm và đánh giá đều được thực hiện trong khuôn khổ bộ dữ liệu này, không mở rộng sang các loại hình di sản khác hoặc các nguồn dữ liệu ngoài phạm vi đã nêu.

5. Phương pháp nghiên cứu

Để giải quyết bài toán phân lớp dữ liệu văn hóa phi vật thể đa phương thức, đề tài áp dụng cách tiếp cận hỗn hợp, kết hợp giữa nghiên cứu lý thuyết để nắm bắt cơ sở khoa học, phương pháp thực nghiệm và phân tích định lượng để kiểm chứng hiệu quả mô hình. Cụ thể như sau:

- Phương pháp nghiên cứu lý thuyết: Tìm hiểu và tổng hợp tài liệu về các kỹ thuật trích xuất đặc trưng (CNN, Transformer, MFCC), lý thuyết mạng noron đồ thị (GNN), Graph Attention Network (GAT) và kiến trúc KAN (FastKAN).
- Phương pháp thực nghiệm và phân tích định lượng: Xây dựng, huấn luyện mô hình trên dữ liệu thực tế; sử dụng các thang đo độ chính xác cho bài toán phân lớp (Accuracy, Precision, Recall, F1-Score) để đánh giá và so sánh kết quả giữa các phương pháp.

Tóm tắt quy trình thực hiện: Quy trình nghiên cứu bắt đầu từ việc thu thập và tiền xử lý dữ liệu trên cả ba phương thức (hình ảnh, văn bản, âm thanh), với dữ liệu được tải từ nguồn video thực tế. Dựa trên tập dữ liệu này, đề tài thực hiện xây dựng mô hình phân loại đơn phương thức (CNN Baseline) để tạo mốc chuẩn cho đánh giá, ngoài ra còn dùng để trích xuất đặc trưng cho mô hình đồ thị đa phương thức. Trọng tâm của quy trình là việc thiết kế và huấn luyện kiến trúc đồ thị đa phương thức kết hợp GAT và KAN nhằm học các mối quan hệ ngữ nghĩa phức tạp. Cuối cùng, kết quả nghiên cứu được đánh giá định lượng trên tập kiểm thử và kiểm chứng thực tế thông qua việc triển khai lên ứng dụng Web.

6. Bố cục quyển báo cáo

Quyển báo cáo gồm có 3 phần chính là: Phần giới thiệu, Phần nội dung và Phần kết luận, cuối quyển báo cáo là phần Tài liệu tham khảo chứa những quyển sách, bài báo được trích dẫn trong báo cáo. Cụ thể phần bố cục được chia như sau:

- **Phần giới thiệu:** Trình bày các vấn đề hiện tại, các nghiên cứu liên quan, mục tiêu của đề tài, đối tượng và phạm vi nghiên cứu, cùng với phương pháp nghiên cứu được áp dụng.
- **Phần nội dung:**

+ **Chương 1 – Mô tả bài toán:** Giới thiệu chi tiết về bài toán, bao gồm các kiến thức và framework cụ được sử dụng trong quá trình nghiên cứu đề tài.
+ **Chương 2 – Thiết kế và cài đặt giải pháp:** Mô tả sơ lược về pipeline của hệ thống và kiến trúc của mô hình. Đồng thời mô tả phương pháp thu thập và tiền xử lý dữ liệu.
+ **Chương 3 – Kiểm thử và đánh giá:** Trình bày giao diện sản phẩm và thực hiện đánh giá kết quả thực nghiệm của mô hình đề ra.

– **Phần kết luận:** Tóm tắt kết quả đạt được, nêu lên những hạn chế của đề tài và đề xuất hướng phát triển trong tương lai.

– **Tài liệu tham khảo:** Liệt kê các nguồn tài liệu được sử dụng trong quá trình nghiên cứu và thực hiện đề tài.

II. PHẦN NỘI DUNG

CHƯƠNG 1. MÔ TẢ BÀI TOÁN

1. Mô tả chi tiết bài toán

1.1. Bài toán phân lớp dữ liệu ICH

Nghiên cứu tập trung giải quyết bài toán phân lớp ICH dựa trên dữ liệu đa phương thức gồm video (được trích xuất thành hình ảnh/âm thanh), hình ảnh, văn bản và âm thanh vào các nhóm chủ đề (các lớp) đã được xác định trước. Khác với các phương pháp phân lớp truyền thống chỉ dựa trên hình ảnh tĩnh, bài toán này đòi hỏi mô hình phải có khả năng tổng hợp và xử lý tri thức từ nhiều nguồn thông tin phức tạp, phản ánh đúng tính chất đa dạng của dữ liệu ICH.

Hệ thống phân lớp được xây dựng dựa trên ba cách thức xử lý đặc trưng chính:

– Đặc trưng hình ảnh: Phân tích đặc điểm không gian, trang phục, động tác biểu diễn hoặc quy trình thủ công thông qua các khung hình trích xuất từ video hoặc hình ảnh đầu vào. Quá trình này sử dụng các kiến trúc CNN tiên tiến (được huấn luyện trước trên tập ImageNet) làm bộ trích xuất đặc trưng nền tảng (backbone).

– Đặc trưng văn bản: Khai thác thông tin ngữ nghĩa từ phụ đề video hoặc văn bản mô tả do người dùng nhập liệu. Các từ khóa quan trọng và ngữ cảnh câu được trích xuất và mã hóa thành các vector đặc trưng (embeddings) thông qua mô hình thuộc dòng Sentence Transformers, giúp máy hiểu được nội dung văn bản.

– Đặc trưng âm thanh: Đối với các loại hình diễn xướng hoặc lễ hội, cần tận dụng các tín hiệu âm thanh đặc trưng (như giai điệu, tiết tấu), bằng cách sử dụng kỹ thuật trích xuất như MFCC để phân biệt các sắc thái nghệ thuật.

Mục tiêu cốt lõi của đề tài là xây dựng một kiến trúc hợp nhất dựa trên sự kết hợp giữa mạng noron đồ thị đa phương thức (MGAT) và KAN (FastKAN). Kiến trúc này đóng vai trò tích hợp và liên kết các đặc trưng rời rạc thu được từ ba phương thức khác nhau vào một không gian biểu diễn tri thức thống nhất, nhằm cải thiện độ chính xác cho bài toán phân lớp dữ liệu ICH.

1.2. Ứng dụng Web

Để minh chứng cho tính thực tiễn của mô hình nghiên cứu và hỗ trợ người dùng trong việc phân lớp dữ liệu ICH, đề tài triển khai xây dựng ứng dụng web ICH Predictor. Hệ thống được thiết kế không chỉ để đưa ra kết quả dự đoán mà còn hướng tới việc trực quan hóa, giúp người dùng có thêm góc nhìn khác về cách mà dữ liệu tương tác với nhau.

Các chức năng chính của hệ thống bao gồm:

– **Chức năng 1 – Dự đoán đơn phương thức:** Người dùng tải lên video hoặc tập hợp hình ảnh. Hệ thống sẽ sử dụng mô hình CNN Baseline để trích xuất

và phân tích dựa trên dữ liệu hình ảnh thuần tuý. Kết quả trả về bao gồm nhãn ICH và độ tin cậy của nhãn.

– **Chức năng 2 – Dự đoán đa phương thức (Hình ảnh + Văn bản):** Người dùng cung cấp dữ liệu hình ảnh, video kèm theo văn bản mô tả (nhập trực tiếp hoặc tải lên file `.txt`). Hệ thống sẽ sử dụng mô hình MGAT + FastKAN/MLP được huấn luyện chuyên biệt cho hai phương thức này để tiến hành phân lớp. Bên cạnh kết quả dự đoán, giao diện sẽ hiển thị trực quan cấu trúc đồ thị, minh họa cách các nút hình ảnh và văn bản được liên kết và tương tác với nhau trong quá trình suy luận.

– **Chức năng 3 – Dự đoán đa phương thức toàn diện (Hình ảnh + Văn bản + Âm thanh):** Đây là chức năng cho phép người dùng bổ sung dữ liệu âm thanh cũng như là tận dụng dữ liệu âm thanh từ video trong quá trình dự đoán. Ở chức năng này, hệ thống sẽ sử dụng mô hình MGAT + FastKAN/MLP được huấn luyện với đầy đủ 3 phương thức để cho ra kết quả phân lớp. Tương tự như Chức năng 2, hệ thống sẽ cung cấp nhãn ICH, độ tin cậy và phần trực quan hóa cấu trúc đồ thị đa phương thức.

2. Vấn đề giải pháp liên quan đến bài toán

2.1. Mạng noron tích chập (CNN)

Mạng noron tích chập (CNN) [6] là kiến trúc mạng noron sâu cơ bản trong lĩnh vực thị giác máy tính, được thiết kế chuyên biệt để xử lý dữ liệu có cấu trúc dạng lưới như hình ảnh. Khác với mạng noron truyền thống (MLP) với các kết nối dày đặc, có thể dẫn đến bùng nổ tham số, CNN áp dụng cơ chế *tích chập* (convolution) thường được dùng trong xử lý ảnh. Điều này cho phép mạng tự động trích xuất các đặc trưng phân cấp từ thấp (cạnh, góc) đến cao (vật thể hoàn chỉnh) một cách hiệu quả mà vẫn tối ưu được tài nguyên tính toán, nhờ số lượng tham số nhỏ.

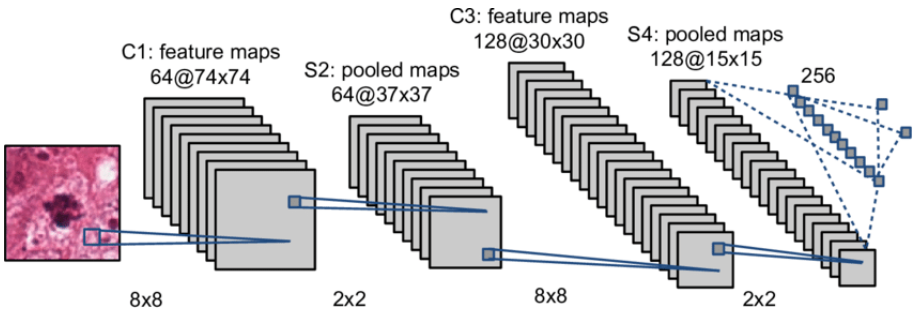

Hình 1. *Minh hoạ kiến trúc cơ bản của CNN*

Một kiến trúc CNN tiêu chuẩn thường bao gồm các loại tầng chính sau:

– Convolutional Layer (Tầng tích chập): Thực hiện phép tích chập giữa dữ liệu đầu vào và các bộ lọc học được (kernels/filters) nhằm trích xuất các đặc trưng cục bộ quan trọng, từ đó hình thành các features map đại diện cho nội dung của hình ảnh.

– Activation Function (Hàm kích hoạt): Được sử dụng sau tầng tích chập để đưa yếu tố phi tuyến vào mô hình, giúp mạng có khả năng biểu diễn và học các quan hệ phức tạp trong dữ liệu.
– Pooling Layer (Tầng gộp): Có nhiệm vụ giảm kích thước của các features map, thường thông qua các phép gộp như max pooling hoặc average pooling, qua đó giảm chi phí tính toán và hạn chế ảnh hưởng của các biến đổi nhỏ về vị trí.
– Fully Connected Layer (Tầng kết nối đầy đủ): Kết hợp các đặc trưng đã được trích xuất ở các tầng trước để tạo ra đầu ra cuối cùng của mô hình, phục vụ cho các bài toán như phân lớp hoặc hồi quy.

Trong quá trình phát triển, nhiều kiến trúc CNN tiên tiến đã ra đời và thường được đánh giá dựa trên bộ dữ liệu chuẩn ImageNet, trong số đó, tiêu biểu gồm những kiến trúc sau đây:

– ResNet (Residual Networks): Được đề xuất nhằm khắc phục hiện tượng biến mất gradient (vanishing gradient) khi huấn luyện các mạng có độ sâu lớn. Thông qua cơ chế kết skip connections, các khối residual học hàm sai khác $F(x)$ so với đầu vào, từ đó giúp quá trình tối ưu ổn định hơn và cho phép xây dựng các mạng có độ sâu lên đến hàng trăm tầng [8].
– DenseNet (Densely Connected Networks): Tăng cường khả năng lan truyền thông tin bằng cách kết nối trực tiếp mỗi tầng với toàn bộ các tầng phía trước theo hướng feed-forward. Cách tổ chức này cho phép tái sử dụng hiệu quả các đặc trưng đã học, giúp mô hình đạt hiệu suất cao trong khi vẫn duy trì số lượng tham số tương đối nhỏ so với các kiến trúc sâu truyền thống [10].
– MobileNet: Là họ kiến trúc được thiết kế hướng tới các thiết bị có tài nguyên hạn chế như thiết bị di động. MobileNet sử dụng phép tích chập tách rời theo chiều sâu (depthwise separable convolution) để thay thế tích chập chuẩn, qua đó giảm đáng kể chi phí tính toán và số tham số mà vẫn đảm bảo độ chính xác ở mức chấp nhận được [9].
– ShuffleNet: Kiến trúc này tiếp tục mở rộng hướng tiếp cận tối ưu hoá cho các thiết bị có tài nguyên hạn chế, bằng cách kết hợp tích chập điểm theo nhóm (pointwise group convolution) với cơ chế hoán đổi kênh (channel shuffle). Cách thiết kế này cho phép tăng cường trao đổi thông tin giữa các nhóm kênh, giúp mô hình đạt hiệu quả cao hơn so với MobileNet trong cùng mức độ phức tạp tính toán [22].
– RegNet: Khác với các kiến trúc được thiết kế thủ công, RegNet tập trung nghiên cứu về network design space. Thông qua phân tích thống kê, RegNet đề xuất các cấu trúc mạng có quy luật rõ ràng, cân bằng hợp lý giữa độ sâu, độ rộng và chi phí tính toán, đồng thời đạt hiệu quả thực nghiệm tốt trên nhiều bài toán thị giác máy tính [21].

2.2. Mô hình embedding câu (Sentence Transformer)

Trong các bài toán xử lý ngôn ngữ tự nhiên (NLP) hiện đại, việc chuyển đổi văn bản thành các vector số thực (embeddings) là bước tiên quyết để máy tính có thể hiểu và xử lý ngữ nghĩa. Khác với các phương pháp truyền thống như Bag-of-Words

hay TF-IDF dựa trên tần suất từ, các mô hình embedding hiện đại ánh xạ văn bản vào một không gian vector, nơi các câu có ngữ nghĩa tương đồng sẽ nằm gần nhau về mặt hình học.

Mặc dù các mô hình ngôn ngữ lớn như BERT (Bidirectional Encoder Representations from Transformers) đạt hiệu quả cao trong nhiều tác vụ, chúng lại không tối ưu cho việc tạo ra vector biểu diễn ở cấp độ câu (sentence embeddings). Để giải quyết vấn đề này, Reimers và Gurevych [15] đã giới thiệu Sentence-BERT (SBERT), một sửa đổi của kiến trúc BERT sử dụng Siamese networks để trích xuất các đặc trưng ngữ nghĩa.

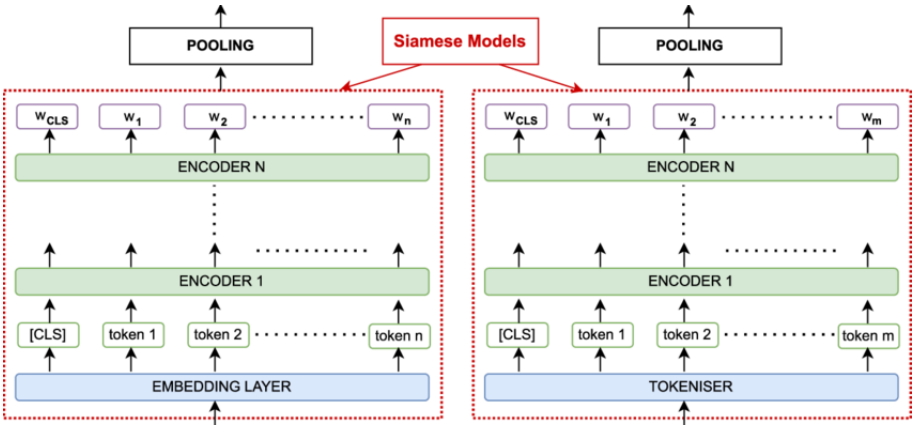

Hình 2. *Minh hoạ kiến trúc cơ bản của SBERT*

Cơ chế hoạt động của SBERT như sau:

- Siamese Architecture: Hai câu văn bản đầu vào được đưa qua cùng một mạng BERT (chia sẻ trọng số) để tạo ra các vector ngữ cảnh.
- Pooling Strategy: Một lớp Pooling (thường là Mean Pooling) được áp dụng để nén thông tin từ các token thành một vector cố định đại diện cho toàn bộ câu.
- Objective Function: Trong quá trình huấn luyện, mạng tối ưu hóa hàm mất mát (như Cosine Similarity Loss) để kéo các vector của các câu có nghĩa giống nhau lại gần và đẩy các câu khác nghĩa ra xa.

Trong thực tế triển khai, các mô hình BERT chuẩn (như BERT-base) là rất nặng và chậm. Để cân bằng giữa hiệu suất và tốc độ, Wang và cộng sự đã thiết kế kiến trúc MiniLM [18] dựa trên kỹ thuật chưng cất tri thức (Knowledge Distillation).

Mô hình all-MiniLM-L6-v2 là một trong những đại diện phổ biến nhất của dòng này (được triển khai trong thư viện *sentence-transformers*), với các đặc điểm kỹ thuật sau:

- Kiến trúc: Sử dụng MiniLM làm nền tảng, mô hình này đóng vai trò là "học sinh" (student) học lại tri thức từ các mô hình "giáo viên" (teacher) lớn hơn như BERT hoặc RoBERTa. Đặc biệt, MiniLM chưng cất cả mối quan hệ self-attention thay vì chỉ chưng cất lớp đầu ra, giúp mô hình nhỏ giữ được khả năng hiểu ngữ cảnh sâu.

– Cấu hình: Ký hiệu "L6" biểu thị mô hình chỉ có 6 lớp Transformer (so với 12 lớp của BERT-base), giúp giảm kích thước mô hình xuống khoảng 80MB và tăng tốc độ suy luận lên hơn 5 lần.
– Biểu diễn: Đầu ra là một vector có kích thước 384 chiều. Mặc dù số chiều nhỏ hơn so với chuẩn 768 của BERT, all-MiniLM-L6-v2 vẫn duy trì độ chính xác cao trên các bảng xếp hạng đánh giá embedding (như MTEB), đặc biệt hiệu quả cho các tác vụ tìm kiếm ngữ nghĩa và gom nhóm văn bản.

2.3. Đặc trưng MFCC của âm thanh

Trong xử lý tín hiệu âm thanh và nhận dạng tiếng nói, việc trích xuất đặc trưng là bước chuyển đổi tín hiệu miền thời gian sang miền tần số rút gọn, giúp mô hình loại bỏ các nhiễu nền và tập trung vào các thành phần mang thông tin ngữ nghĩa. Phương pháp phổ biến và hiệu quả nhất hiện nay là sử dụng Mel-Frequency Cepstral Coefficients (MFCC) kết hợp với các đặc trưng động của chúng.

MFCC [2] được thiết kế dựa trên đặc điểm sinh lý học của tai người. Tai người không cảm nhận tần số theo tuyến tính mà theo thang đo logarit (nhạy cảm hơn với sự thay đổi ở tần số thấp và kém nhạy cảm hơn ở tần số cao).

Quy trình trích xuất MFCC bao gồm các bước: Tín hiệu âm thanh được chia thành các khung (frames) ngắn (thường 20-30ms), rồi áp dụng biến đổi Fourier, sau đó đi qua một bộ lọc (Filterbank) được phân bố theo thang đo Mel. Mối quan hệ giữa tần số Hertz (f) và tần số Mel (m) được mô tả qua công thức:

$$m = 2595 \log_{10}\left(1 + \frac{f}{700}\right)$$

Cuối cùng, phép biến đổi cosine rời rạc được áp dụng lên log năng lượng của các bộ lọc để tạo ra các hệ số MFCC, giúp loại bỏ sự tương quan giữa các chiều dữ liệu.

Điểm đặc trưng của MFCC là chỉ biểu diễn được các đặc trưng quang phổ tĩnh (static spectral features) của một khung tại một thời điểm, bỏ qua tính chất thay đổi theo thời gian của tín hiệu âm thanh. Để khắc phục điều này, Furui [5] đã giới thiệu việc sử dụng các đạo hàm bậc một và bậc hai của chuỗi MFCC:

– Delta: Là đạo hàm bậc một của MFCC, biểu diễn vận tốc thay đổi của các hệ số cepstral giữa các khung liên tiếp. Công thức tính hệ số Delta d_t tại thời điểm t thường được tính bằng hồi quy tuyến tính trên một cửa sổ ngắn N:

$$d_t = \frac{\sum_{n=1}^{N} n(c_{t+n} - c_{t-n})}{2\sum_{n=1}^{N} n^2}$$

  Trong đó c_t là hệ số MFCC tại thời điểm t.

– Delta-Delta: Là đạo hàm bậc hai của MFCC (hay đạo hàm của Delta), đại diện cho gia tốc hay sự thay đổi của Delta theo thời gian.

Trong thực nghiệm, một vector đặc trưng âm thanh hoàn chỉnh thường là sự kết hợp của ba thành phần này. Ví dụ, nếu sử dụng 13 hệ số MFCC đầu tiên, kết hợp

với 13 hệ số Delta và 13 hệ số Delta-Delta, ta sẽ thu được một vector đặc trưng 39 chiều cho mỗi khung thời gian, nắm bắt đầy đủ cả thông tin phổ âm và động lực học của tín hiệu.

2.4. Đồ thị đa phương thức (MG)

Đồ thị đa phương thức (MG) [14] là một cấu trúc dữ liệu cho phép mô hình hóa sự kết hợp giữa dữ liệu hình ảnh, văn bản và âm thanh trong một không gian thống nhất.

Về mặt định nghĩa, một đồ thị đa phương thức $G = (V, E)$ được đặc trưng bởi hai thành phần:

- Tập hợp các đỉnh V chứa dữ liệu hoặc đặc trưng thuộc về một hoặc nhiều phương thức khác nhau.
- Tập hợp các cạnh E thể hiện mối quan hệ tương tác giữa các đỉnh trong tập V.

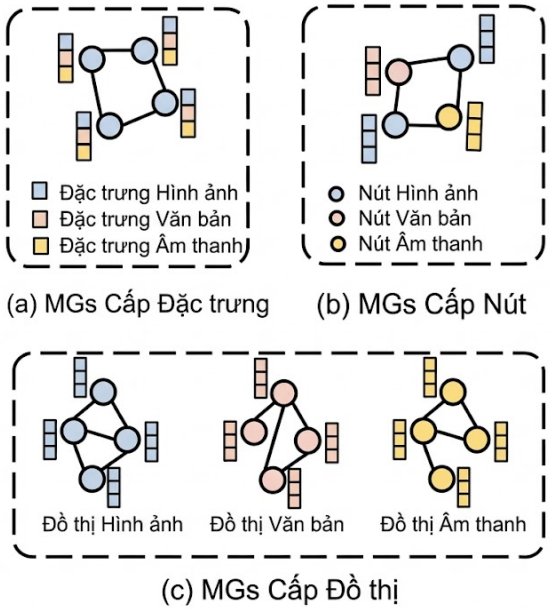

Hình 3. *Các kiến trúc đồ thị đa phương thức phổ biến*

Dựa vào cách thức phân phối dữ liệu đa phương thức trên các đỉnh, cũng như cách mà chúng kết nối với nhau, Peng và cộng sự [14] đã tiến hành phân loại MG thành ba dạng kiến trúc chính:

- Đồ thị đa phương thức cấp đặc trưng (Feature-Level MG): Tại cấp độ này, tính đa phương thức được tích hợp ngay bên trong mỗi đỉnh của đồ thị. Mỗi đỉnh $v_i \in V$ lưu trữ một tập hợp các đặc trưng từ tất cả các phương thức có sẵn.
- Đồ thị đa phương thức cấp đỉnh (Node-Level MG): Trong kiến trúc này, mỗi đỉnh chỉ mang đặc trưng của một phương thức duy nhất (đơn phương thức), nhưng toàn bộ đồ thị là tập hợp của các đỉnh thuộc nhiều loại phương thức khác nhau cùng tồn tại và kết nối.

– Đồ thị đa phương thức cấp đồ thị (Graph-Level MG): Loại đồ thị này được xây dựng từ một tập các đồ thị con (subgraphs), trong đó mỗi đồ thị con mô tả cấu trúc quan hệ của các thực thể dưới góc nhìn của một phương thức riêng biệt. Đặc biệt, các cạnh chỉ tồn tại giữa các đỉnh thuộc cùng một đồ thị con, tức là các kết nối chỉ được thiết lập trong phạm vi từng phương thức và không có kết nối trực tiếp giữa các đỉnh thuộc các phương thức khác nhau.

2.5. Mạng noron đồ thị (GNN)

Mạng noron đồ thị (GNN) [7] là một mô hình học sâu được thiết kế để xử lý dữ liệu có cấu trúc đồ thị. Mục tiêu cốt lõi của GNN là học một vector biểu diễn (embedding) cho mỗi đỉnh, cạnh hoặc toàn bộ đồ thị, sao cho vector này bảo toàn được cả đặc trưng tại các đỉnh và thông tin cấu trúc của đồ thị đó.

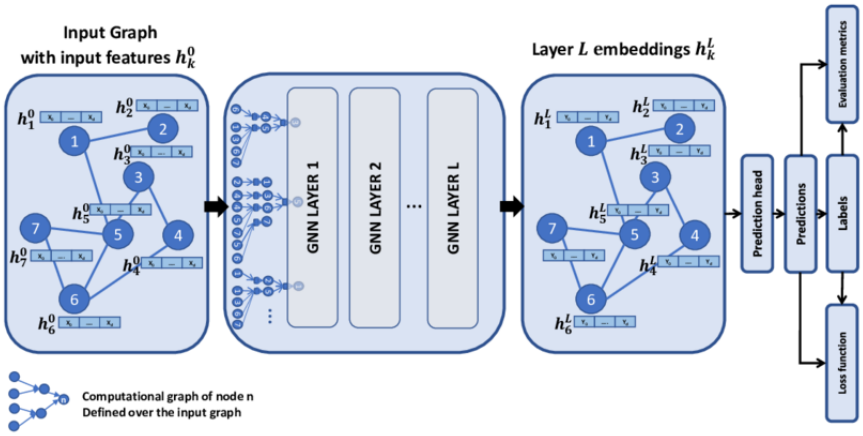

Hình 4. *Minh hoạ kiến trúc cơ bản của GNN*

Cơ chế hoạt động nền tảng của hầu hết các GNN hiện đại là truyền thông điệp (Message Passing). Tại mỗi tầng k, vector đặc trưng của đỉnh v được cập nhật bằng cách tổng hợp thông tin từ các đỉnh hàng xóm $N(v)$:

$$h_v^{(k)} = \text{UPDATE}^{(k)}\left(h_v^{(k-1)}, \text{AGGREGATE}^{(k)}\left(\{h_u^{(k-1)} | u \in N(v)\}\right)\right)$$

Trong đó $h_v^{(k)}$ là hidden state của đỉnh v tại tầng k, hàm AGGREGATE có nhiệm vụ gom thông tin từ hàng xóm, và hàm UPDATE kết hợp thông tin đó với trạng thái hiện tại của đỉnh.

Có rất nhiều phiên bản cụ thể được triển khai từ GNN, trong đó nổi bật nhất phải kể đến Graph Attention Network (GAT). Kiến trúc này được giới thiệu bởi Veličković và cộng sự [17], họ đề xuất cơ chế self-attention để học trọng số cho các cạnh. Điều này cho phép mô hình tập trung vào các hàng xóm quan trọng nhất đối với đỉnh đang xét.

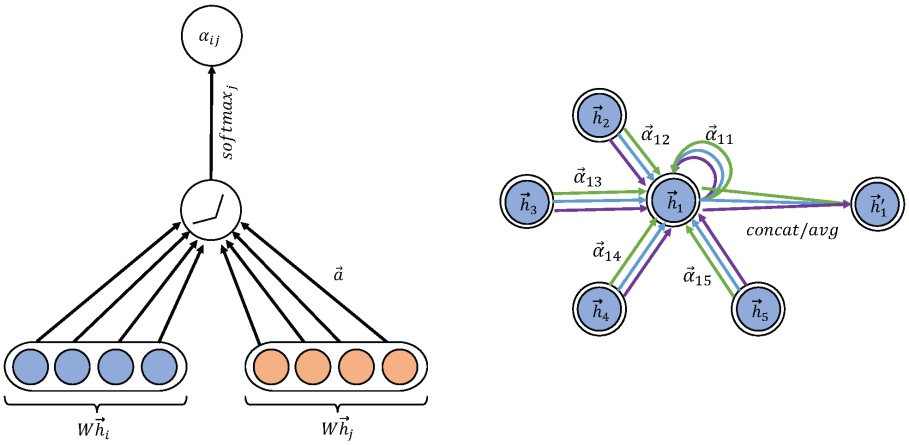

Hình 5. *Minh hoạ kiến trúc cơ bản của GAT*

Cơ chế Attention trong GAT được thực hiện như sau:

– Đầu tiên, hệ số chú ý (attention coefficient) e_{ij} giữa đỉnh i và đỉnh lân cận j được tính toán thông qua một mạng noron truyền thẳng:

$$e_{ij} = \text{LeakyReLU}\left(\vec{a}^T [\mathbf{W}\vec{h}_i \| \mathbf{W}\vec{h}_j]\right)$$

Trong đó: $\vec{a}$ là một vector trọng số có thể học được, $\mathbf{W}$ là ma trận trọng số, $\|$ là phép nối (concatenation), và hàm kích hoạt LeakyReLU đảm bảo tính phi tuyến.

– Để so sánh được các hệ số giữa các đỉnh khác nhau, Veličković và cộng sự đề xuất sử dụng hàm softmax được để chuẩn hóa trọng số chú ý α_{ij}:

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in N_i} \exp(e_{ik})}$$

– Cuối cùng, vector đặc trưng đầu ra của đỉnh i được tính bằng tổng có trọng số của các đặc trưng hàng xóm:

$$\vec{h}'_i = \sigma\left(\sum_{j \in N_i} \alpha_{ij} \mathbf{W}\vec{h}_j\right)$$

Trong đó σ là một hàm kích hoạt dạng phi tuyến, thường là ELU.

GAT cũng sử dụng cơ chế Multi-head Attention tương tự như Transformer để ổn định quá trình huấn luyện, cho phép mô hình học các mối quan hệ ngữ nghĩa đa dạng từ nhiều không gian con khác nhau. Cụ thể, với K đầu attention độc lập, quá trình tổng hợp vector đầu ra $\vec{h}'_i$ được thực hiện theo hai trường hợp:

– Trường hợp 1 (Concatenation): Thường được áp dụng tại các tầng ẩn. Kết quả từ K đầu chú ý sẽ được nối lại với nhau, tạo ra vector đặc trưng có số chiều

mở rộng:

$$\vec{h}'_i = \Big\|_{k=1}^{K} \sigma\left(\sum_{j\in N_i} \alpha_{ij}^{(k)} \mathbf{W}^{(k)} \vec{h}_j\right)$$

Trong đó $\|$ biểu diễn phép nối vector, $\alpha_{ij}^{(k)}$ là hệ số chú ý chuẩn hóa của đầu thứ k, và $\mathbf{W}^{(k)}$ là ma trận trọng số tương ứng.

– Trường hợp 2 (Averaging): Thường được áp dụng tại tầng đầu ra (output layer) hoặc tầng phân lớp cuối cùng để đưa vector về kích thước mong muốn. Thay vì nối, mô hình thực hiện lấy trung bình cộng và áp dụng hàm kích hoạt phi tuyến sau cùng:

$$\vec{h}'_i = \sigma\left(\frac{1}{K}\sum_{k=1}^{K}\sum_{j\in N_i} \alpha_{ij}^{(k)} \mathbf{W}^{(k)} \vec{h}_j\right)$$

2.6. Mạng Kolgomorov-Arnold (KAN)

Trong nhiều thập kỷ, kiến trúc MLP đã đóng vai trò là xương sống của hầu hết các mô hình học sâu. Tuy nhiên, MLP tồn tại những hạn chế trong khả năng biểu diễn phi tuyến đối với các đặc trưng phức tạp. Gần đây, Liu và cộng sự [12] đã đề xuất một kiến trúc mới, gọi là mạng Kolmogorov-Arnold (KAN), kiến trúc này dựa trên định lý biểu diễn Kolmogorov-Arnold.

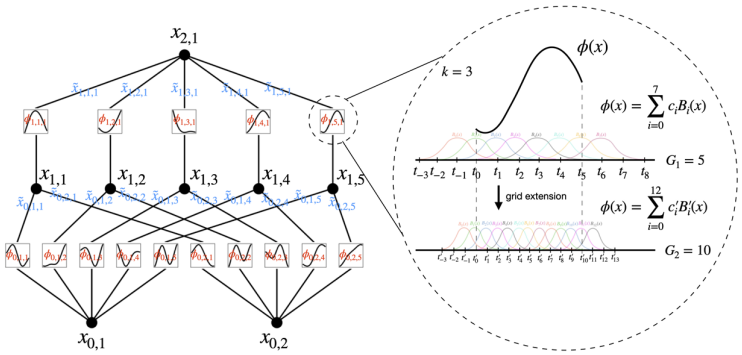

Hình 6. *Minh hoạ kiến trúc cơ bản của KAN*

Khác với MLP – nơi các hàm kích hoạt (activation functions) là cố định tại các nút và trọng số là các tham số học được trên các cạnh, KAN đảo ngược tư duy này: KAN không có trọng số tuyến tính, thay vào đó, mỗi cạnh kết nối chứa một hàm kích hoạt phi tuyến có thể học được (thường được tham số hóa bởi B-splines).

Về mặt toán học, nếu MLP xấp xỉ hàm số thông qua tổ hợp tuyến tính và phi tuyến xen kẽ, thì một tầng KAN biểu diễn hàm mục tiêu Φ dựa trên công thức:

$$\Phi(\mathbf{x}) = \sum_{q=1}^{2n+1} \Phi_q\left(\sum_{p=1}^{n} \phi_{q,p}(x_p)\right)$$

Trong đó $\phi_{q,p}$ là các hàm đơn biến có thể học được. Kiến trúc này cho phép KAN đạt độ chính xác tương đương hoặc hơn MLP nhưng với số lượng tham số ít hơn đáng kể.

Mặc dù KAN mang lại lợi ích lớn về mặt lý thuyết, việc triển khai nguyên bản sử dụng B-splines gặp trở ngại lớn về tốc độ tính toán trên GPU do khó tận dụng khả năng tính toán song song ma trận. Để giải quyết vấn đề này, tác giả Li [11] đã giới thiệu FastKAN.

FastKAN thay thế việc tính toán B-splines phức tạp bằng các hàm Gaussian Radial Basis Functions (Gaussian RBF) kết hợp với các phép nhân ma trận tiêu chuẩn. Cải tiến này giúp:

- Chuyển đổi các phép tính cục bộ của spline thành các phép tính vector hóa, tận dụng tối đa sức mạnh của CUDA core trên GPU.
- Tăng tốc độ huấn luyện lên gấp nhiều lần (thường là 3-5 lần) so với KAN gốc mà vẫn duy trì độ chính xác tương đương.

Sự ra đời của FastKAN đã đưa kiến trúc Kolmogorov-Arnold đến gần hơn với các ứng dụng thực tế quy mô lớn, thay vì chỉ dừng lại ở mức độ lý thuyết. Tuy nhiên FastKAN lại có 1 nhược điểm là số lượng tham số có thể lớn hơn KAN gốc, thậm chí là lớn hơn MLP, nhưng đây là một đánh đổi đáng giá cho tốc độ thực thi chậm chạp của KAN.

2.7. Thang đo độ chính xác

Để đánh giá định lượng hiệu quả của các mô hình học sâu trong bài toán phân lớp, việc chỉ dựa vào số lượng mẫu dự đoán đúng là chưa đủ. Mà cần phải dựa trên ma trận nhầm lẫn (Confusion Matrix) với bốn thành phần cơ bản: Dương tính thật (True Positive – TP), Âm tính thật (True Negative – TN), Dương tính giả (False Positive – FP), và Âm tính giả (False Negative – FN), các thành phần này tạo thành các thang đo tiêu chuẩn sau:

- Accuracy: Là tỷ lệ giữa tổng số mẫu được dự đoán đúng trên tổng số mẫu trong tập dữ liệu. Đây là thang đo phổ biến nhất nhưng thường không phản ánh đúng hiệu năng khi tập dữ liệu bị mất cân bằng.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

- Precision: Phản ánh mức độ tin cậy của mô hình khi dự đoán một mẫu là dương tính. Precision trả lời câu hỏi: "Trong số các mẫu mô hình dự đoán là Positive, bao nhiêu mẫu thực sự là Positive?".

$$\text{Precision} = \frac{TP}{TP + FP}$$

- Recall: Còn được gọi là Sensitivity, thang đo này phản ánh khả năng của mô hình trong việc phát hiện các mẫu dương tính thực tế. Recall trả lời câu hỏi:

"Trong tổng số các mẫu thực sự là Positive, mô hình đã bỏ sót bao nhiêu mẫu?".

$$\text{Recall} = \frac{TP}{TP + FN}$$

– F1-Score: Trong thực tế, thường có sự đánh đổi giữa Precision và Recall. F1-Score là trung bình điều hòa của hai giá trị này, cung cấp một đánh giá tổng quát cân bằng hơn, đặc biệt hữu ích trong các bài toán mà dữ liệu phân bố không đều.

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

2.8. Framework web

Để xây dựng một hệ thống tích hợp mô hình học sâu với giao diện người dùng tương tác cao, kiến trúc ứng dụng được chia thành hai phần chính: frontend sử dụng Angular và backend sử dụng FastAPI.

Angular[1] là một framework front-end mã nguồn mở được phát triển và duy trì bởi Google, sử dụng TypeScript làm ngôn ngữ chính và hướng đến việc xây dựng các ứng dụng web một trang (Single Page Application – SPA). Angular là bản tái thiết kế hoàn chỉnh của AngularJS, mang lại một nền tảng hiện đại với cấu trúc dự án rõ ràng, hỗ trợ tốt cho các ứng dụng quy mô lớn, phức tạp và dễ mở rộng hơn so với các phiên bản trước.

Trong các phiên bản gần đây (như Angular 16 trở lên), framework này đã đưa vào một số cải tiến trọng tâm cho mô hình reactivity thông qua cơ chế Signals, giúp quản lý trạng thái và cập nhật giao diện hiệu quả hơn so với các cách tiếp cận truyền thống như Zone.js. Đây là một bước tiến quan trọng trong thiết kế kiến trúc của Angular, hướng tới trải nghiệm phát triển linh hoạt, tối ưu hiệu suất và dễ bảo trì.

Ưu điểm nổi bật của Angular so với các framework như React hay Vue nằm ở tính nguyên khối và định hướng kiến trúc rõ ràng. Angular cung cấp sẵn một hệ sinh thái đồng bộ bao gồm cơ chế định tuyến (routing), HTTP client, quản lý và kiểm tra dữ liệu biểu mẫu (form validation), cùng hệ thống dependency injection mạnh mẽ. Cách tiếp cận này giúp chuẩn hóa cấu trúc dự án, giảm sự phụ thuộc vào các thư viện bên ngoài và nâng cao tính nhất quán trong quá trình phát triển. Nhờ đó, Angular đặc biệt phù hợp với các hệ thống doanh nghiệp quy mô lớn, nơi yêu cầu cao về khả năng bảo trì, mở rộng và ổn định lâu dài.

Về phần backend, FastAPI[2] thường được lựa chọn nhờ hiệu năng vượt trội và khả năng tương thích hoàn hảo với hệ sinh thái Python (ngôn ngữ bản ngữ của AI/Machine Learning).

FastAPI được xây dựng trên chuẩn ASGI (Asynchronous Server Gateway Interface), cho phép xử lý bất đồng bộ các yêu cầu đồng thời, giúp giảm độ trễ khi mô hình AI thực hiện suy luận. Điểm mạnh của FastAPI bao gồm:

[1] https://angular.dev/
[2] https://fastapi.tiangolo.com/

- Hiệu suất cao: Tốc độ xử lý ngang ngửa với NodeJS và Go, nhờ sử dụng Starlette cho phần web và Pydantic cho phần validation dữ liệu.
- Tích hợp AI dễ dàng: Vì chạy trên Python, FastAPI có thể gọi trực tiếp các thư viện PyTorch, TensorFlow hay các mô hình HuggingFace mà không cần qua các cầu nối ngôn ngữ phức tạp.
- Tự động hóa tài liệu: Tự động sinh tài liệu API chuẩn OpenAPI (Swagger UI), giúp việc giao tiếp giữa đội ngũ phát triển frontend và AI engineer trở nên dễ dàng.

CHƯƠNG 2. THIẾT KẾ VÀ CÀI ĐẶT GIẢI PHÁP

1. Thiết kế hệ thống

Quy trình tổng quát của hệ thống được minh họa tại **Hình 7**, bao gồm 4 giai đoạn xử lý tuần tự: (1) Phân tách video, (2) Tiền xử lý và trích xuất đặc trưng, (3) Xây dựng MG, và (4) Suy luận phân tầng.

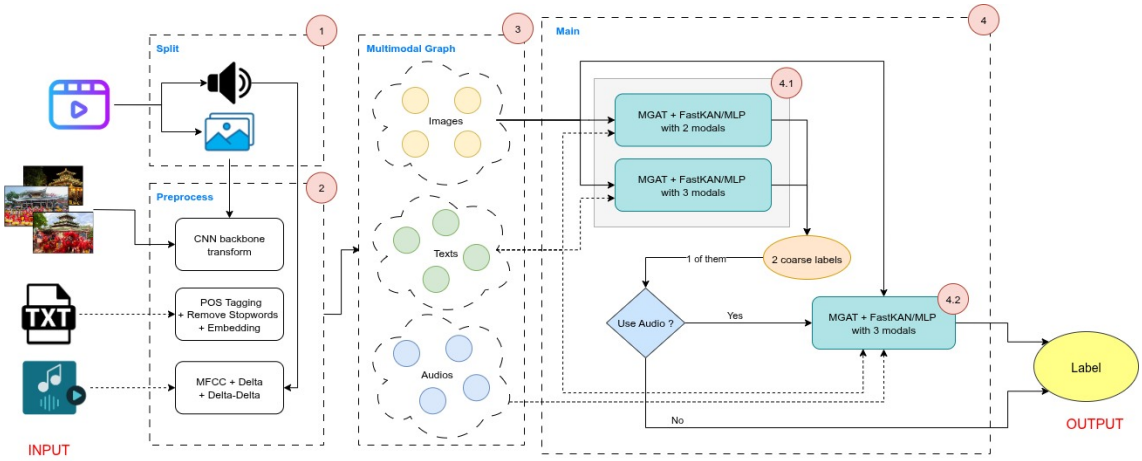

Hình 7. Luồng xử lý tổng quát của hệ thống khi triển khai thành ứng dụng

Đặc tả dữ liệu đầu vào (INPUT): Hệ thống được thiết kế với cơ chế chấp nhận thiếu hụt, cho phép hoạt động ngay cả khi người dùng không cung cấp đầy đủ văn bản hoặc âm thanh. Tuy nhiên, dữ liệu hình ảnh là thành phần bắt buộc. Các ràng buộc cụ thể bao gồm:

- Video: Yêu cầu thời lượng tối thiểu 30 giây và tối đa 2 phút. Trong trường hợp người dùng đã cung cấp đủ tối thiểu 3 hình ảnh hợp lệ, việc tải lên video trở thành tùy chọn.
- Hình ảnh: Số lượng tối thiểu là 3 và tối đa 20 ảnh. Nếu video hợp lệ đã được tải lên, hệ thống sẽ tự động trích xuất khung hình và người dùng không cần thao tác thêm.
- Văn bản: Đây là thành phần tùy chọn. Nếu cung cấp, hệ thống chấp nhận duy nhất 01 tệp tin định dạng `.txt` chứa nội dung mô tả.
- Âm thanh: Đây cũng là thành phần tùy chọn. Hệ thống chấp nhận 01 tệp tin định dạng `.mp3` hoặc `.wav` với thời lượng từ 30 giây đến 2 phút. Trường hợp người dùng tải lên video, phần âm thanh sẽ được tự động tách xuất từ video đó.

Đặc tả dữ liệu đầu ra (OUTPUT): Nhãn chủ đề ICH được dự đoán bởi mô hình, kèm theo độ tin cậy.

Chi tiết các giai đoạn xử lý:

- **Giai đoạn 1 – Phân tách video:** Nếu người dùng có tải lên video đầu vào, hệ thống sẽ tiến hành phân tách, quá trình này thực hiện trích xuất chuỗi hình ảnh (tần suất 4 giây/khung hình) và các đoạn âm thanh (5 giây/đoạn) để chuẩn bị cho bước tiếp theo.
- **Giai đoạn 2 – Tiền xử lý và trích xuất đặc trưng:** Các dữ liệu thô ứng với mỗi phương thức sẽ có cách xử lý riêng biệt khác nhau, bao gồm:
  + Đặc trưng hình ảnh: Hệ thống tích hợp 6 kiến trúc CNN tiền huấn luyện (pretrained) trên tập dữ liệu ImageNet làm bộ trích xuất đặc trưng nền tảng (backbone). Người dùng có quyền lựa chọn một trong các mô hình: ResNet18, RegNetX400MF, MobileNetV3 Large, MobileNetV3 Small, DenseNet121 và ShuffleNetV2 1.0x. Hình ảnh đầu vào được tự động thay đổi kích thước (resize) và chuẩn hóa (normalize) tuân theo chuẩn của backbone được chọn.
  + Đặc trưng văn bản: Dữ liệu văn bản trải qua quy trình gán nhãn từ loại (POS Tagging) sử dụng thư viện *underthesea* chuyên dụng cho tiếng Việt. Sau đó, hệ thống tiến hành loại bỏ stopwords và chỉ giữ lại các từ mang nội dung chính thuộc các nhóm: danh từ (N), danh từ riêng (Np), động từ (V) và tính từ (A). Để biểu diễn ngữ nghĩa, hệ thống sử dụng mô hình all-MiniLM-L6-v2 nhằm chuyển đổi cặp (từ khóa, câu chứa từ khóa) thành vector embedding.
  + Đặc trưng âm thanh: Hệ thống áp dụng kỹ thuật trích xuất MFCC để nắm bắt đặc trưng về tần số của âm thanh. Để mô tả sự biến thiên của tín hiệu âm thanh theo thời gian (yếu tố quan trọng trong các lễ hội âm nhạc), hệ thống kết hợp thêm các đặc trưng động là Delta (đạo hàm bậc 1) và Delta-Delta (đạo hàm bậc 2).
- **Giai đoạn 3 – Xây dựng MG:** Các vector đặc trưng từ ba phương thức được chuyển đổi thành các đỉnh trong một đồ thị thống nhất. Về mặt cấu trúc, đây là đồ thị đa phương thức cấp đỉnh (Node-Level MG). Trong đó, các kết nối được thiết lập giữa tất cả các đỉnh, bao gồm các đỉnh cùng phương thức và các đỉnh khác phương thức (ví dụ: kết nối giữa 1 đỉnh hình ảnh và 1 đỉnh văn bản). Trọng số của các kết nối này là tham số học được, bằng việc huấn luyện các mô hình **Giai đoạn 4**, nhằm tìm ra cấu trúc tương quan tốt nhất.
- **Giai đoạn 4 – Suy luận phân tầng:** Đây là cơ chế ra quyết định được thiết kế nhằm tối ưu hóa việc sử dụng dữ liệu âm thanh. Hệ thống sử dụng song song hai mô hình MGAT + FastKAN/MLP gồm: mô hình được huấn luyện chỉ trên hai phương thức (hình ảnh và văn bản) và mô hình được huấn luyện trên cả ba phương thức (hình ảnh, văn bản và âm thanh).
  + Bước 4.1 – Dự đoán nhãn thô: Hệ thống tiến hành dùng 2 mô hình MGAT + FastKAN/MLP đã đề cập ở bên trên để dự đoán và cho ra 2 nhãn thô.

+ Bước 4.2 – Ra quyết định: Dựa trên nhãn thô, hệ thống tiến hành xét rằng liệu 1 trong số các nhãn dự đoán được có dùng âm thanh hay không, cụ thể như sau:
  - Trường hợp Có (Yes): Hệ thống sử dụng dữ liệu hình ảnh, văn bản cùng với âm thanh để đưa vào mô hình MGAT + FastKAN/MLP (ba phương thức) một lần nữa, nhằm dự đoán ra kết quả cuối cùng.
  - Trường hợp Không (No): Hệ thống sẽ ưu tiên nhãn thô có độ tin cậy cao hơn giữa 2 nhãn để cho ra kết quả cuối cùng.

1.1. Mô hình CNN baseline

Trước khi đi vào xây dựng mô hình MGAT + FastKAN/MLP, đề tài đề xuất xây dựng và huấn luyện một kiến trúc CNN cơ sở (baseline) chỉ sử dụng dữ liệu hình ảnh. Mục tiêu của bước này là tạo ra một mốc tham chiếu (benchmark) để đánh giá sự cải thiện của các phương pháp đa phương thức được đề ra ở phía sau.

Kiến trúc của mô hình CNN baseline được minh họa tại **Hình 8**, bao gồm các thành phần và cơ chế hoạt động như sau:

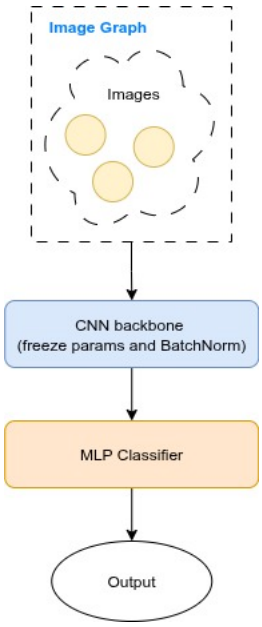

Hình 8. *Kiến trúc của mô hình CNN baseline*

Đầu vào (Image Graph): Là dữ liệu ảnh đã được tiền xử lý bằng cách dùng các transforms từ các CNN backbone tương ứng.

Đầu ra (Output): Kết quả dự đoán xác suất cho từng hình ảnh, sau đó tiền hành lấy trung bình cộng xác suất lại và cho ra kết quả phân lớp cuối cùng trên một mẫu đồ thị.

Quy trình xử lý:

– Trích xuất đặc trưng: Sáu kiến trúc CNN bao gồm ResNet18, RegNetX400MF, MobileNetV3 Large, MobileNetV3 Small, DenseNet121 và ShuffleNetV2 1.0x được sử dụng làm backbone trích xuất đặc trưng. Các mô hình này đều đã được huấn luyện trước trên tập dữ liệu ImageNet quy mô lớn. Điểm chính trong thiết kế CNN baseline nằm ở cơ chế đóng băng tham số (freezing), nhằm tận dụng các tri thức đã được học sẵn:

  + Freeze Parameters: Toàn bộ trọng số và bias của các lớp tích chập được giữ nguyên, không cập nhật trong quá trình lan truyền ngược. Điều này giúp bảo toàn khả năng nhận diện các đặc trưng cơ bản (cạnh, góc) mà mạng đã học được từ ImageNet.
  + Freeze BatchNorm: Các lớp Batch Normalization cũng được chuyển sang chế độ đánh giá (eval mode), nghĩa là chúng sử dụng các giá trị trung bình (mean) và phương sai (variance) toàn cục đã học trước đó thay vì tính toán lại trên từng batch dữ liệu huấn luyện mới. Điều này đảm bảo tính ổn định của đặc trưng đầu ra.

– Bộ phân lớp (MLP Classifier): Các đặc trưng sau khi đi qua backbone sẽ được đưa vào một mạng MLP. Đây là thành phần duy nhất có thể học được. Nhiệm vụ của MLP là học cách ánh xạ từ không gian đặc trưng của ImageNet sang không gian nhãn của ICH.

1.2. Mô hình MGAT + FastKAN/MLP

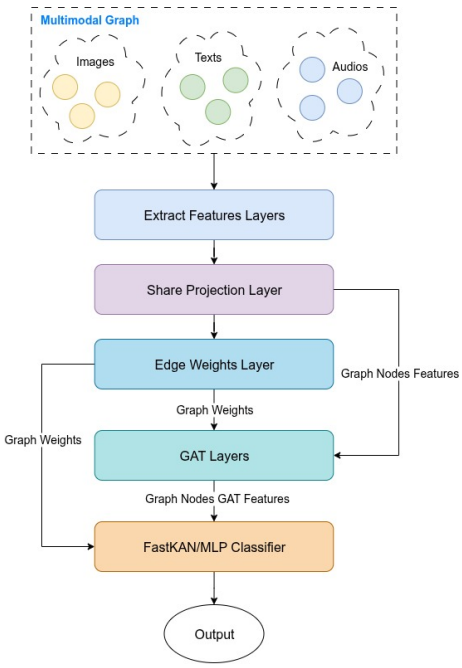

Hình 9. *Kiến trúc tổng quát của mô hình CNN backbone + MGAT + FastKAN/MLP*

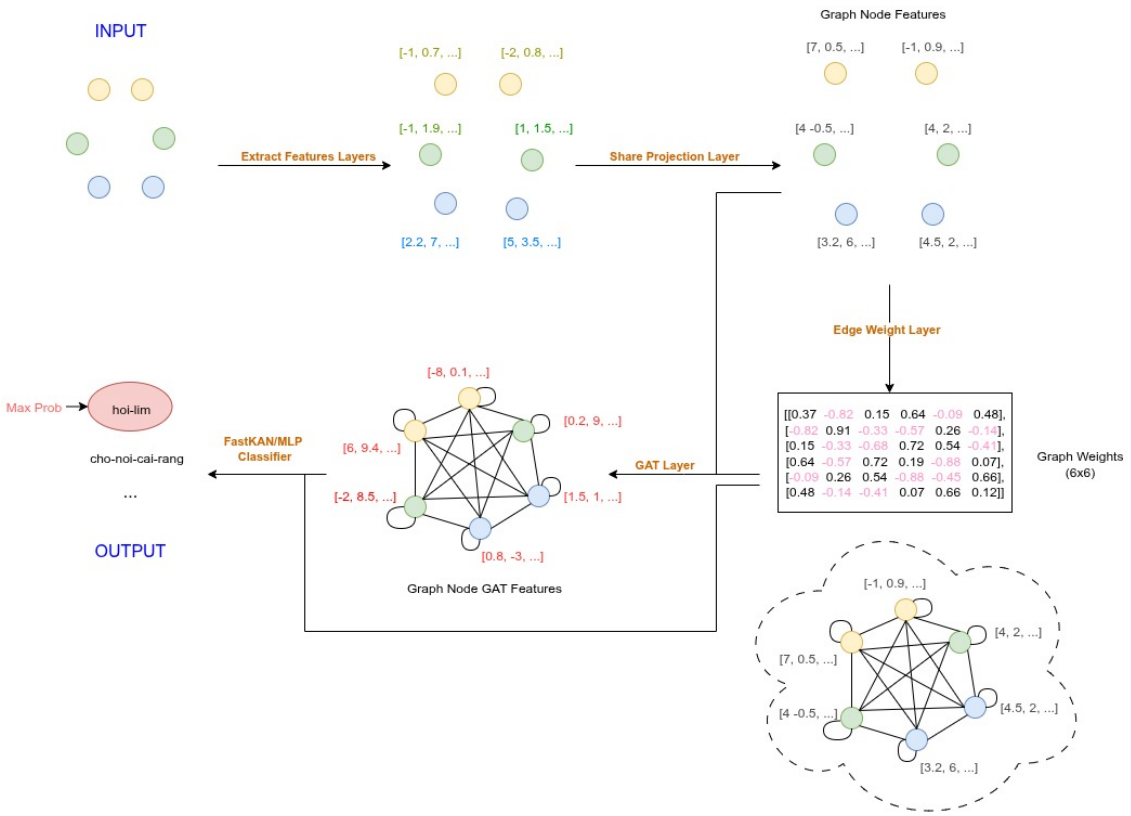

Hình 10. *Ví dụ về cách xây dựng đồ thị và dự đoán nhãn khi dùng mô hình CNN backbone + MGAT + FastKAN/MLP*

Kiến trúc của mô hình gồm 5 tầng, được mô tả tổng quát trong **Hình 9** và được minh hoạ cụ thể qua **Hình 10**. Mỗi tầng đảm nhận một vai trò riêng trong toàn bộ pipeline, cụ thể như sau:

- **Extract Features Layers:** Tầng này có nhiệm vụ trích xuất đặc trưng riêng cho từng loại phương thức dữ liệu. Như minh hoạ trong **Hình 10**, khi đồ thị ban đầu đi qua tầng này, các nút sẽ được ánh xạ sang những không gian đặc trưng khác nhau tuỳ theo phương thức của chúng (nút màu vàng biểu diễn hình ảnh, nút màu xanh lá biểu diễn văn bản, và nút màu xanh dương biểu diễn âm thanh).
- **Share Projection Layer:** Tầng này thực hiện phép chiếu các đặc trưng từ những không gian phương thức khác nhau về một không gian biểu diễn chung, nhằm đảm bảo các nút được biểu diễn một cách thống nhất và có thể so sánh trực tiếp với nhau.
- **Edge Weight Layer**: Dựa trên các vector biểu diễn của nút do Share Projection Layer sinh ra, tầng này học và tính toán trọng số cho các cạnh trong đồ thị. Trọng số cạnh là một giá trị nằm trong đoạn $[-1, 1]$, phản ánh mức độ quan hệ giữa các nút, trong đó trọng số dương biểu thị mối quan hệ "bạn bè", còn trọng số âm biểu thị mối quan hệ "đối kháng".

– **GAT Layers**: Tầng này áp dụng GAT để tổng hợp và cập nhật biểu diễn mới cho mỗi nút dựa trên thông tin từ các nút hàng xóm. Trong quá trình này, mô hình chỉ xét các hàng xóm có trọng số cạnh dương (nhóm "bạn bè"), vì đây là những nút cung cấp thông tin bổ trợ hữu ích cho nút đang xét.

– **FastKAN/MLP Classifier**: Tầng này sử dụng các vector đã được cập nhật từ GAT Layer để thực hiện phân lớp. Đầu tiên, mô hình tiến hành dự đoán trên từng nút và sau đó tổng hợp kết quả bằng cách lấy trung bình có trọng số, trong đó trọng số được xác định bởi Graph Weight từ Edge Weight Layer. Phương pháp này giúp tăng tính linh hoạt của mô hình, cho phép mỗi nút đóng góp khác nhau vào kết quả dự đoán cuối cùng.

1.2.1. Extract Features Layers (Tầng trích xuất đặc trưng)

Đây là tầng nhận dữ liệu đồ thị từ ba phương thức khác nhau. Kiến trúc của tầng này được minh họa tại **Hình 11**, bao gồm ba nhánh xử lý độc lập:

– Extract Image Features Layer: Sử dụng backbone CNN đã được đóng băng tham số và BatchNorm để trích xuất đặc trưng hình ảnh. Đầu ra từ backbone được đưa qua một tầng Linear để chiếu về chiều không gian vector mong muốn (448 chiều).

– Extract Text Features Layer: Kết hợp vector embedding của từ (Word) và câu (Sentence).

– Extract Audio Features Layer: Xử lý đặc trưng MFCC kết hợp với các giá trị Delta và Delta-Delta.

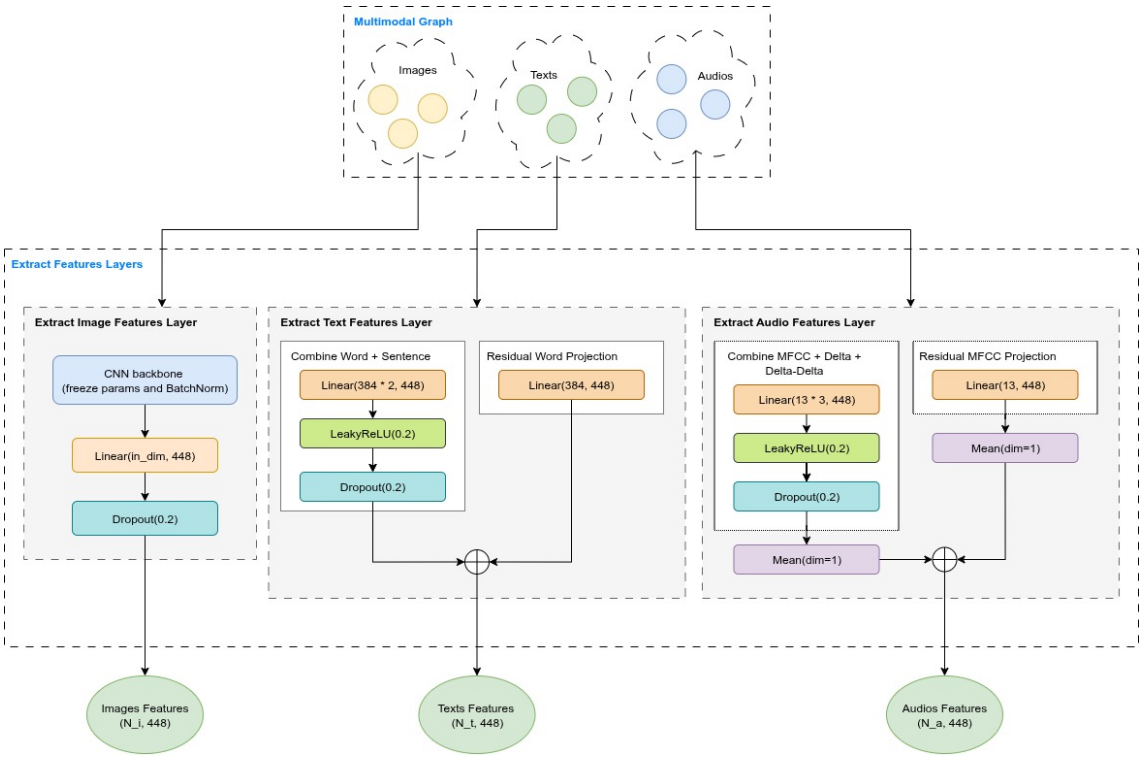

Hình 11. *Kiến trúc chi tiết của Extract Features Layers*

Đối với nhánh đặc trưng hình ảnh, do backbone đã cung cấp các vector đặc trưng giàu thông tin ngữ nghĩa, mô hình chỉ áp dụng phép chiếu tuyến tính đơn giản. Ngược lại, đối với văn bản và âm thanh, mô hình áp dụng cơ chế Residual Connection bằng cách cộng vector đặc trưng gốc (đã được chiếu về cùng chiều) vào đầu ra cuối cùng của nhánh. Kỹ thuật này giúp giải quyết vấn đề biến mất đạo hàm khi huấn luyện mạng sâu, đồng thời bảo toàn thông tin gốc quan trọng trước các phép biến đổi phi tuyến có thể gây mất mát thông tin đặc trưng [8].

1.2.2. Share Projection Layer (Tầng chiếu không gian chung)

Mục tiêu của tầng này là đồng bộ hóa các vector đặc trưng từ ba phương thức khác nhau về cùng một không gian biểu diễn có số chiều cố định (512 chiều), với kiến trúc chi tiết tại **Hình 12**.

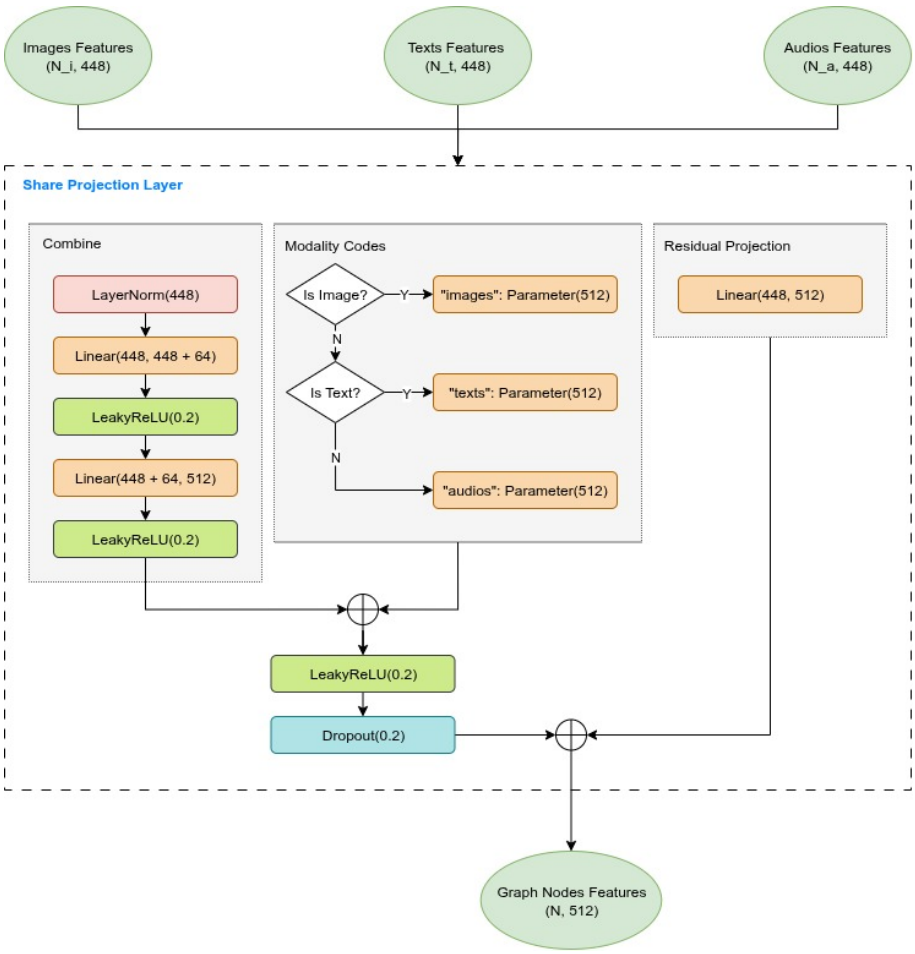

Hình 12. *Kiến trúc của Share Projection Layer*

Để phân biệt được phương thức của từng vector đặc trưng trong không gian chung, mô hình sử dụng kỹ thuật Modality Embeddings (hay Modality Codes). Mỗi phương thức được gán một vector tham số học được riêng biệt, cộng trực tiếp vào đặc trưng đầu ra nhằm "đánh dấu" vị trí của nó trong không gian vector chung. Kỹ thuật này được lấy cảm hứng từ cơ chế Token Type Embeddings trong mô hình BERT, giúp mô hình nhận biết ngữ cảnh phương thức [3]. Đồng thời, cơ

chế Residual Connection tiếp tục được áp dụng tại đây nhằm duy trì luồng thông tin xuyên suốt, tránh sự mất mát dữ liệu do các phép biến đổi của tầng Linear.

1.2.3. Edge Weight Layer (Tầng học trọng số cạnh)

Tầng này đóng vai trò khởi tạo cấu trúc đồ thị bằng cách xác định độ mạnh yếu của các liên kết giữa các đỉnh, như minh họa tại **Hình 13**.

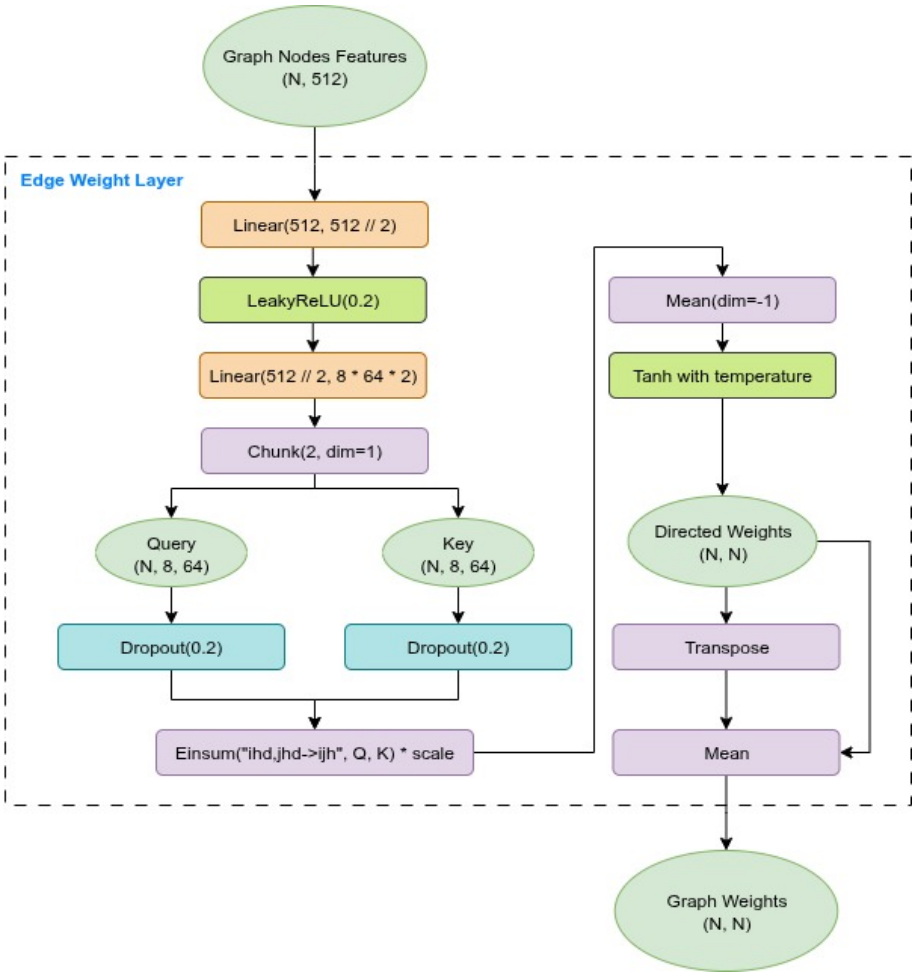

Hình 13. *Kiến trúc của Edge Weights Layer sử dụng cơ chế Attention*

Mạng học trọng số cạnh được xây dựng dựa trên cơ chế *self-attention*, trong đó tích vô hướng $Q \cdot K^T$ được sử dụng để thể hiện tính tương quan ngữ nghĩa giữa các nút [16]. Đầu ra của tầng này sử dụng hàm kích hoạt `Tanh` nhằm giới hạn giá trị trọng số cạnh trong khoảng $[-1, 1]$, điều này cho phép mô hình biểu diễn hai loại quan hệ đối lập: quan hệ "bạn bè" với trọng số cạnh dương (tiệm cận 1) và quan hệ "đối kháng" với trọng số cạnh âm (tiệm cận -1).

Việc cho phép tồn tại trọng số cạnh âm ở giai đoạn này đóng vai trò như một cơ chế lọc mềm. Với các giá trị trọng số âm sẽ được loại bỏ ở các tầng tiếp theo thông qua hàm `Clamp(min=0)`, nhờ đó mô hình có khả năng chủ động học cách loại bỏ các kết nối nhiễu hoặc không mang thông tin hữu ích. Phương pháp này linh hoạt hơn so với việc sử dụng hàm kích hoạt `Sigmoid`, vốn chỉ sinh ra các trọng số không

âm trong khoảng $(0, 1)$, điều này buộc mô hình phải duy trì tất cả các cạnh với mức độ ảnh hưởng khác nhau, kể cả những kết nối kém liên quan (có trọng số dương rất nhỏ, tiệm cận 0).

Ngoài ra, để đảm bảo tính vô hướng của đồ thị, chỉ cần lấy ma trận trọng số cạnh tính được đem trung bình cộng với ma trận chuyển vị của chính nó. Cách xử lý này đảm bảo rằng trọng số liên kết giữa hai nút là nhất quán theo cả hai chiều, tức trọng số từ nút A đến nút B bằng với trọng số từ B đến A.

1.2.4. GAT Layers (Tầng GAT)

Đây là thành phần cốt lõi thực hiện quá trình truyền tin (Message Passing) để cập nhật đặc trưng nút, với kiến trúc được minh hoạ như **Hình 14**.

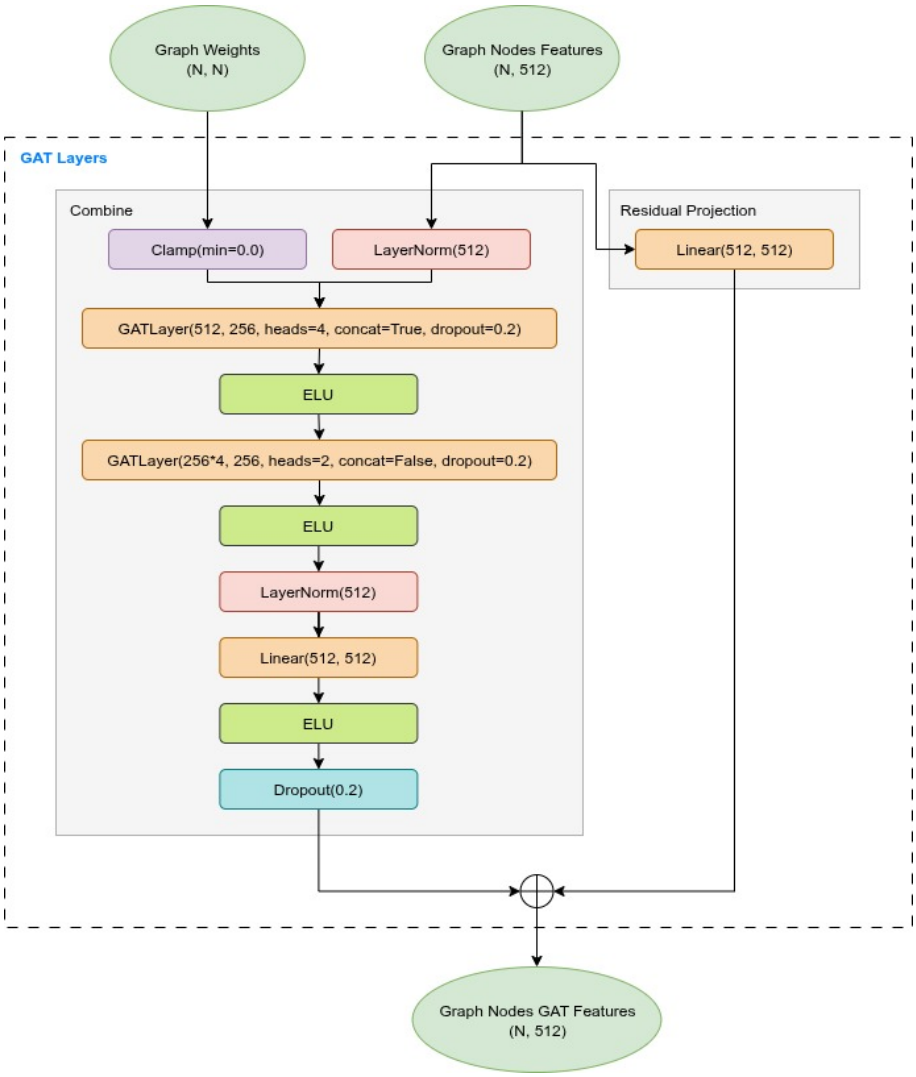

Hình 14. *Kiến trúc của GAT Layers với cơ chế Weighted Message Passing*

Mô hình áp dụng biến thể Weighted GAT kết hợp với Dynamic Attention. Khác với GAT truyền thống chỉ dựa vào đặc trưng nút và ma trận kề để tính hệ số attention, thì mô hình trong đề tài này tích hợp trực tiếp trọng số cạnh học được (GW_{ij})

vào quá trình tính toán, với công thức cụ thể như sau:

$$\alpha_{ij} = \text{softmax}(\text{LeakyReLU}(\vec{a}^T[W\vec{h}_i \| W\vec{h}_j]) \cdot GW_{ij})$$

Trong đó GW_{ij} là ma trận trọng số cạnh của đồ thị từ tầng trước đã qua hàm `Clamp(min=0.0)` để loại bỏ giá trị âm. Cơ chế này giúp khắc phục hạn chế "Static Attention", cho phép mô hình kiểm soát luồng thông tin linh hoạt hơn: các cạnh có trọng số lớn sẽ khuếch đại tín hiệu, ngược lại các cạnh yếu sẽ bị chặn lại. Hàm kích hoạt phi tuyến ELU (Exponential Linear Unit) được sử dụng sau mỗi lớp GAT nhằm hỗ trợ việc học các biểu diễn của vector tốt hơn và tăng tốc độ hội tụ so với ReLU thông thường [1].

Ngoài ra, tầng này cũng được áp dụng thêm kỹ thuật Pre-LayerNorm (chuẩn hóa trước khi đưa vào layer) để ổn định gradient khi huấn luyện mô hình sâu, tránh hiện tượng bùng nổ hoặc biến mất gradient thường gặp trong các mạng GNN nhiều lớp [19]. Tương tự các tầng trước, cơ chế Residual Connection vẫn được duy trì để bảo toàn thông tin gốc qua các phép biến đổi phức tạp.

1.2.5. FastKAN/MLP Classifier (Bộ phân lớp)

Tầng cuối cùng thực hiện ánh xạ từ không gian đặc trưng đồ thị sang không gian nhãn xác suất, sử dụng FastKAN hoặc MLP như minh họa tại **Hình 15**.

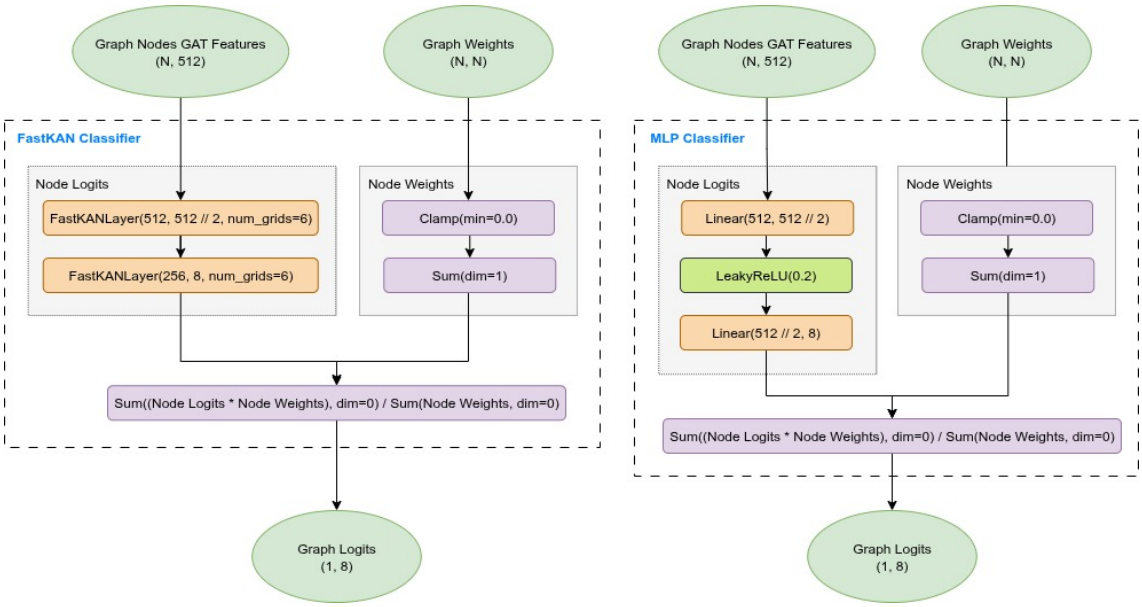

Hình 15. *Kiến trúc bộ phân lớp bằng FastKAN và MLP*

Thay vì sử dụng kỹ thuật Global Mean Pooling thông thường (coi vai trò các nút là như nhau), mô hình áp dụng cơ chế Weighted Pooling (trung bình có trọng số). Kết quả dự đoán cuối cùng là trung bình có trọng số của các dự đoán từ từng nút ($logits_i$), với trọng số của mỗi nút được tính dựa trên tổng trọng số cạnh dương

($d_i = \sum_j w_{ij}$) của nút đó, với công thức cụ thể như sau:

$$y_{pred} = \frac{\sum_i (logits_i \cdot d_i)}{\sum_i d_i + \varepsilon}$$

Trong đó ε là hằng số nhỏ để tránh lỗi chia cho 0. Cơ chế này phù hợp với lý thuyết về Graph Readout Operations, khẳng định rằng việc tổng hợp thông tin dựa trên cấu trúc giúp mô hình ưu tiên các nút giàu thông tin và giảm thiểu tác động của các nút ngoại lai lên kết quả dự đoán cuối cùng [20].

2. Cài đặt giải pháp

2.1. Thu thập dữ liệu

Tập dữ liệu được thu thập bao gồm 8 lớp, gồm: *cho-noi-cai-rang* (Chợ nổi Cái Răng), *dua-bo-bay-nui* (Đua bò Bảy Núi), *le-hoi-nghinh-ong* (Lễ hội Nghinh Ông), *hoi-lim* (Hội Lim), *nghe-dan-tre* (Nghề đan tre), *nghe-det-chieu* (Nghề dệt chiếu), *ok-om-bok* (Ok Om Bok) và *via-ba-chua-xu-nui-sam* (Vía Bà Chúa Xứ Núi Sam).

Dữ liệu được thu thập thông qua thư viện *yt_dlp*, cho phép tải cả video lẫn phụ đề (nếu có) trực tiếp từ YouTube. Mỗi video có thời lượng dao động từ 5 phút đến 1 giờ 45 phút. Bên dưới là hình minh hoạ về số lượng video thu thập được, tuy không cùng số lượng nhưng thời lượng trên mỗi lớp được đảm bảo là gần nhau để cân bằng số lượng mẫu giữa các lớp.

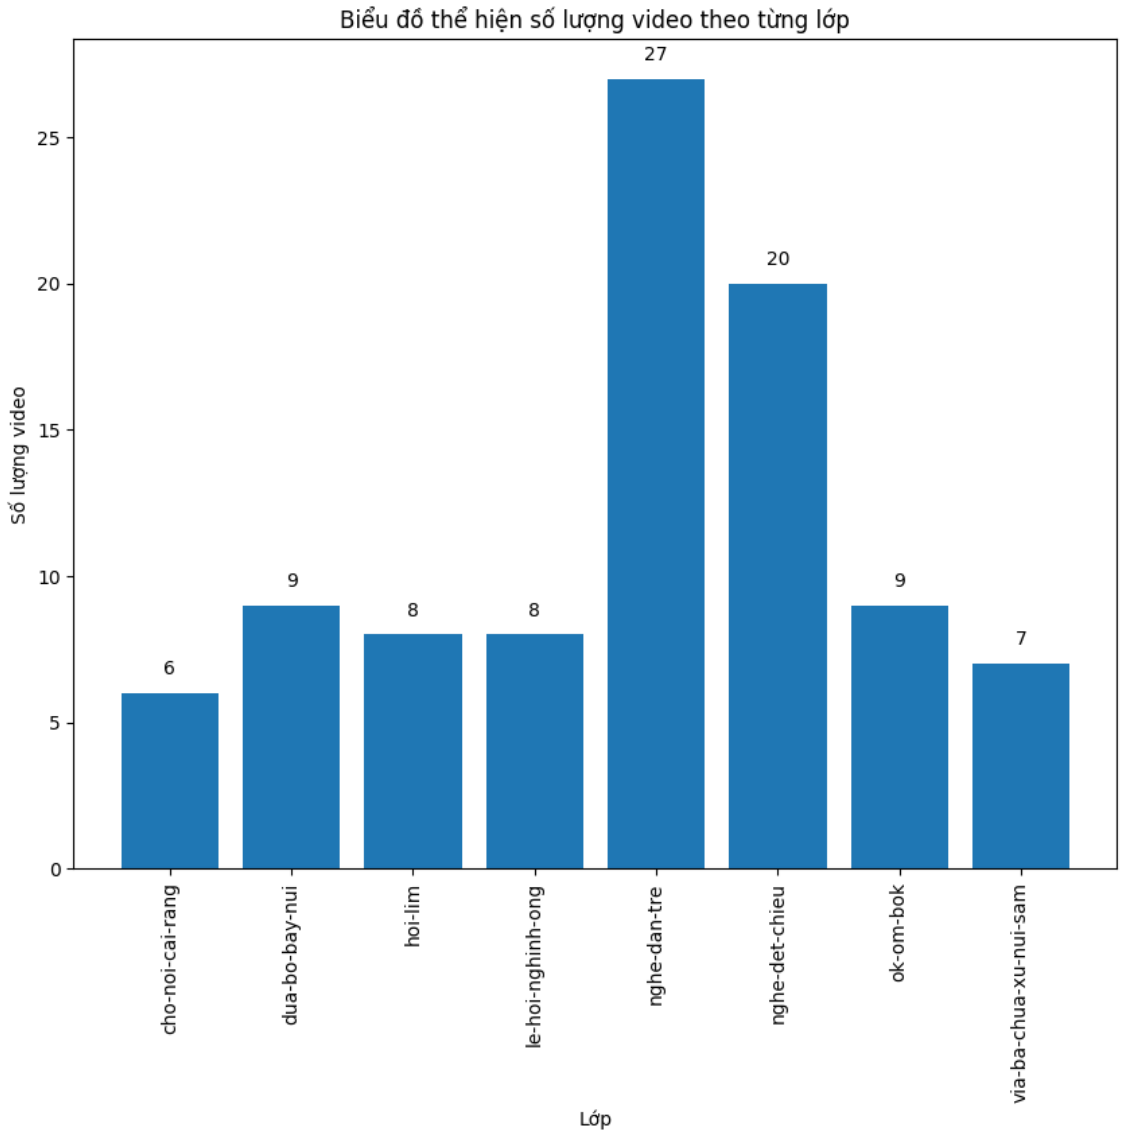

Hình 16. *Số lượng video theo từng lớp*

2.2. Tiền xử lý dữ liệu

Quy trình tiền xử lý dữ liệu đóng vai trò then chốt trong việc chuẩn hóa đầu vào cho mô hình đa phương thức. Quy trình này được thực hiện tuần tự qua 5 bước chính như sau:

- **Bước 1 – Phân đoạn video và phụ đề:** Chia tách video gốc thành các mẫu dữ liệu (video clip) có độ dài cố định, đồng thời trích xuất phụ đề tương ứng.
- **Bước 2 – Trích xuất hình ảnh và âm thanh:** Tách video clip thành chuỗi hình ảnh (frames) và các đoạn âm thanh (audio segments) theo tần số lấy mẫu quy định.
- **Bước 3 – Chuẩn hóa phụ đề:** Sử dụng các mô hình ngôn ngữ lớn (LLM) để hiệu chỉnh và làm sạch dữ liệu phụ đề.
- **Bước 4 – Tiền tính toán:** Trích xuất trước các đặc trưng văn bản và âm thanh, chuyển đổi sang định dạng vector/ma trận lưu trữ sẵn nhằm giảm tải chi phí tính toán trong quá trình huấn luyện.
- **Bước 5 – Phân chia tập dữ liệu:** Chia tách dữ liệu thành các tập Train, Val và Test.

2.2.1. Phân đoạn video và phụ đề

Từ nguồn dữ liệu thô ban đầu, thư viện *ffmpeg* được sử dụng để phân đoạn các video gốc thành các video clip nhỏ, mỗi clip có thời lượng chuẩn là 1 phút. Đây được coi là một mẫu dữ liệu (sample) đầu vào.

Đối với việc xử lý phụ đề (định dạng `.srt` tải từ thư viện *yt-dlp*), thách thức lớn nhất là sự không đồng bộ giữa mốc thời gian của phụ đề và thời điểm cắt video. Để khắc phục vấn đề này, quá trình cắt không được thực hiện theo cách ràng buộc cứng nhắc theo timestamp, mà thay vào đó áp dụng cơ chế cửa sổ chồng lấn (overlapping window). Nếu thời điểm bắt đầu hoặc kết thúc của một dòng phụ đề nằm trong khoảng thời gian của video clip, toàn bộ nội dung dòng phụ đề sẽ được giữ lại. Điều này đảm bảo ngữ nghĩa của câu nói không bị ngắt quãng, dù chấp nhận việc phụ đề có thể lấn sang khung thời gian trước hoặc sau video một khoảng nhất định.

Sau quá trình cắt, bước lọc thủ công được tiến hành tiếp tục nhằm nâng cao chất lượng dữ liệu. Các video clip có thời lượng ngắn hơn 1 phút hoặc chứa nội dung nhiễu, không phù hợp với chủ đề của tập dữ liệu, sẽ bị loại bỏ trước khi đưa vào các giai đoạn xử lý và phân tích tiếp theo.

2.2.2. Trích xuất hình ảnh và âm thanh

Tại bước này, mỗi mẫu dữ liệu (video clip 1 phút) sẽ được tách thành hai thành phần phương thức riêng biệt sử dụng *ffmpeg*:

- Đối với hình ảnh: Thực hiện lấy mẫu (sampling) với chu kỳ 4 giây/khung hình. Như vậy, mỗi mẫu dữ liệu sẽ cung cấp một danh sách gồm 15 hình ảnh.
- Đối với âm thanh: Cũng thực hiện lấy mẫu với chu kỳ 5 giây/đoạn. Tương ứng mỗi mẫu dữ liệu sẽ cung cấp 12 đoạn âm thanh.

2.2.3. Chuẩn hóa phụ đề

Các đoạn phụ đề sau khi cắt sẽ được chuyển đổi sang định dạng văn bản thuần (`.txt`). Do đặc thù là văn bản nói và được tạo tự động, dữ liệu này thường chứa lỗi ngữ pháp, từ ngữ địa phương hoặc sai sót do nhận dạng âm thanh.

Để nâng cao chất lượng dữ liệu văn bản, đề tài đề xuất sử dụng các LLM như GPT-5.0, GPT-4o hoặc Gemini 2.5 Pro để thực hiện tác vụ làm mượt. Các mô hình này hỗ trợ hiệu chỉnh ngữ pháp, tái cấu trúc câu từ cho mạch lạc mà vẫn giữ nguyên ý nghĩa gốc. Sau đó, cần phải tiến hành rà soát thủ công lần cuối để loại bỏ các mẫu không đạt yêu cầu.

Kết quả của quá trình này là một tập dữ liệu đa phương thức đã được chuẩn hóa. Mỗi mẫu dữ liệu bao gồm: 15 hình ảnh, 1 file văn bản và 12 đoạn âm thanh. Do dữ liệu được trích xuất từ video nên hình ảnh là loại dữ liệu bắt buộc. Đối với văn bản, dữ liệu này nằm rải rác ở các mẫu vì không phải video nào cũng có phụ đề. Riêng đối với âm thanh, đề tài chỉ giữ lại đặc trưng ở 4 lớp dữ liệu có tính chất lễ hội âm nhạc đặc thù là: *hoi-lim*, *le-hoi-nghinh-ong*, *ok-om-bok* và *via-ba-chua-xu-nui-sam*. Ở 4 lớp còn lại, do đặc trưng âm thanh không mang nhiều thông tin quan trọng nên cần loại bỏ chúng để tối ưu hóa mô hình.

2.2.4. Tiền tính toán dữ liệu văn bản và âm thanh

Việc tính toán trước đặc trưng là bước quan trọng để tối ưu hóa thời gian huấn luyện, tuy nhiên chiến lược này được áp dụng linh hoạt tùy theo loại dữ liệu:

- Đối với dữ liệu hình ảnh: Đề tài quyết định không lưu trữ các đặc trưng đã tính toán trước vì chúng chiếm dung lượng lưu trữ rất lớn. Thay vào đó, các bước thay đổi kích thước (resize) và chuẩn hóa (normalize) sẽ được thực hiện trực tiếp trong quá trình huấn luyện. Cách tiếp cận này không chỉ tiết kiệm tài nguyên đĩa cứng mà còn tạo điều kiện thuận lợi cho việc thay đổi các mô hình CNN backbone trong kiến trúc.
- Đối với dữ liệu văn bản: Thực hiện tính toán và lưu trữ đặc trưng vào các file tensor (`.pt`) để tránh lặp lại các thao tác xử lý ngôn ngữ tự nhiên tốn thời gian. Quy trình cụ thể bao gồm:
  + Sử dụng thư viện *underthesea* để tách câu và gán nhãn từ loại (POS Tagging).
  + Loại bỏ stopwords và giữ lại các từ khóa quan trọng thuộc nhóm: danh từ (N), danh từ riêng (Np), động từ (V) và tính từ (A) như đã đề ra trước đó.
  + Sử dụng mô hình all-MiniLM-L6-v2 để tính toán vector embedding cho cả từ đơn lẻ và câu chứa từ đó (ngữ cảnh).
- Đối với dữ liệu âm thanh: Sử dụng thư viện *librosa* để trích xuất trước các đặc trưng quan trọng bao gồm MFCC, Delta và Delta-Delta. Để đảm bảo tính nhất quán về mặt cấu trúc dữ liệu đầu vào cho mô hình, các mẫu âm thanh trong cùng một đồ thị sẽ được xử lý để có cùng chiều thời gian (thông qua kỹ thuật padding). Các ma trận đặc trưng sau đó được nén và lưu trữ dưới định dạng `.npz` của thư viện *numpy*, giúp truy xuất nhanh chóng trong quá trình huấn luyện.

2.2.5. Phân chia tập dữ liệu

Sau quá trình tiền xử lý, đề tài thu được một tập dữ liệu cân bằng gồm 8 lớp, với 300 mẫu dữ liệu cho mỗi lớp. Kế đến, tiến hành phân chia dữ liệu theo tỷ lệ 70:15:15 tương ứng cho các tập Train, Val và Test. Với chi tiết phân bố số lượng mẫu được trình bày trong **Bảng 1**.

Bảng 1. *Phân bố số lượng mẫu dữ liệu cho từng tập*

Tập dữ liệu	Tỷ lệ (%)	SL mẫu/lớp	Tổng SL mẫu	Tổng SL ảnh	Tổng SL từ	Tổng SL âm thanh
Train	70%	210	1 680	25 200	35 646	20 160
Val	15%	45	360	5 400	7 499	4 320
Test	15%	45	360	5 400	8 260	4 320
Tổng cộng	**100%**	**300**	**2 400**	**36 000**	**51 405**	**28 800**

Ngoài ra, để làm rõ quy mô của dữ liệu đa phương thức được sử dụng, các biểu đồ thống kê số lượng thành phần hình ảnh, văn bản và âm thanh trong từng tập Train, Val và Test được trình bày ở phần dưới.

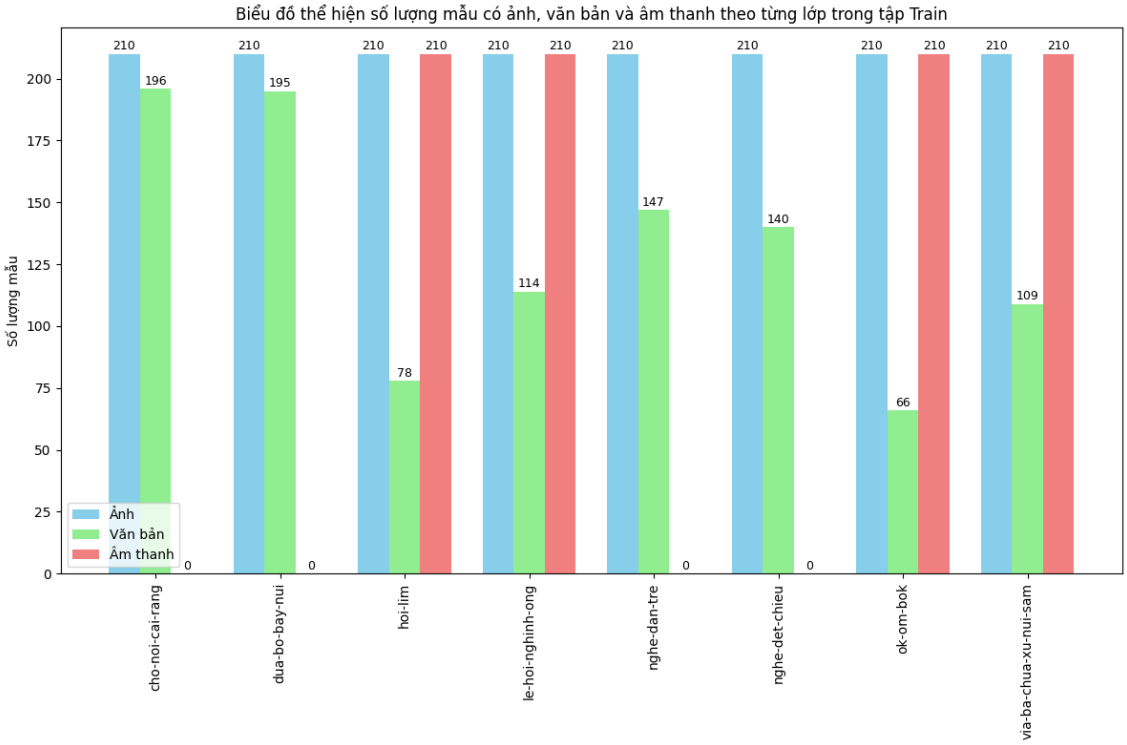

Hình 17. *Biểu đồ thể hiện số lượng mẫu có ảnh, văn bản và âm thanh theo từng lớp trong tập Train*

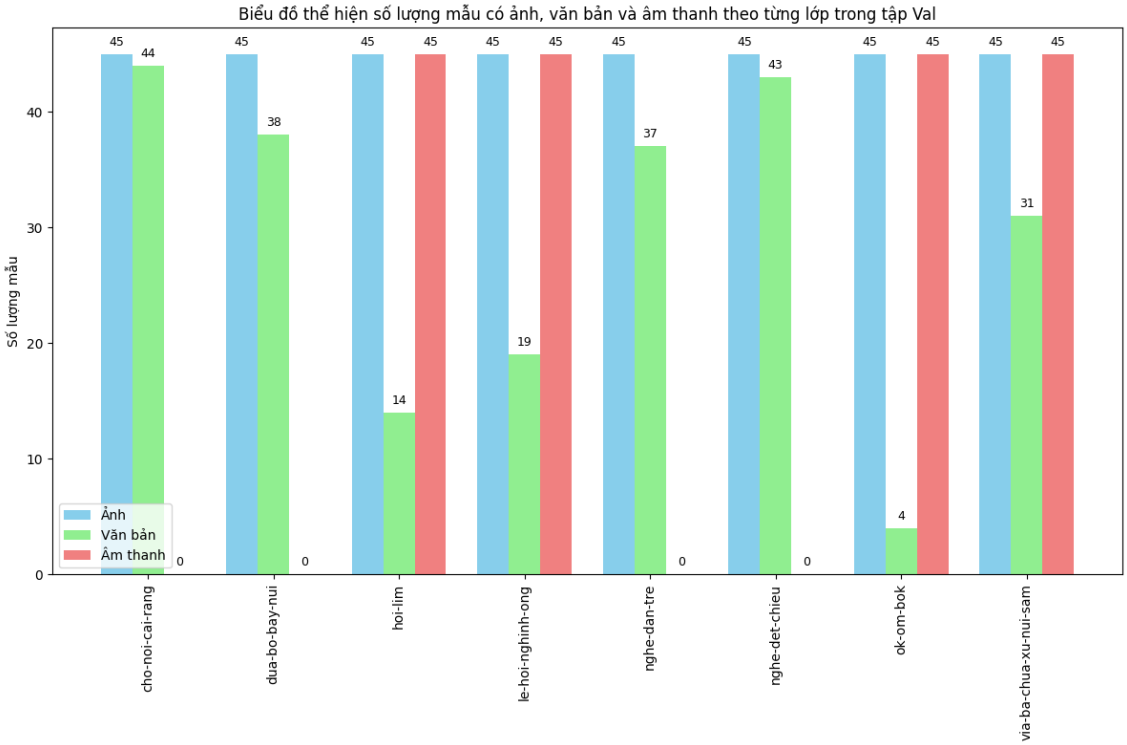

Hình 18. *Biểu đồ thể hiện số lượng mẫu có ảnh, văn bản và âm thanh theo từng lớp trong tập Val*

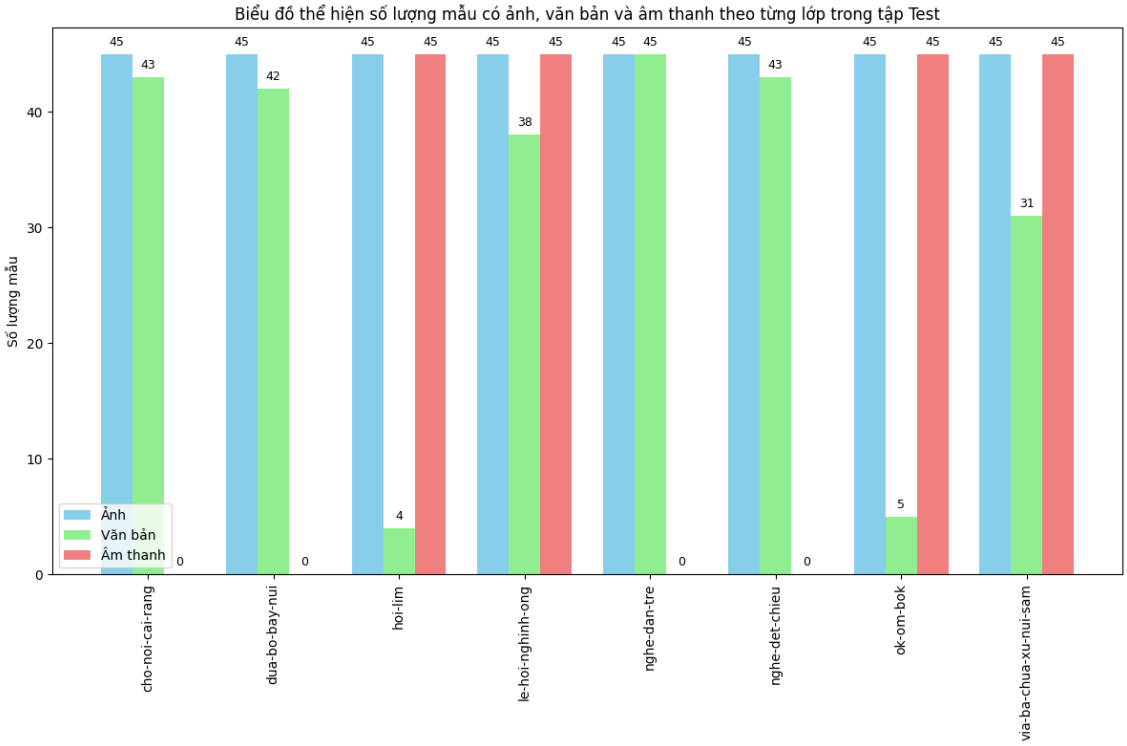

Hình 19. *Biểu đồ thể hiện số lượng mẫu có ảnh, văn bản và âm thanh theo từng lớp trong tập Test*

CHƯƠNG 3. KIỂM THỬ VÀ ĐÁNH GIÁ

1. Giao diện sản phẩm

Trang chủ: Ứng dụng ICH Predictor được thiết kế tích hợp toàn bộ quy trình xử lý trên một trang duy nhất. Giao diện chính được minh hoạ tại **Hình 20** và **Hình 21**, bao gồm các nhóm chức năng chính: Quản lý tệp tin (Thêm tệp/Hoàn tất), Chọn mô hình và tiến hành dự đoán. Hệ thống hỗ trợ linh hoạt ba kịch bản dự đoán: đơn phương thức (chỉ ảnh), đa phương thức chỉ dùng hình ảnh và văn bản và đa phương thức toàn diện. Tương ứng với mỗi kịch bản, người dùng có thể lựa chọn các phiên bản mô hình đã được huấn luyện.

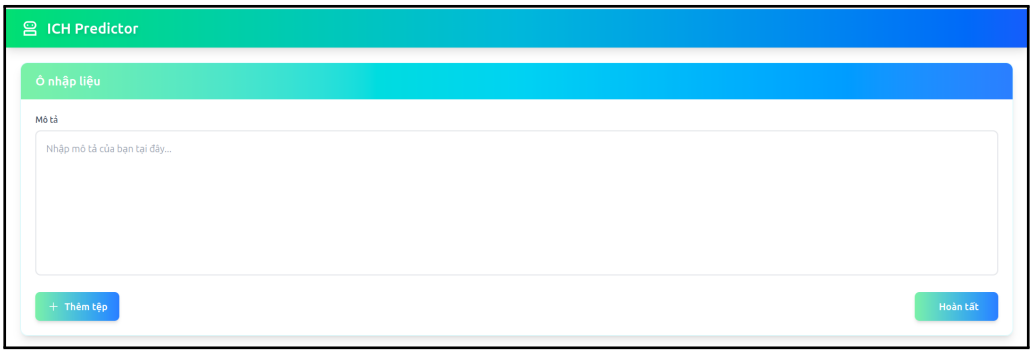

Hình 20. *Giao diện trang chủ – Khu vực nhập liệu, thêm và hoàn tất tải tệp lên*

Hình 21. *Giao diện trang chủ – Khu vực hiển thị kết quả*

Quản lý tệp tin: Khi người dùng tương tác với chức năng "Thêm tệp", hệ thống hiển thị một cửa sổ cho phép tải lên dữ liệu. Tại đây, các tệp tin được kiểm tra tự động để đảm bảo tuân thủ các ràng buộc về định dạng và kích thước đã đề ra.

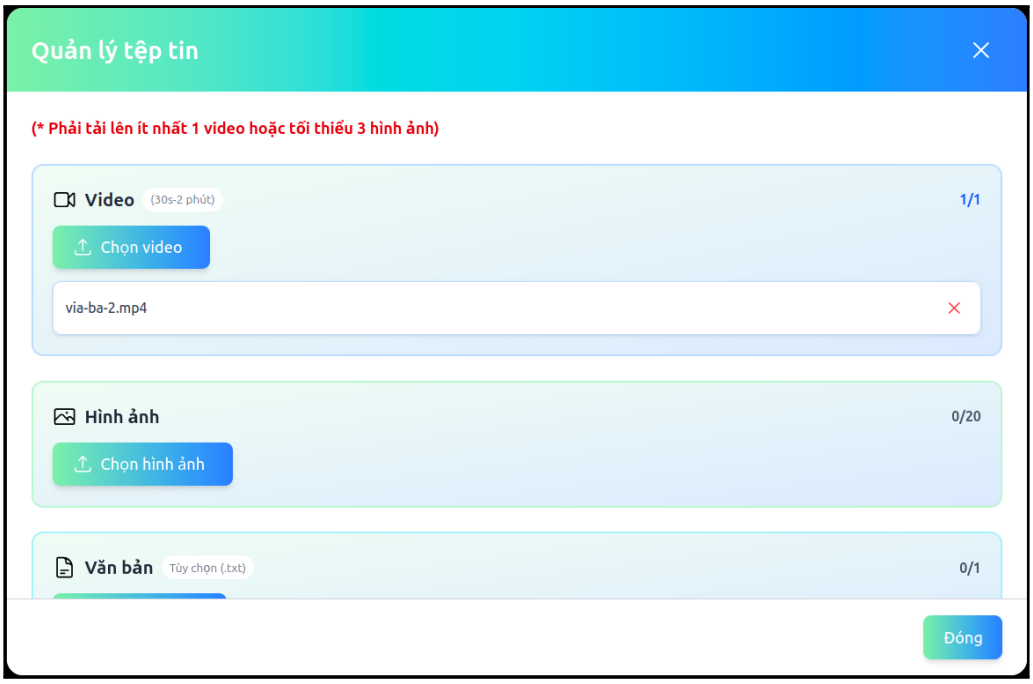

Hình 22. *Giao diện modal cho phép thêm tệp tin đa phương thức*

Hoàn tất tải lên: Sau khi lựa chọn dữ liệu, người dùng xác nhận bằng nút "Hoàn tất". Lúc này, dữ liệu và nội dung mô tả được đẩy lên máy chủ để kích hoạt quy trình tiền xử lý (bao gồm phân tách video và trích xuất đặc trưng sơ bộ). Cơ chế này giúp tối ưu hóa thời gian phản hồi khi thực hiện lệnh dự đoán sau đó. Hình minh họa dưới đây thể hiện trạng thái khi dữ liệu đã được đồng bộ thành công lên máy chủ.

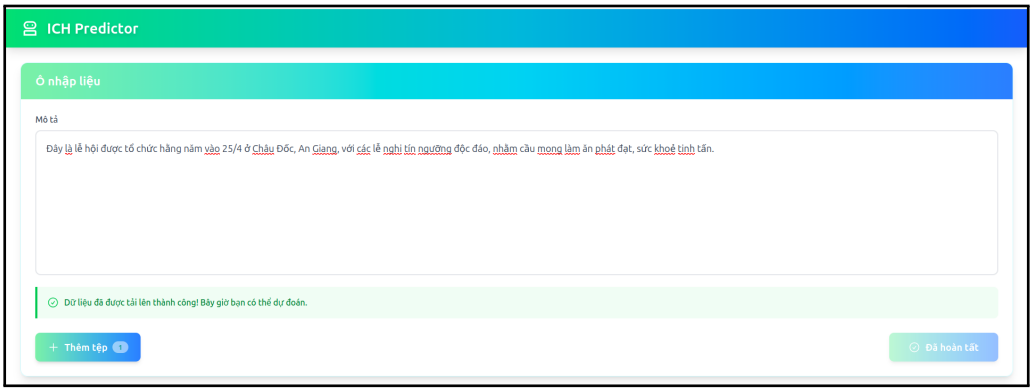

Hình 23. *Giao diện hiển thị trạng thái tải tệp và nội dung mô tả thành công*

Kết quả dự đoán: Người dùng lựa chọn kiến trúc mô hình mong muốn (ví dụ: MobileNetV3 Small) và kích hoạt quá trình dự đoán. Hệ thống sẽ trả về kết quả bao gồm nhãn chủ đề văn hóa dự đoán và chỉ số độ tin cậy tương ứng.

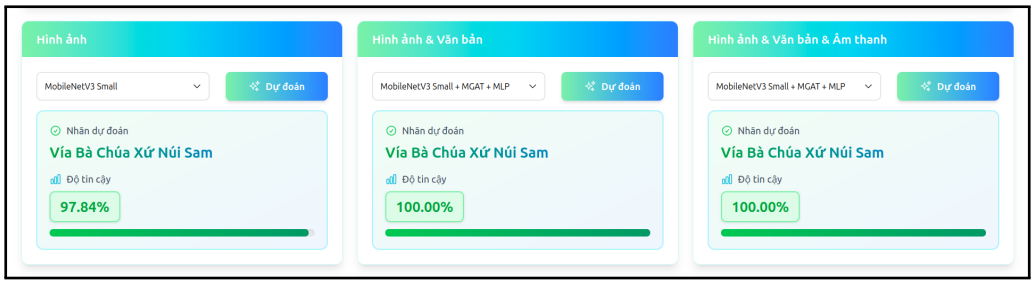

Hình 24. *Giao diện hiển thị kết quả dự đoán với mô hình backbone MobileNetV3 Small*

Đồ thị: Đối với các kịch bản dự đoán đa phương thức, khu vực kết quả cung cấp thêm công cụ trực quan hóa cấu trúc đồ thị. Giao diện này cho phép người dùng xem xét danh sách các nút (đỉnh) tham gia vào quá trình suy luận và hiển thị trực quan các kết nối giữa chúng.

Hình 25. *Giao diện công cụ trực quan hóa đồ thị cho mô hình MGAT + FastKAN/MLP*

Danh sách nút hình ảnh: Khi bấm vào nút "Danh sách nút", người dùng có thể tùy chọn các nút hình ảnh cụ thể để hiển thị. Đồng thời, hệ thống cung cấp các bộ lọc để lọc các cạnh kết nối dựa trên ngưỡng trọng số (hiển thị top % các cạnh có trọng số cao nhất), giúp giảm nhiễu khi quan sát.

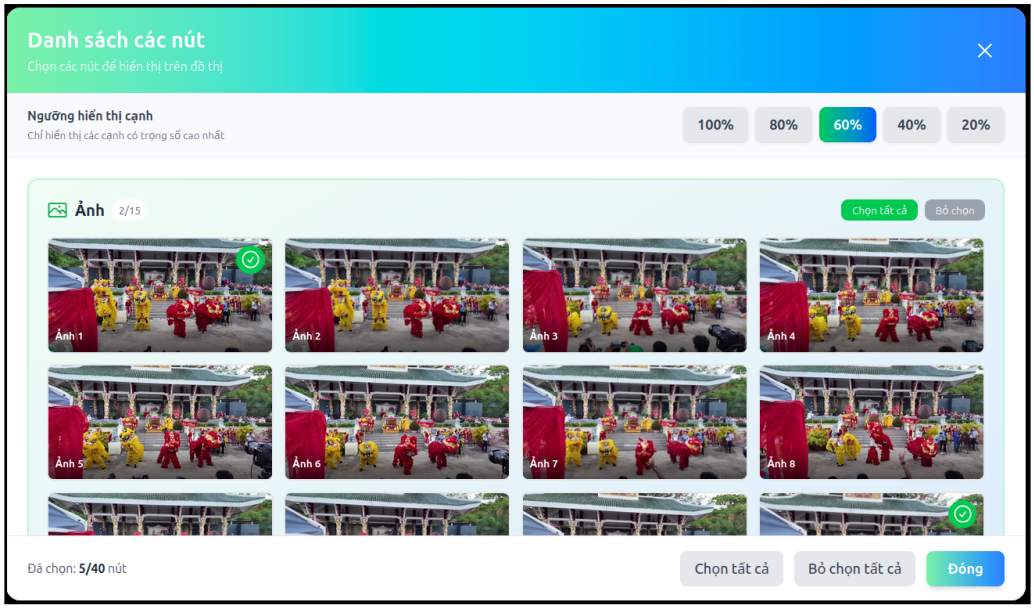

Hình 26. Giao diện danh sách nút cho phương thức hình ảnh

Danh sách nút văn bản: Tương tự như hình ảnh, khu vực này liệt kê các các nút gồm các từ đã được phân tách từ văn bản theo quy tắc đã đề ra ở các phần trên, tại đây người dùng cũng có thể chọn các từ cần trực quan hoá để hiển thị ra đồ thị.

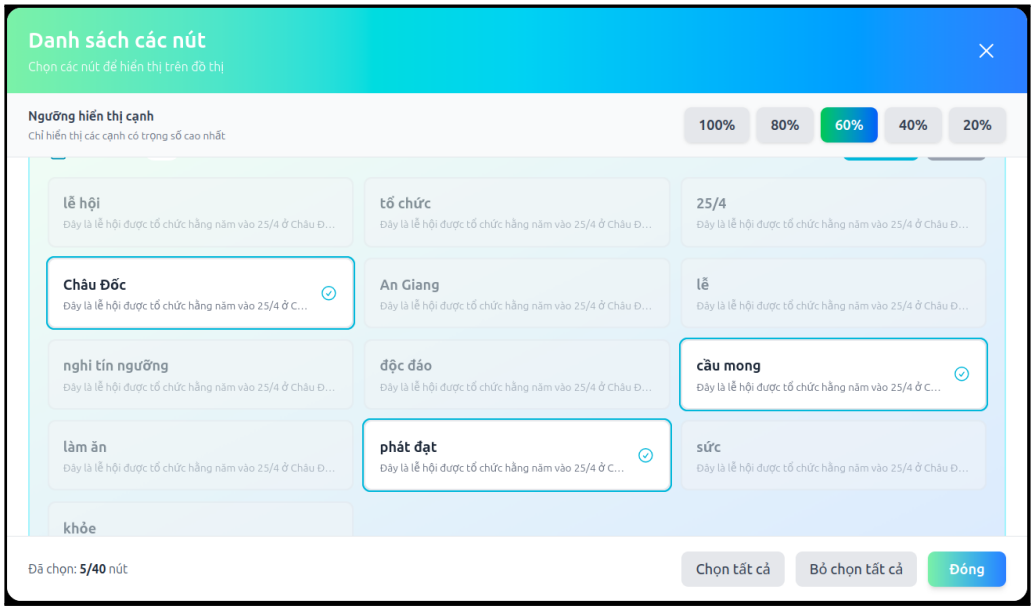

Hình 27. Giao diện danh sách nút cho phương thức văn bản

Danh sách nút âm thanh: Khu vực này quản lý các nút đại diện cho đoạn âm thanh. Đặc biệt, hệ thống tích hợp trình phát media mini, cho phép người dùng nghe lại trực tiếp nội dung của đoạn âm thanh đó bằng cách nhấn vào biểu tượng phát.

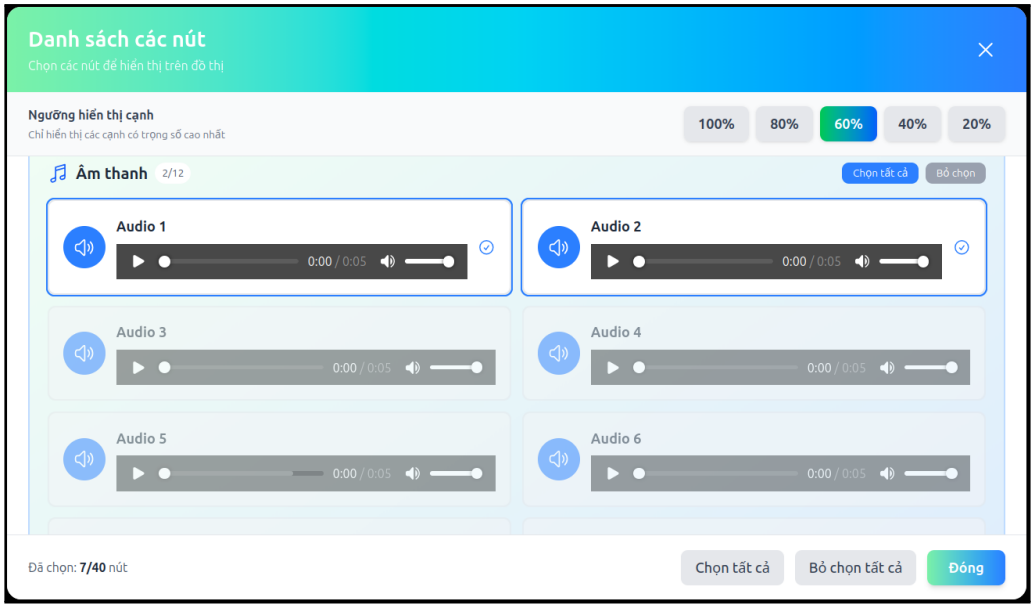

Hình 28. Giao diện danh sách nút cho phương thức âm thanh

Kết quả hiển thị đồ thị: Hình minh họa dưới đây thể hiện cấu trúc đồ thị đa phương thức được trực quan hóa với bộ lọc 60% trọng số cạnh cao nhất. Giao diện hỗ trợ tương tác toàn diện, cho phép người dùng phóng to, thu nhỏ và kéo thả các đỉnh để khám phá cấu trúc liên kết ngữ nghĩa giữa các phương thức.

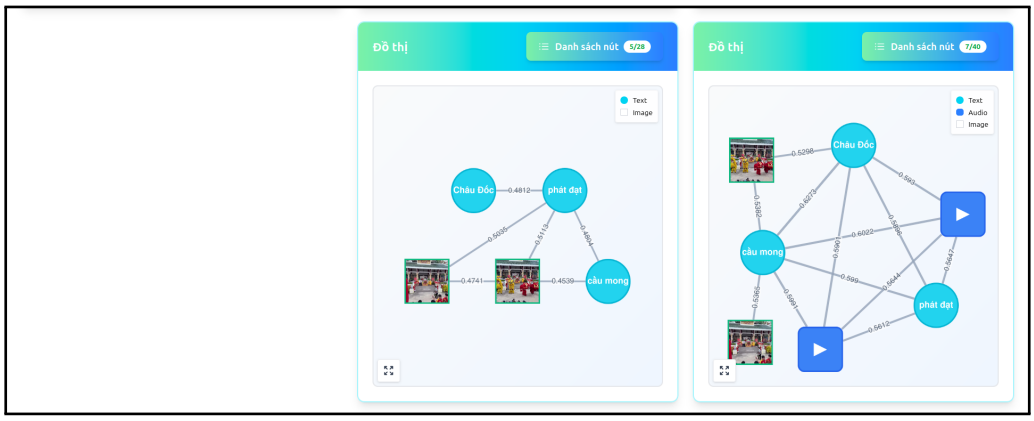

Hình 29. Giao diện hiển thị đồ thị tương tác

2. Kết quả thực nghiệm

Việc huấn luyện và thực nghiệm mô hình được tiến hành trên nhiều máy chủ khác nhau, với các cấu hình phần cứng như sau:

- **Hệ điều hành:** Debian 11
- **RAM:** từ 192 GiB đến 512 GiB
- **CPU:** Intel Xeon Silver/Gold và AMD EPYC
- **GPU:** Nvidia Quadro RTX 6000 (23 GiB) và Nvidia A40 (45 GiB)
- **Thư viện:** Sử dụng các thư viện phổ biến cho từng tác vụ như:
  + Xây dựng các mô hình học sâu: torch (2.9.0), torchvision (0.24.0), torch-geometric (2.7.0), fastkan[3].
  + Xử lý ảnh và CNN backbone: torchvision (0.24.0), pillow (12.0.0).
  + Xử lý văn bản: underthesea (8.3.0) cho tách câu, tokenization và POS tagging; sentence-transformers (5.1.2) cho tạo embedding văn bản.
  + Xử lý âm thanh: librosa (0.11.0).
  + Hỗ trợ mô hình máy học truyền thống và các thang đo đánh giá: numpy (2.3.4), pandas (2.3.3), scikit-learn (1.7.2).

2.1. Các thông số cho huấn luyện và kiểm thử

2.1.1. Tham số mô hình, siêu tham số và kỹ thuật huấn luyện

Về cấu hình tham số, đề tài áp dụng chiến lược đóng băng toàn bộ kiến trúc CNN backbone trong việc huấn luyện baseline và huấn luyện mô hình MGAT + FastKAN. Ngoài ra, mô hình ngôn ngữ all-MiniLM-L6-v2 cũng được sử dụng ở chế độ đóng băng để trích xuất đặc trưng văn bản. Do đó, tổng số lượng tham số (Total Params) của hệ thống bao gồm cả phần đóng băng và phần có thể huấn luyện (Trainable Params). Chi tiết thống kê tham số cho từng kịch bản cụ thể như sau:

*** CNN Baseline:**

Bảng 2. *Thống kê số lượng tham số của các mô hình CNN Baseline*

Mô hình	Trainable Params	Total Params
ResNet18	4.1K	11.2M
RegNetX400MF	3.2K	5.1M
MobileNetV3 Large	7.7K	3.0M
MobileNetV3 Small	4.6K	1.0M
DenseNet121	8.2K	7.0M
ShuffleNetV2 1.0x	8.2K	1.3M

[3] https://github.com/ZiyaoLi/fast-kan

*** CNN backbone + MGAT + FastKAN/MLP:**

Bảng 3. *Thống kê số lượng tham số của mô hình CNN backbone + MGAT + FastKAN/MLP*

Backbone Model (+ MGAT)	Classifier	Trainable Params	Total Params
ResNet18	FastKAN	4.9M	38.8M
	MLP	4.1M	38.0M
RegNetX400MF	FastKAN	4.9M	32.7M
	MLP	4.1M	31.9M
MobileNetV3 Large	FastKAN	5.1M	30.8M
	MLP	4.3M	30.0M
MobileNetV3 Small	FastKAN	5.0M	28.6M
	MLP	4.2M	27.8M
DenseNet121	FastKAN	5.2M	34.8M
	MLP	4.4M	34.0M
ShuffleNetV2 1.0x	FastKAN	5.2M	29.1M
	MLP	4.4M	28.3M

*** Các siêu tham số và kỹ thuật huấn luyện:** Quá trình huấn luyện được thực hiện thống nhất với bộ siêu tham số sau:

- Epoch: 100.
- Batch size: 8.
- Accumulation steps: 2 (Kỹ thuật tích lũy gradient này giúp mô phỏng kích thước batch thực tế là 16, cho phép mô hình hội tụ ổn định hơn mà vẫn tiết kiệm bộ nhớ VRAM)
- Early Stopping: Cơ chế dừng sớm được kích hoạt với patience = 10. Nếu sau 10 epoch liên tiếp giá trị *validation loss* không cải thiện, quá trình huấn luyện sẽ tự động kết thúc.
- Optimizer: *AdamW* với tốc độ học khởi tạo *lr = 1e-4* và trọng số suy giảm *weight_decay = 1e-5*.
- Scheduler: Sử dụng chiến lược *ReduceLROnPlateau* để tự động giảm tốc độ học (factor=0.5) nếu loss không giảm sau 3 epoch (patience=3).
- Drop Node (Augmentation): Để tăng khả năng tổng quát hóa của mô hình, tôi áp dụng kỹ thuật loại bỏ ngẫu nhiên các đỉnh ngay trong quá trình huấn luyện. Quy trình bao gồm 2 lượt drop liên tiếp:
  + Hình ảnh: Lần 1 (tỷ lệ 0.2), Lần 2 (tỷ lệ 0.3).
  + Văn bản: Lần 1 (tỷ lệ 0.3), Lần 2 (tỷ lệ 0.4). Đặc biệt, áp dụng ràng buộc min_not_drop = 10 để đảm bảo mỗi mẫu luôn giữ lại ít nhất 10 từ khóa quan trọng, tránh làm mất mát hoàn toàn ngữ nghĩa của mô tả.
  + Âm thanh: Lần 1 (tỷ lệ 0.2), Lần 2 (tỷ lệ 0.3).

  Tỷ lệ drop cao hơn được áp dụng cho văn bản vì số lượng đỉnh của phương thức này chiếm đa số trong đồ thị và có độ biến động cao, trong khi số lượng

đỉnh hình ảnh và âm thanh là cố định (lần lượt là 15 hình ảnh và 12 đoạn âm thanh). Thống kê phân bố số lượng từ trong tập huấn luyện được thể hiện tại **Hình 30** và **Hình 31**.

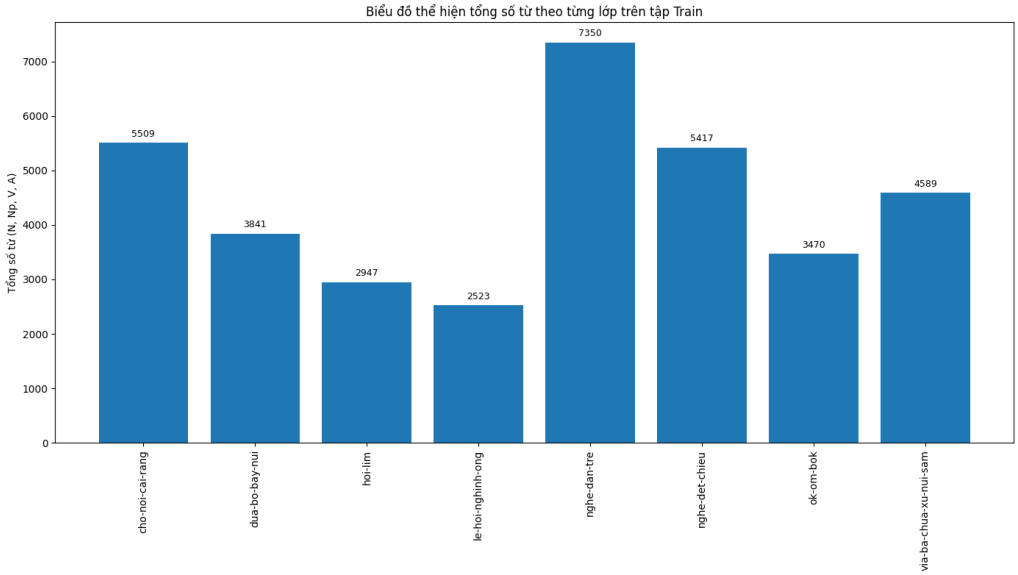

Hình 30. *Biểu đồ thống kê tổng số từ vựng trên tập Train*

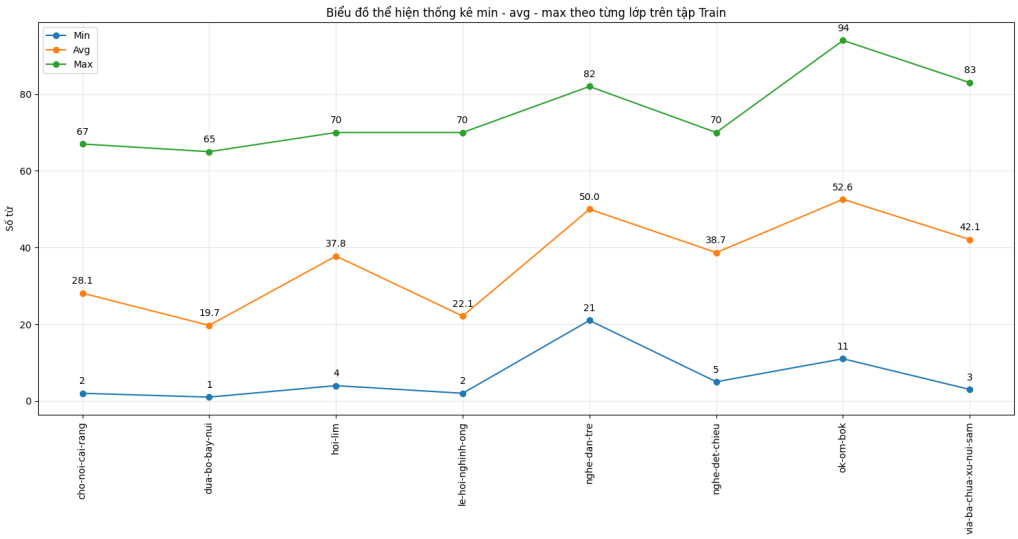

Hình 31. *Biểu đồ thống kê số lượng từ (Min, Avg, Max) trên tập Train*

2.1.2. Chiến lược kiểm thử

Quy trình kiểm thử tuân thủ nguyên tắc best model checkpoint. Trong quá trình huấn luyện, tại cuối mỗi epoch, nếu giá trị *val_loss* < *best_val_loss*, trạng thái trọng số của mô hình sẽ được lưu lại. Khi quá trình huấn luyện kết thúc (do hoàn thành 100 epoch hoặc early stopping), hệ thống sẽ tải lại phiên bản trọng số tốt nhất này để thực hiện đánh giá trên tập Test, đảm bảo kết quả phản ánh đúng năng lực của mô hình.

Bên cạnh đó, nhằm đảm bảo tính khách quan và độ ổn định của quá trình huấn luyện cũng như các kết quả kiểm thử, đề tài sử dụng ba giá trị *random seed* khác nhau, lần lượt là 1023, 123 và 42 (trong đó seed 42 được sử dụng cho kỹ thuật *drop node*). Kết quả cuối cùng được báo cáo dưới dạng giá trị trung bình của ba lần huấn luyện và kiểm thử độc lập.

2.2. Kết quả kiểm thử trên các mô hình CNN baseline

Dưới đây là kết quả kiểm thử chi tiết của sáu mô hình CNN baseline, trong đó các giá trị được lấy từ lần chạy đạt kết quả cao nhất.

*** ResNet18**

Bảng 4. *Classification report của ResNet18 trên CNN baseline*

Lớp	Precision	Recall	F1-Score	Support
cho-noi-cai-rang	0.9333	0.9333	0.9333	45
dua-bo-bay-nui	0.9574	1.0000	0.9783	45
hoi-lim	0.9333	0.9333	0.9333	45
le-hoi-nghinh-ong	0.8108	0.6667	0.7317	45
nghe-dan-tre	0.9565	0.9778	0.9670	45
nghe-det-chieu	0.9318	0.9111	0.9213	45
ok-om-bok	0.9762	0.9111	0.9425	45
via-ba-chua-xu-nui-sam	0.7037	0.8444	0.7677	45
Accuracy			0.8972	360
Macro avg	0.9004	0.8972	0.8969	360
Weighted avg	0.9004	0.8972	0.8969	360

*** RegNetX400MF**

Bảng 5. *Classification report của RegNetX400MF trên CNN baseline*

Lớp	Precision	Recall	F1-Score	Support
cho-noi-cai-rang	0.8958	0.9556	0.9247	45
dua-bo-bay-nui	0.9783	1.0000	0.9890	45
hoi-lim	0.8077	0.9333	0.8660	45
le-hoi-nghinh-ong	0.8000	0.6222	0.7000	45
nghe-dan-tre	0.9565	0.9778	0.9670	45
nghe-det-chieu	0.9744	0.8444	0.9048	45
ok-om-bok	1.0000	0.9111	0.9535	45
via-ba-chua-xu-nui-sam	0.6792	0.8000	0.7347	45
Accuracy			0.8806	360
Macro avg	0.8865	0.8806	0.8800	360
Weighted avg	0.8865	0.8806	0.8800	360

* MobileNetV3 Large

Bảng 6. *Classification report của MobileNetV3 Large trên CNN baseline*

Lớp	Precision	Recall	F1-Score	Support
cho-noi-cai-rang	0.9565	0.9778	0.9670	45
dua-bo-bay-nui	0.9783	1.0000	0.9890	45
hoi-lim	0.8958	0.9556	0.9247	45
le-hoi-nghinh-ong	0.8750	0.6222	0.7273	45
nghe-dan-tre	0.9348	0.9556	0.9451	45
nghe-det-chieu	0.9302	0.8889	0.9091	45
ok-om-bok	0.9773	0.9556	0.9663	45
via-ba-chua-xu-nui-sam	0.7091	0.8667	0.7800	45
Accuracy			0.9028	360
Macro avg	0.9071	0.9028	0.9011	360
Weighted avg	0.9071	0.9028	0.9011	360

* MobileNetV3 Small

Bảng 7. *Classification report của MobileNetV3 Small trên CNN baseline*

Lớp	Precision	Recall	F1-Score	Support
cho-noi-cai-rang	0.9184	1.0000	0.9574	45
dua-bo-bay-nui	0.9778	0.9778	0.9778	45
hoi-lim	0.7925	0.9333	0.8571	45
le-hoi-nghinh-ong	0.8636	0.4222	0.5672	45
nghe-dan-tre	0.9111	0.9111	0.9111	45
nghe-det-chieu	0.9070	0.8667	0.8864	45
ok-om-bok	0.9286	0.8667	0.8966	45
via-ba-chua-xu-nui-sam	0.5902	0.8000	0.6792	45
Accuracy			0.8472	360
Macro avg	0.8611	0.8472	0.8416	360
Weighted avg	0.8611	0.8472	0.8416	360

* DenseNet121

Bảng 8. *Classification report khi kiểm thử DenseNet121 trên CNN baseline*

Lớp	Precision	Recall	F1-Score	Support
cho-noi-cai-rang	0.9565	0.9778	0.9670	45
dua-bo-bay-nui	0.9783	1.0000	0.9890	45
hoi-lim	0.9348	0.9556	0.9451	45
le-hoi-nghinh-ong	0.7857	0.7333	0.7586	45
nghe-dan-tre	0.9767	0.9333	0.9545	45
nghe-det-chieu	0.9318	0.9111	0.9213	45
ok-om-bok	0.9348	0.9556	0.9451	45
via-ba-chua-xu-nui-sam	0.7447	0.7778	0.7609	45
Accuracy			0.9056	360
Macro avg	0.9054	0.9056	0.9052	360
Weighted avg	0.9054	0.9056	0.9052	360

*** ShuffleNetV2 1.0x**

Bảng 9. *Classification report khi kiểm thử ShuffleNet V2 1.0x trên CNN baseline*

Lớp	Precision	Recall	F1-Score	Support
cho-noi-cai-rang	0.8696	0.8889	0.8791	45
dua-bo-bay-nui	0.9149	0.9556	0.9348	45
hoi-lim	0.7925	0.9333	0.8571	45
le-hoi-nghinh-ong	0.6667	0.4444	0.5333	45
nghe-dan-tre	0.9767	0.9333	0.9545	45
nghe-det-chieu	0.8889	0.8889	0.8889	45
ok-om-bok	0.9697	0.7111	0.8205	45
via-ba-chua-xu-nui-sam	0.5873	0.8222	0.6852	45
Accuracy			0.8222	360
Macro avg	0.8333	0.8222	0.8192	360
Weighted avg	0.8333	0.8222	0.8192	360

Dựa trên kết quả kiểm thử chi tiết của các mô hình CNN baseline, có thể rút ra một số nhận xét chính như sau:

– Khả năng trích xuất đặc trưng của kiến trúc mạng:

  + DenseNet121 đạt độ chính xác cao nhất (0.9056). Điều này cho thấy rằng cơ chế kết nối dày đặc đem lại hiệu quả cao trong việc duy trì và lan truyền thông tin qua nhiều tầng, giúp mô hình xử lý tốt các đặc trưng hình ảnh của dữ liệu ảnh ICH.

  + MobileNetV3 Large cũng đạt kết quả cao với độ chính xác 0.9028, tiệm cận DenseNet121 và vượt qua ResNet18, mặc dù được thiết kế hướng đến các thiết bị có tài nguyên hạn chế. Kết quả này cho thấy các khối Inverted Residuals kết hợp với cơ chế Squeeze-and-Excitation hoạt động hiệu quả trên tập dữ liệu đang xét. Ngược lại, khi số lượng tham số bị cắt giảm mạnh, như trong MobileNetV3 Small hoặc ShuffleNetV2 1.0x, khả năng biểu diễn của mô hình yếu đi rõ rệt, với mức giảm khoảng 6–8% so với nhóm mô hình dẫn đầu.

– Mức độ khó trong phân loại giữa các lớp:

  + Lớp *dua-bo-bay-nui* duy trì F1-score trên 0.97 ở hầu hết các mô hình. Các yếu tố về thị giác như khung cảnh ruộng bùn và cặp bò đang di chuyển tạo nên đặc trưng mang tính phân biệt cao, giúp mô hình nhận diện chính xác ngay cả khi sử dụng các kiến trúc có năng lực biểu diễn hạn chế như ShuffleNet.

  + Lớp *le-hoi-nghinh-ong* có độ khó phân lớp cao nhất trong bài toán hiện tại, với F1-score thấp nhất (khoảng 0.53 ở ShuffleNet và xấp xỉ 0.75 ở DenseNet). Việc Recall của lớp này thường xuyên ở mức thấp cho thấy nhiều mẫu thực tế không được nhận diện đúng. Nguyên nhân có thể đến từ sự tương đồng về khung cảnh sông nước và tàu thuyền với lớp *cho-noi-cai-rang*, khiến việc phân biệt chỉ dựa trên thông tin hình ảnh trở nên kém hiệu quả.

Dưới đây là bảng tổng hợp và biểu đồ thể hiện kết quả trung bình của tất cả 6 mô hình CNN baseline:

Bảng 10. *Kết quả kiểm thử trung bình của tất cả các mô hình CNN baseline*

Mô hình	Accuracy	Precision	Recall	F1-Score
ResNet18	0.8907	0.8936	0.8907	0.8905
RegNetX400MF	0.8806	0.8860	0.8806	0.8797
MobileNetV3 Large	**0.9028**	**0.9076**	**0.9028**	**0.9006**
MobileNetV3 Small	0.8379	0.8547	0.8379	0.8329
DenseNet121	0.8963	0.8976	0.8963	0.8955
ShuffleNetV2 1.0x	0.8204	0.8314	0.8204	0.8172

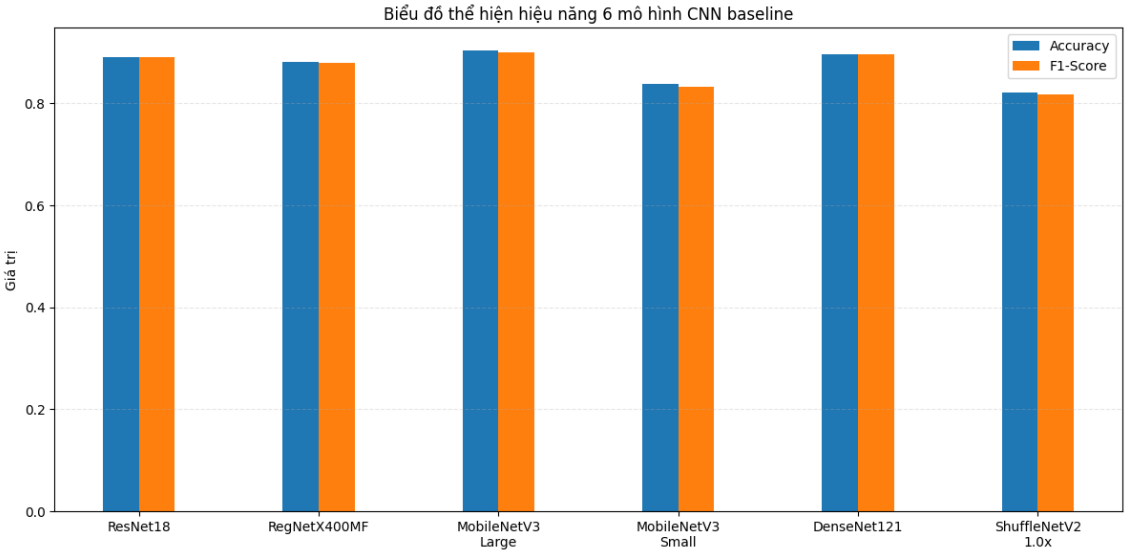

Hình 32. *Biểu đồ thể hiện hiệu năng của 6 mô hình CNN baseline*

Dựa trên bảng tổng hợp và các biểu đồ thể hiện kết quả trung bình của sáu mô hình CNN baseline, có thể rút ra một số kết luận chính như sau:

- MobileNetV3 Large đạt được kết quả trung bình tốt nhất trong bài toán này với Accuracy đạt 0.9028 và F1-Score đạt 0.9006. Mặc dù trước đó DenseNet121 cho ra kết quả tốt nhất, điều này cho thấy sự thích ứng của mô hình MobileNet V3 Large với các tập dữ liệu khác nhau (được drop ngẫu nhiên theo random seed), làm cho kết quả của mô hình vẫn ổn định qua các lần chạy.
- DenseNet121, ResNet18 và RegNetX400MF đạt độ chính xác ở mức cao và khá sát nhau, lần lượt là 0.8963, 0.8907 và 0.8806. DenseNet121 vẫn thể hiện ưu thế về khả năng học đặc trưng ở từng lần chạy riêng lẻ, tuy nhiên khi xét trên kết quả trung bình, mô hình này thấp hơn MobileNetV3 Large một khoảng nhỏ. Điều này cho thấy các kiến trúc có quy mô lớn vẫn hoạt động hiệu quả, nhưng chưa hẳn là lựa chọn tối ưu nếu xét đến sự cân bằng giữa hiệu suất và chi phí tính toán.
- MobileNetV3 Small và ShuffleNetV2 1.0x đạt kết quả thấp hơn rất nhiều, với độ chính xác lần lượt là 0.8379 và 0.8204. Khoảng cách gần 8% so với nhóm

mô hình dẫn đầu cho thấy việc giản lược mô hình quá mức đã làm hạn chế khả năng nắm bắt các chi tiết, góc cạnh phức tạp, đặc biệt đối với các lớp dữ liệu có bối cảnh hình ảnh tương đồng.

Kết quả kiểm thử cho thấy các mô hình CNN baseline, khi chỉ sử dụng thông tin hình ảnh, có thể đạt độ chính xác xấp xỉ **0.91**. Tuy nhiên, việc khó vượt qua ngưỡng này, cùng với những hạn chế trong việc phân biệt các lớp có mức độ nhập nhằng cao (chẳng hạn như lớp *le-hoi-nghinh-ong*), cho thấy sự cần thiết của việc bổ sung thêm thông tin từ hai phương thức văn bản và âm thanh.

2.3. Kết quả kiểm thử trên mô hình CNN + MGAT + FastKAN/MLP với toàn bộ phương thức

Dưới đây là kết quả kiểm thử chi tiết của 12 mô hình CNN backbone + MGAT + FastKAN/MLP với toàn bộ phương thức, trong đó các giá trị được lấy từ lần chạy đạt kết quả cao nhất.

*** ResNet18 + MGAT + FastKAN/MLP:**

Bảng 11. *Classification report của FastKAN(1) và MLP(2) trên toàn bộ phương thức với backbone ResNet18*

Lớp	P(1)	R(1)	F1(1)	P(2)	R(2)	F1(2)	Support
cho-noi-cai-rang	1.0000	0.9556	**0.9773**	0.9333	0.9333	0.9333	45
dua-bo-bay-nui	1.0000	1.0000	**1.0000**	0.9574	1.0000	0.9783	45
hoi-lim	0.9762	0.9111	**0.9425**	0.9130	0.9333	0.9231	45
le-hoi-nghinh-ong	0.9000	0.8000	**0.8471**	0.8261	0.8444	0.8352	45
nghe-dan-tre	1.0000	1.0000	**1.0000**	0.9565	0.9778	0.9670	45
nghe-det-chieu	0.9574	1.0000	**0.9783**	0.9348	0.9556	0.9451	45
ok-om-bok	0.9574	1.0000	**0.9783**	1.0000	0.8444	0.9157	45
via-ba-chua-xu-nui-sam	0.8235	0.9333	**0.8750**	0.8478	0.8667	0.8571	45
Accuracy			**0.9500**			0.9194	360
Macro avg	**0.9518**	**0.9500**	**0.9498**	0.9211	0.9194	0.9193	360
Weighted avg	**0.9518**	**0.9500**	**0.9498**	0.9211	0.9194	0.9193	360

*** RegNetX400MF + MGAT + FastKAN/MLP:**

Bảng 12. *Classification report của FastKAN(1) và MLP(2) trên toàn bộ phương thức với backbone RegNetX400MF*

Lớp	P(1)	R(1)	F1(1)	P(2)	R(2)	F1(2)	Support
cho-noi-cai-rang	0.9778	0.9778	**0.9778**	0.9565	0.9778	0.9670	45
dua-bo-bay-nui	1.0000	1.0000	**1.0000**	0.9375	1.0000	0.9677	45
hoi-lim	0.8889	0.8889	0.8889	0.9318	0.9111	**0.9213**	45
le-hoi-nghinh-ong	0.7727	0.7556	0.7640	0.8649	0.7111	**0.7805**	45
nghe-dan-tre	1.0000	1.0000	**1.0000**	0.9783	1.0000	0.9890	45
nghe-det-chieu	0.9778	0.9778	**0.9778**	1.0000	0.8889	0.9412	45
ok-om-bok	0.9545	0.9333	0.9438	0.9556	0.9556	**0.9556**	45
via-ba-chua-xu-nui-sam	0.7660	0.8000	0.7826	0.7593	0.9111	**0.8283**	45
Accuracy			0.9167			**0.9194**	360
Macro avg	0.9172	0.9167	0.9169	**0.9230**	**0.9194**	**0.9188**	360
Weighted avg	0.9172	0.9167	0.9169	**0.9230**	**0.9194**	**0.9188**	360

* MobileNetV3 Large + MGAT + FastKAN/MLP:

Bảng 13. *Classification report của FastKAN(1) và MLP(2) trên toàn bộ phương thức với backbone MobileNetV3 Large*

Lớp	P(1)	R(1)	F1(1)	P(2)	R(2)	F1(2)	Support
cho-noi-cai-rang	0.9184	1.0000	0.9574	0.9778	0.9778	**0.9778**	45
dua-bo-bay-nui	1.0000	1.0000	**1.0000**	0.9783	1.0000	0.9890	45
hoi-lim	0.9111	0.9111	**0.9111**	0.8333	0.8889	0.8602	45
le-hoi-nghinh-ong	0.8780	0.8000	**0.8372**	0.8684	0.7333	0.7952	45
nghe-dan-tre	1.0000	0.9778	**0.9888**	0.9778	0.9778	0.9778	45
nghe-det-chieu	0.9762	0.9111	0.9425	0.9767	0.9333	**0.9545**	45
ok-om-bok	0.9773	0.9556	**0.9663**	0.9130	0.9333	0.9231	45
via-ba-chua-xu-nui-sam	0.8000	0.8889	**0.8421**	0.7551	0.8222	0.7872	45
Accuracy			**0.9306**			0.9083	360
Macro avg	**0.9326**	**0.9306**	**0.9307**	0.9101	0.9083	0.9081	360
Weighted avg	**0.9326**	**0.9306**	**0.9307**	0.9101	0.9083	0.9081	360

* MobileNetV3 Small + MGAT + FastKAN/MLP:

Bảng 14. *Classification report của FastKAN(1) và MLP(2) trên toàn bộ phương thức với backbone MobileNetV3 Small*

Lớp	P(1)	R(1)	F1(1)	P(2)	R(2)	F1(2)	Support
cho-noi-cai-rang	0.9778	0.9778	**0.9778**	0.8980	0.9778	0.9362	45
dua-bo-bay-nui	1.0000	0.9778	0.9888	1.0000	1.0000	**1.0000**	45
hoi-lim	0.9302	0.8889	0.9091	0.9111	0.9111	**0.9111**	45
le-hoi-nghinh-ong	0.7857	0.7333	0.7586	0.8372	0.8000	**0.8182**	45
nghe-dan-tre	0.9773	0.9556	0.9663	1.0000	0.9778	**0.9888**	45
nghe-det-chieu	0.9130	0.9333	0.9231	0.9535	0.9111	**0.9318**	45
ok-om-bok	0.9565	0.9778	**0.9670**	0.9556	0.9556	0.9556	45
via-ba-chua-xu-nui-sam	0.7600	0.8444	0.8000	0.8261	0.8444	**0.8352**	45
Accuracy			0.9111			**0.9222**	360
Macro avg	0.9126	0.9111	0.9113	**0.9227**	**0.9222**	**0.9221**	360
Weighted avg	0.9126	0.9111	0.9113	**0.9227**	**0.9222**	**0.9221**	360

* DenseNet121 + MGAT + FastKAN/MLP:

Bảng 15. *Classification report của FastKAN(1) và MLP(2) trên toàn bộ phương thức với backbone DenseNet121*

Lớp	P(1)	R(1)	F1(1)	P(2)	R(2)	F1(2)	Support
cho-noi-cai-rang	1.0000	1.0000	**1.0000**	0.9565	0.9778	0.9670	45
dua-bo-bay-nui	1.0000	1.0000	**1.0000**	1.0000	1.0000	**1.0000**	45
hoi-lim	0.9302	0.8889	0.9091	0.9149	0.9556	**0.9348**	45
le-hoi-nghinh-ong	0.8750	0.9333	0.9032	0.9111	0.9111	**0.9111**	45
nghe-dan-tre	1.0000	0.9778	0.9888	0.9783	1.0000	**0.9890**	45
nghe-det-chieu	0.9783	1.0000	**0.9890**	1.0000	0.9556	0.9773	45
ok-om-bok	0.9318	0.9111	0.9213	0.9333	0.9333	**0.9333**	45
via-ba-chua-xu-nui-sam	0.9333	0.9333	**0.9333**	0.9302	0.8889	0.9091	45
Accuracy			**0.9556**			0.9528	360
Macro avg	**0.9561**	**0.9556**	**0.9556**	0.9530	0.9528	0.9527	360
Weighted avg	**0.9561**	**0.9556**	**0.9556**	0.9530	0.9528	0.9527	360

*** ShuffleNetV2 1.0x + MGAT + FastKAN/MLP:**

Bảng 16. *Classification report của FastKAN(1) và MLP(2) trên toàn bộ phương thức với backbone ShuffleNetV2 1.0x*

Lớp	P(1)	R(1)	F1(1)	P(2)	R(2)	F1(2)	Support
cho-noi-cai-rang	1.0000	0.9111	**0.9535**	0.9556	0.9556	0.9556	45
dua-bo-bay-nui	0.9778	0.9778	0.9778	1.0000	0.9778	**0.9888**	45
hoi-lim	0.8478	0.8667	0.8571	0.8958	0.9556	**0.9247**	45
le-hoi-nghinh-ong	0.8333	0.8889	**0.8602**	0.8750	0.7778	0.8235	45
nghe-dan-tre	1.0000	0.9333	0.9655	0.9556	0.9556	**0.9556**	45
nghe-det-chieu	0.8800	0.9778	0.9263	0.9565	0.9778	**0.9670**	45
ok-om-bok	0.8667	0.8667	0.8667	1.0000	0.9333	**0.9655**	45
via-ba-chua-xu-nui-sam	0.8837	0.8444	**0.8636**	0.8200	0.9111	0.8632	45
Accuracy			0.9083			**0.9306**	360
Macro avg	0.9112	0.9083	0.9088	**0.9323**	**0.9306**	**0.9305**	360
Weighted avg	0.9112	0.9083	0.9088	**0.9323**	**0.9306**	**0.9305**	360

Dựa trên kết quả kiểm thử chi tiết của các mô hình CNN backbone kết hợp với MGAT và FastKAN/MLP trên tập dữ liệu kiểm thử với đầy đủ ba phương thức, có thể rút ra một số nhận xét chính như sau:

– Hiệu quả của tiếp cận đa phương thức: So với các mô hình CNN baseline chỉ sử dụng thông tin hình ảnh (với Accuracy trung bình xấp xỉ 0.9-0.91), việc tích hợp thêm dữ liệu văn bản và âm thanh thông qua kiến trúc MGAT giúp cải thiện kết quả một cách đáng kể trên hầu hết các backbone. Mức cải thiện này thể hiện rõ nhất ở các lớp có mức độ nhập nhằng cao trong dữ liệu hình ảnh (*le-hoi-nghinh-ong* và *via-ba-chua-xu-nui-sam*), cho thấy vai trò bổ trợ quan trọng của thông tin ngữ nghĩa và âm thanh trong quá trình phân loại.

– So sánh FastKAN và MLP trên từng backbone:

  + ResNet18: FastKAN thể hiện ưu thế rõ rệt so với MLP. Mô hình ResNet18 kết hợp FastKAN đạt độ chính xác 0.95, cao hơn đáng kể so với 0.9194 của MLP. Đặc biệt, tại lớp khó *via-ba-chua-xu-nui-sam*, FastKAN giúp cải thiện Recall từ 0.87 lên 0.93, cho thấy khả năng mô hình hóa các biên quyết định phi tuyến phức tạp hiệu quả hơn so với cấu trúc MLP truyền thống.

  + DenseNet121: Đây là backbone cho kết quả cao nhất trong toàn bộ các kết quả kiểm thử, với độ chính xác vượt ngưỡng 0.95 ở cả hai bộ phân lớp FastKAN và MLP. So với mô hình CNN baseline đơn phương thức, mức cải thiện đạt được vào khoảng 5%, cho thấy sự kết hợp giữa biểu diễn đặc trưng mạnh và tích hợp đa phương thức mang lại hiệu quả đáng kể.

  + MobileNetV3 Large: FastKAN tiếp tục cho thấy lợi thế với Accuracy đạt 0.9306, so với 0.9083 của MLP. Mô hình đạt kết quả gần như tuyệt đối ở lớp *dua-bo-bay-nui*, đồng thời cải thiện đáng kể F1-Score của lớp *le-hoi-nghinh-ong* (0.8372 so với 0.7952). Điều này cho thấy sự kết hợp giữa một backbone gọn nhẹ và một bộ phân lớp có năng lực biểu diễn cao là một hướng tiếp cận tiềm năng.

+ Các backbone MobileNetV3 Small, ShuffleNetV2 và RegNet: Trong nhóm các kiến trúc gọn nhẹ hơn, MLP cho kết quả tương đương hoặc nhỉnh hơn FastKAN. Chẳng hạn, với ShuffleNetV2 1.0x, MLP đạt độ chính xác 0.9306 trong khi FastKAN đạt 0.9083. Khi đặc trưng đầu vào từ backbone bị nén mạnh và chứa ít thông tin hơn, độ phức tạp cao của FastKAN có thể dẫn đến hiện tượng overfitting nhẹ, trong khi cấu trúc đơn giản của MLP giúp mô hình duy trì khả năng tổng quát hóa tốt hơn.

Dưới đây là bảng tổng hợp và biểu đồ thể hiện kết quả trung bình của tất cả 12 mô hình CNN backbone + MGAT + FastKAN/MLP:

Bảng 17. *Kết quả kiểm thử trung bình của tất cả các mô hình CNN backbone + MGAT + FastKAN/MLP trên toàn bộ phương thức*

Backbone Model (+ MGAT)	Classifier	Accuracy	Precision	Recall	F1-Score
ResNet18	FastKAN	**0.9343**	**0.9358**	**0.9343**	**0.9341**
	MLP	0.9000	0.9030	0.9000	0.8996
RegNetX400MF	FastKAN	0.9074	0.9094	0.9074	0.9071
	MLP	**0.9092**	**0.9134**	**0.9092**	**0.9090**
MobileNetV3 Large	FastKAN	**0.9260**	**0.9283**	**0.9260**	**0.9258**
	MLP	0.9056	0.9059	0.9056	0.9043
MobileNetV3 Small	FastKAN	0.9055	0.9111	0.9055	0.9041
	MLP	**0.9120**	**0.9174**	**0.9120**	**0.9118**
DenseNet121	FastKAN	**0.9435**	**0.9477**	**0.9435**	**0.9438**
	MLP	0.9417	0.9455	0.9417	0.9413
ShuffleNetV2 1.0x	FastKAN	0.8981	0.9007	0.8981	0.8980
	MLP	**0.9204**	**0.9236**	**0.9204**	**0.9203**

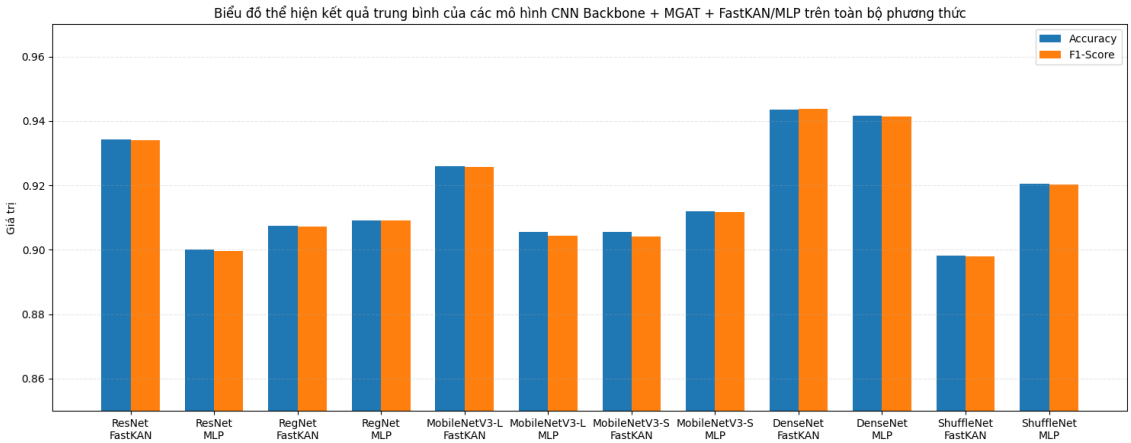

Hình 33. *Biểu đồ thể hiện kết quả kiểm thử trung bình của tất cả các mô hình CNN backbone + MGAT + FastKAN/MLP trên toàn bộ phương thức*

Dựa trên bảng tổng hợp và các biểu đồ thể hiện kết quả trung bình của 12 mô hình trên toàn bộ phương thức, có thể rút ra những kết luận chính sau:

– Khẳng định hiệu quả của phương pháp đề xuất: Phần lớn các mô hình sử dụng MGAT (kết hợp với FastKAN hoặc MLP) cho ra kết quả cao hơn so với mô

hình CNN baseline (cao nhất khoảng 0.91). Nổi bật nhất trong số đó là sự kết hợp của mô hình DenseNet121 + MGAT + FastKAN với độ chính xác đạt **0.9435** và ResNet18 + MGAT + FastKAN đạt 0.9343. Kết quả này cho thấy việc mô hình hóa dữ liệu dưới dạng đồ thị đa phương thức là một phương pháp xử lý hiệu quả các thông tin bổ trợ từ văn bản và âm thanh, qua đó bù đắp những hạn chế của các mô hình đơn phương thức.

– Mối quan hệ giữa FastKAN và MLP: Kết quả kiểm thử cho thấy không tồn tại một bộ phân lớp duy nhất có thể tối ưu cho mọi kiến trúc backbone:

  + FastKAN phù hợp hơn với các backbone có năng lực trích xuất đặc trưng mạnh (các kiến trúc lớn hoặc sâu như ResNet, DenseNet và MobileNetV3 Large). Nhờ khả năng biểu diễn hàm linh hoạt, FastKAN có thể khai thác hiệu quả lượng thông tin giàu ngữ nghĩa từ các đặc trưng đầu vào, qua đó giúp cải thiện đáng kể độ chính xác phân lớp.
  + MLP cho ra kết quả ổn định hơn đối với các backbone gọn nhẹ (như MobileNetV3 Small và ShuffleNet). Trong bối cảnh tài nguyên tính toán bị giới hạn nghiêm ngặt, sự kết hợp ShuffleNetV2 + MLP (Accuracy đạt 0.9204) vẫn mang lại kết quả rất ấn tượng..

2.4. Kết quả kiểm thử trên mô hình CNN + MGAT + FastKAN/MLP với hai phương thức (hình ảnh và văn bản)

Dưới đây là kết quả kiểm thử chi tiết của 12 mô hình CNN backbone + MGAT + FastKAN/MLP với hai phương thức (hình ảnh và văn bản), trong đó các giá trị được lấy từ lần chạy đạt kết quả cao nhất.

*** ResNet18 + MGAT + FastKAN/MLP:**

Bảng 18. *Classification report của FastKAN(1) và MLP(2) trên hai phương thức với backbone ResNet18*

Lớp	P(1)	R(1)	F1(1)	P(2)	R(2)	F1(2)	Support
cho-noi-cai-rang	0.9130	0.9333	**0.9231**	1.0000	0.7556	0.8608	45
dua-bo-bay-nui	0.9783	1.0000	**0.9890**	0.9574	1.0000	0.9783	45
hoi-lim	0.9565	0.9778	**0.9670**	0.9773	0.9556	0.9663	45
le-hoi-nghinh-ong	0.8286	0.6444	0.7250	0.8333	0.7778	**0.8046**	45
nghe-dan-tre	0.9783	1.0000	**0.9890**	0.8654	1.0000	0.9278	45
nghe-det-chieu	0.9778	0.9778	**0.9778**	0.9512	0.8667	0.9070	45
ok-om-bok	1.0000	0.9111	**0.9535**	0.8400	0.9333	0.8842	45
via-ba-chua-xu-nui-sam	0.7091	0.8667	**0.7800**	0.8000	0.8889	0.8421	45
Accuracy			**0.9139**			0.8972	360
Macro avg	**0.9177**	**0.9139**	**0.9130**	0.9031	0.8972	0.8964	360
Weighted avg	**0.9177**	**0.9139**	**0.9130**	0.9031	0.8972	0.8964	360

* RegNetX400MF + MGAT + FastKAN/MLP:

Bảng 19. *Classification report của FastKAN(1) và MLP(2) trên hai phương thức với backbone RegNetX400MF*

Lớp	P(1)	R(1)	F1(1)	P(2)	R(2)	F1(2)	Support
cho-noi-cai-rang	0.8600	0.9556	0.9053	0.9149	0.9556	**0.9348**	45
dua-bo-bay-nui	0.9574	1.0000	0.9783	0.9783	1.0000	**0.9890**	45
hoi-lim	0.8113	0.9556	0.8776	0.9333	0.9333	**0.9333**	45
le-hoi-nghinh-ong	0.7234	0.7556	0.7391	0.7500	0.8000	**0.7742**	45
nghe-dan-tre	1.0000	0.9778	0.9888	0.9783	1.0000	**0.9890**	45
nghe-det-chieu	0.9487	0.8222	0.8810	0.9556	0.9556	**0.9556**	45
ok-om-bok	0.9737	0.8222	0.8916	0.9545	0.9333	**0.9438**	45
via-ba-chua-xu-nui-sam	0.7381	0.6889	0.7126	0.8718	0.7556	**0.8095**	45
Accuracy			0.8722			**0.9167**	360
Macro avg	0.8766	0.8722	0.8718	**0.9171**	**0.9167**	**0.9162**	360
Weighted avg	0.8766	0.8722	0.8718	**0.9171**	**0.9167**	**0.9162**	360

* MobileNetV3 Large + MGAT + FastKAN/MLP:

Bảng 20. *Classification report của FastKAN(1) và MLP(2) trên hai phương thức với backbone MobileNetV3 Large*

Lớp	P(1)	R(1)	F1(1)	P(2)	R(2)	F1(2)	Support
cho-noi-cai-rang	0.8824	1.0000	**0.9375**	0.9149	0.9556	0.9348	45
dua-bo-bay-nui	1.0000	1.0000	**1.0000**	1.0000	1.0000	**1.0000**	45
hoi-lim	0.9333	0.9333	**0.9333**	0.8182	1.0000	0.9000	45
le-hoi-nghinh-ong	0.9032	0.6222	0.7368	0.9118	0.6889	**0.7848**	45
nghe-dan-tre	0.9783	1.0000	**0.9890**	0.9783	1.0000	**0.9890**	45
nghe-det-chieu	1.0000	0.9556	**0.9773**	0.9762	0.9111	0.9425	45
ok-om-bok	0.9778	0.9778	**0.9778**	0.9778	0.9778	**0.9778**	45
via-ba-chua-xu-nui-sam	0.7222	0.8667	0.7879	0.8043	0.8222	**0.8132**	45
Accuracy			**0.9194**			**0.9194**	360
Macro avg	**0.9246**	**0.9194**	0.9175	0.9227	**0.9194**	**0.9178**	360
Weighted avg	**0.9246**	**0.9194**	0.9175	0.9227	**0.9194**	**0.9178**	360

* MobileNetV3 Small + MGAT + FastKAN/MLP:

Bảng 21. *Classification report của FastKAN(1) và MLP(2) trên hai phương thức với backbone MobileNetV3 Small*

Lớp	P(1)	R(1)	F1(1)	P(2)	R(2)	F1(2)	Support
cho-noi-cai-rang	0.7627	1.0000	0.8654	0.8980	0.9778	**0.9362**	45
dua-bo-bay-nui	1.0000	0.9556	**0.9773**	1.0000	0.9556	**0.9773**	45
hoi-lim	0.9070	0.8667	0.8864	0.8936	0.9333	**0.9130**	45
le-hoi-nghinh-ong	0.7879	0.5778	**0.6667**	0.7027	0.5778	0.6341	45
nghe-dan-tre	0.9574	1.0000	**0.9783**	1.0000	0.9333	0.9655	45
nghe-det-chieu	0.9730	0.8000	0.8780	0.9333	0.9333	**0.9333**	45
ok-om-bok	0.9574	1.0000	**0.9783**	0.9556	0.9556	0.9556	45
via-ba-chua-xu-nui-sam	0.6863	0.7778	**0.7292**	0.6538	0.7556	0.7010	45
Accuracy			0.8722			**0.8778**	360
Macro avg	0.8790	0.8722	0.8699	**0.8796**	**0.8778**	**0.8770**	360
Weighted avg	0.8790	0.8722	0.8699	**0.8796**	**0.8778**	**0.8770**	360

*** DenseNet121 + MGAT + FastKAN/MLP:**

Bảng 22. *Classification report của FastKAN(1) và MLP(2) trên hai phương thức với backbone DenseNet121*

Lớp	P(1)	R(1)	F1(1)	P(2)	R(2)	F1(2)	Support
cho-noi-cai-ran	0.9565	0.9778	**0.9670**	0.9149	0.9556	0.9348	45
dua-bo-bay-nui	0.9375	1.0000	0.9677	1.0000	1.0000	**1.0000**	45
hoi-lim	0.8980	0.9778	**0.9362**	0.9756	0.8889	0.9302	45
le-hoi-nghinh-ong	0.7692	0.8889	0.8247	0.7843	0.8889	**0.8333**	45
nghe-dan-tre	0.9783	1.0000	**0.9890**	1.0000	0.9333	0.9655	45
nghe-det-chieu	1.0000	0.9333	**0.9655**	0.9111	0.9111	0.9111	45
ok-om-bok	0.9744	0.8444	0.9048	0.9149	0.9556	**0.9348**	45
via-ba-chua-xu-nui-sam	0.8421	0.7111	0.7711	0.8571	0.8000	**0.8276**	45
Accuracy			**0.9167**			**0.9167**	360
Macro avg	0.9195	0.9167	0.9158	**0.9197**	**0.9167**	**0.9172**	360
Weighted avg	0.9195	0.9167	0.9158	**0.9197**	**0.9167**	**0.9172**	360

*** ShuffleNetV2 1.0x + MGAT + FastKAN/MLP:**

Bảng 23. *Classification report của FastKAN(1) và MLP(2) trên hai phương thức với backbone ShuffleNetV2 1.0x*

Lớp	P(1)	R(1)	F1(1)	P(2)	R(2)	F1(2)	Support
cho-noi-cai-rang	0.9545	0.9333	**0.9438**	0.9535	0.9111	0.9318	45
dua-bo-bay-nui	0.8958	0.9556	0.9247	0.9149	0.9556	**0.9348**	45
hoi-lim	0.9167	0.9778	**0.9462**	0.8980	0.9778	0.9362	45
le-hoi-nghinh-ong	0.8085	0.8444	0.8261	0.8780	0.8000	**0.8372**	45
nghe-dan-tre	0.9184	1.0000	**0.9574**	0.9767	0.9333	0.9545	45
nghe-det-chieu	0.9756	0.8889	**0.9302**	0.8958	0.9556	0.9247	45
ok-om-bok	0.9268	0.8444	0.8837	0.9737	0.8222	**0.8916**	45
via-ba-chua-xu-nui-sam	0.8571	0.8000	**0.8276**	0.7647	0.8667	0.8125	45
Accuracy			**0.9056**			0.9028	360
Macro avg	0.9067	**0.9056**	**0.9050**	**0.9069**	0.9028	0.9029	360
Weighted avg	0.9067	**0.9056**	**0.9050**	**0.9069**	0.9028	0.9029	360

Dựa trên kết quả kiểm thử các mô hình chỉ sử dụng hai phương thức, có thể rút ra một số nhận xét chính như sau:

– Mức cải thiện rõ rệt ở các mô hình gọn nhẹ: Trái ngược với các kiến trúc quy mô lớn, các backbone nhẹ lại hưởng lợi nhiều hơn từ việc bổ sung thông tin văn bản. Tiêu biểu là ShuffleNetV2 1.0x, từ kết quả thấp nhất ở baseline (0.8222), khi kết hợp với MGAT + FastKAN đã đạt độ chính xác 0.9056; phương án sử dụng MLP cũng cho kết quả tương đương với 0.9028 (mức cải thiện gần 8%). Tương tự, MobileNetV3 Small cũng cho ra kết quả cao hơn đáng kể khoảng 2.2% (từ 0.8472 lên 0.8778). Kết quả này cho thấy kiến trúc đồ thị đa phương thức đóng vai trò hiệu quả trong việc bù đắp sự thiếu hụt thông tin biểu diễn của các backbone nhỏ.

– Hạn chế khi kết hợp RegNetX400MF với FastKAN: Trong khi phần lớn các mô hình đều cải thiện hoặc duy trì kết quả tương đương so với baseline, thì RegNetX400MF kết hợp với FastKAN lại cho thấy sự sụt giảm về độ chính

xác (0.8722 so với 0.8806). Ngược lại, khi sử dụng bộ phân lớp MLP, mô hình này đạt kết quả khả quan hơn với độ chính xác 0.9167. Điều này cho thấy đặc trưng trích xuất từ RegNet có thể chưa tương thích tốt với cấu trúc biểu diễn của FastKAN trong không gian đa phương thức.

– Mức cải thiện hạn chế ở một số mô hình: Đối với các kiến trúc có năng lực trích xuất đặc trưng cao như DenseNet121, ResNet18 và MobileNetV3 Large, kết quả chỉ được cải thiện ở mức khiêm tốn (khoảng 0.3%–1% so với baseline). Nguyên nhân có thể là do các mô hình này đã khai thác hiệu quả thông tin hình ảnh ngay từ đầu, khiến dữ liệu văn bản chủ yếu đóng vai trò tinh chỉnh các biên quyết định khó thay vì mang lại sự thay đổi đột phá.

Bảng 24. *Kết quả kiểm thử trung bình của tất cả các mô hình CNN backbone + MGAT + FastKAN/MLP trên hai phương thức*

Backbone Model (+ MGAT)	Classifier	Accuracy	Precision	Recall	F1-Score
ResNet18	FastKAN	**0.8962**	**0.8993**	**0.8963**	**0.8958**
	MLP	0.8843	0.8889	0.8843	0.8834
RegNetX400MF	FastKAN	0.8648	0.8814	0.8648	0.8643
	MLP	**0.8926**	**0.8942**	**0.8926**	**0.8921**
MobileNetV3 Large	FastKAN	0.9111	0.9143	0.9111	0.9098
	MLP	**0.9157**	**0.9177**	**0.9157**	**0.9147**
MobileNetV3 Small	FastKAN	0.8583	0.8615	0.8583	0.8557
	MLP	**0.8694**	**0.8726**	**0.8694**	**0.8687**
DenseNet121	FastKAN	**0.9083**	**0.9102**	**0.9083**	**0.9082**
	MLP	0.9037	0.9066	0.9037	0.9028
ShuffleNetV2 1.0x	FastKAN	**0.8982**	0.8988	**0.8982**	**0.8973**
	MLP	0.8917	**0.8989**	0.8917	0.8916

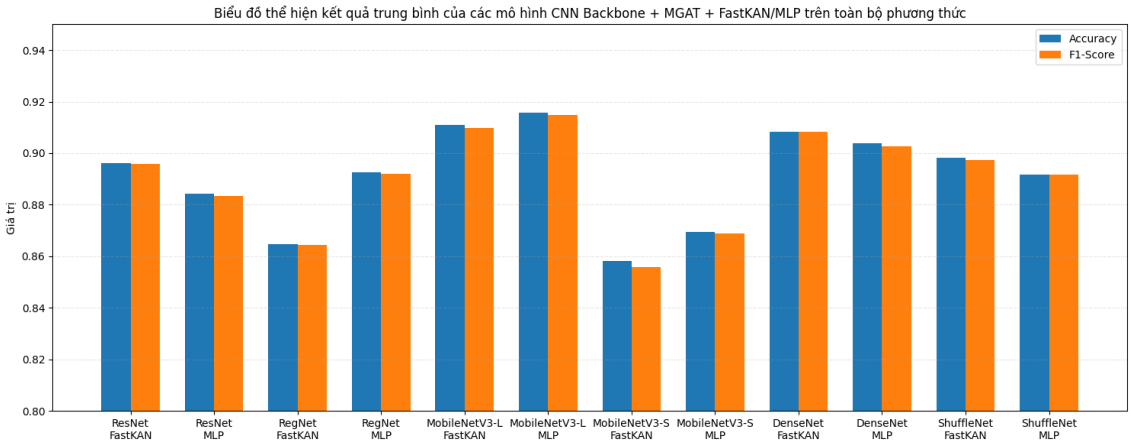

Hình 34. *Biểu đồ thể hiện kết quả kiểm thử trung bình của tất cả các mô hình CNN backbone + MGAT + FastKAN/MLP trên hai phương thức*

Dựa trên bảng tổng hợp và các biểu đồ thể hiện kết quả trung bình của 12 mô hình trên hai phương thức, có thể rút ra các kết luận sau:

– Hiệu quả giới hạn của FastKAN trong kịch bản hai phương thức: So với mức cải thiện rõ rệt khi sử dụng đầy đủ ba phương thức (chẳng hạn ResNet18 tăng hơn 3% so với MLP), thì trong kịch bản chỉ sử dụng hai phương thức, lợi thế của FastKAN thể hiện không rõ ràng, với mức cải thiện chỉ khoảng ~1%. Điều này cho thấy FastKAN cần một không gian đặc trưng đầu vào đủ phong phú và đa dạng để khai thác hiệu quả khả năng xấp xỉ hàm phi tuyến. Khi thiếu đi thông tin âm thanh, không gian biểu diễn bị thu hẹp, các quan hệ ngữ nghĩa trở nên đơn giản hơn, khiến kiến trúc FastKAN chưa được tận dụng triệt để.

– Tính ổn định của MLP trên các backbone MobileNet và RegNet: Với các backbone thuộc dòng MobileNetV3 và RegNetX400MF, MLP cho kết quả ổn định hơn hoặc nhỉnh hơn so với FastKAN. Điển hình là RegNetX400MF, khi kết hợp với MLP đạt độ chính xác 0.8926, cao hơn đáng kể so với 0.8648 của FastKAN. Kết quả này cho thấy đối với dạng đặc trưng được trích xuất từ các backbone này, cấu trúc tuyến tính tương đối đơn giản của MLP phù hợp hơn và ít rủi ro hơn, đồng thời giúp mô hình hội tụ ổn định trong không gian đa phương thức bị rút gọn.

– Vai trò quan trọng của dữ liệu âm thanh: Mặc dù các mô hình chỉ sử dụng hai phương thức đã cải thiện được kết quả so với CNN Baseline, nhưng khi so sánh với kết quả sử dụng đầy đủ ba phương thức (Mục 2.3), vẫn tồn tại sự chênh lệch đáng kể về độ chính xác (thấp hơn khoảng 2–3%). Khoảng cách này là minh chứng cho thấy, đối với các bài toán nhận dạng ICH mang tính trình diễn hoặc lễ hội, thông tin từ kênh âm thanh là thành phần quan trọng giúp hoàn thiện biểu diễn ngữ nghĩa và nâng cao hiệu năng tổng thể của hệ thống.

2.5. Kết quả kiểm thử trên mô hình CNN + MGAT + mô hình phân lớp truyền thống với toàn bộ phương thức

Nhằm đánh giá một cách khách quan chất lượng của các đặc trưng (features) được học bởi kiến trúc đồ thị, đề tài tiến hành thực hiện một thực nghiệm bổ sung, trong đó bộ phân lớp học sâu (FastKAN/MLP) được thay thế bằng các thuật toán máy học truyền thống.

Đối với các mô hình máy học truyền thống, quá trình huấn luyện được thực hiện trên các đặc trưng đã được trích xuất sẵn từ mô hình học sâu, bằng cách dùng mô hình CNN backbone + MGAT + FastKAN/MLP đạt kết quả kiểm thử tốt nhất được sử dụng làm bộ mã hóa bằng cách loại bỏ tầng phân lớp cuối cùng. Vector đặc trưng đại diện cho mỗi mẫu đồ thị được xây dựng bằng cách lấy trung bình các vector đặc trưng của toàn bộ các đỉnh thành phần, từ đó thu được một vector đặc trưng có số chiều là 512. Trước khi đưa vào huấn luyện, các vector đặc trưng này được chuẩn hóa bằng kỹ thuật *StandardScaler* nhằm giảm thiểu sự chênh lệch về độ lớn giữa các chiều, giúp các thuật toán máy học truyền thống hoạt động ổn định và hiệu quả hơn. Sáu mô hình máy học truyền thống được lựa chọn để đánh giá bao gồm: KNN, Naive Bayes, Decision Tree, Random Forest, Logistic Regression và Linear SVC.

Bảng số liệu và các biểu đồ dưới đây trình bày kết quả kiểm thử trung bình của các mô hình máy học truyền thống:

Bảng 25. *Kết quả kiểm thử trung bình của các mô hình truyền thống (sử dụng đặc trưng từ DenseNet121 + MGAT + FastKAN)*

Mô hình	**Accuracy**	**Precision**	**Recall**	**F1-Score**
KNN (k = 1)	0.8213	0.8289	0.8213	0.8022
Gaussian NB	0.7306	0.7210	0.7306	0.7142
Decision Tree (max_depth = 10)	0.7556	0.7656	0.7556	0.7412
Random Forest (n_estimators = 20)	0.8083	0.8108	0.8083	0.7859
Logistic Regression (C = 10)	0.8370	0.8419	0.8370	0.8272
Linear SVC (C = 0.01)	0.8676	0.8696	0.8676	0.8649
DenseNet121 + MGAT + FastKAN	**0.9435**	**0.9477**	**0.9435**	**0.9438**

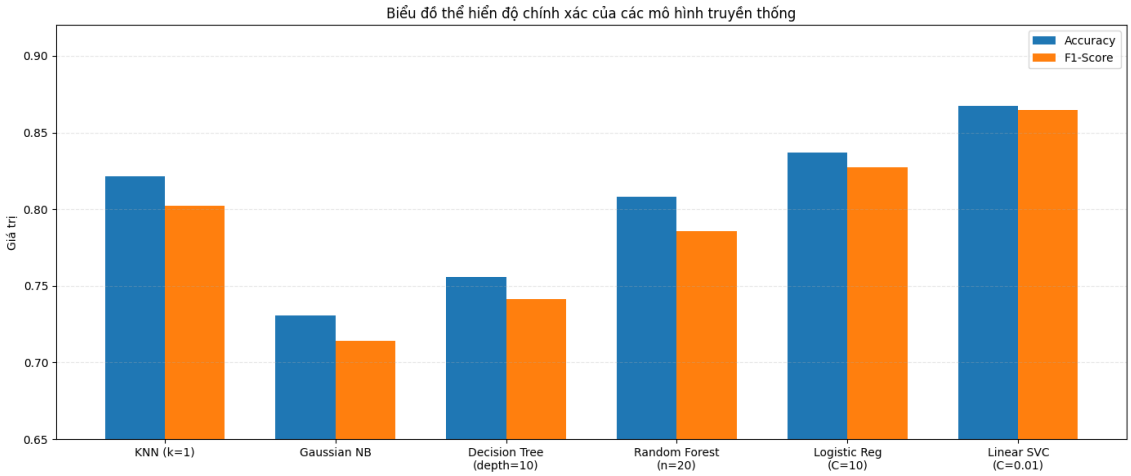

Hình 35. *Biểu đồ thể hiện kết quả kiểm thử trung bình của các mô hình truyền thống (sử dụng đặc trưng từ DenseNet121 + MGAT + FastKAN)*

Dựa trên số liệu thu được từ bảng kết quả kiểm thử trung bình của các mô hình máy học truyền thống, có thể rút ra một số nhận xét chính như sau:

– Khả năng phân tách tuyến tính của không gian đặc trưng: Kết quả đạt được với Linear SVC (độ chính xác 0.8676) cho thấy các vector đặc trưng đầu ra từ tầng MGAT có mức độ phân tách tuyến tính tương đối tốt. Điều này cho thấy các mẫu dữ liệu cùng lớp có xu hướng được gom cụm trong không gian đặc trưng, tạo điều kiện thuận lợi cho các bộ phân lớp tuyến tính hoạt động hiệu quả.

– Vai trò trích xuất và tổng hợp đặc trưng của MGAT: Các kết quả kiểm thử đã cho thấy rằng kiến trúc MGAT tổng hợp thông tin từ nhiều phương thức dữ liệu rời rạc (hình ảnh, văn bản và âm thanh) thành các vector biểu diễn ngữ nghĩa thống nhất rất hiệu quả, trước khi được đưa vào các bộ phân lớp ở giai đoạn cuối.

– So sánh với FastKAN: Mặc dù Linear SVC cho kết quả khả quan, vẫn còn tồn tại một khoảng cách đáng kể về độ chính xác (khoảng 7–8%) khi so sánh với

FastKAN (đạt 0.9435). Sự chênh lệch này thể hiện hạn chế của các mô hình tuyến tính trong việc xử lý các biên quyết định phức tạp. Đối với dữ liệu ICH, nơi tồn tại nhiều mẫu có mức độ nhập nhằng cao, các bộ phân lớp phi tuyến với khả năng biểu diễn linh hoạt như FastKAN sẽ phù hợp hơn so với các mô hình máy học truyền thống.

3. Thảo luận chung về các kết quả thực nghiệm

Dựa trên các thực nghiệm được tiến hành từ mô hình đơn phương thức đến đa phương thức, kết hợp với các kiểm chứng trên các mô hình máy học truyền thống, các thảo luận tổng quát về hiệu quả của giải pháp đề xuất được tổng hợp như sau:

- **Hiệu quả của phương pháp đa phương thức:** Kết quả thực nghiệm cho thấy việc tích hợp thông tin văn bản và âm thanh thông qua kiến trúc MGAT giúp hệ thống đạt độ chính xác cao hơn so với các mô hình phân lớp chỉ dựa trên hình ảnh (CNN Baseline). Các đặc trưng ngữ nghĩa từ văn bản cùng với thông tin âm thanh đóng vai trò bổ trợ cho các đặc trưng hình ảnh, qua đó làm giảm hiện tượng nhập nhằng giữa các lớp có khung cảnh hình ảnh tương đồng và cải thiện độ tin cậy của dự đoán.
- **Chất lượng biểu diễn đặc trưng của MGAT:** Thông qua kết quả kiểm thử với các mô hình máy học truyền thống, trong đó Linear SVC đạt độ chính xác hơn 86%, có thể thấy rằng kiến trúc MGAT học được các biểu diễn đặc trưng mang tính phân biệt cao. Các vector đặc trưng đầu ra hỗ trợ hiệu quả việc gom nhóm các mẫu dữ liệu cùng lớp trong không gian nhiều chiều, ngay cả trước khi áp dụng các bộ phân lớp phi tuyến phức tạp.
- **Sự tương thích giữa CNN backbone và bộ phân lớp:** Hai bộ phân lớp FastKAN và MLP cho thấy mức độ phụ thuộc cao vào đặc điểm của CNN backbone:
  + FastKAN đạt hiệu quả cao khi kết hợp với các CNN backbone có khả năng trích xuất đặc trưng sâu và giàu thông tin (chẳng hạn như DenseNet và ResNet). Khả năng xấp xỉ hàm linh hoạt của KAN cho phép khai thác hiệu quả không gian đặc trưng có độ biểu diễn cao.
  + Ngược lại, MLP thể hiện sự ổn định và phù hợp hơn khi kết hợp với các CNN backbone nhẹ (như MobileNet Small và ShuffleNet). Trong trường hợp không gian đặc trưng đầu vào bị nén hoặc có mức độ thông tin hạn chế, cấu trúc đơn giản của MLP giúp giảm nguy cơ overfitting so với FastKAN.
- **Hiệu quả của chiến lược suy luận phân tầng:** Sự khác biệt về hiệu năng giữa mô hình hai phương thức và mô hình ba phương thức cho thấy dữ liệu âm thanh đóng vai trò quan trọng nhưng chỉ thực sự hữu ích trong những ngữ cảnh nhất định. Chiến lược suy luận hai bước, trong đó bước đầu tiên thực hiện lọc nhãn thô nhằm tránh đưa thông tin âm thanh vào các lớp không phụ thuộc vào âm thanh, giúp duy trì độ chính xác ổn định khi triển khai thực tế, đồng thời đảm bảo sự nhất quán với kết quả đánh giá trên tập Test.

Trong phạm vi của đề tài này, việc so sánh các mô hình chỉ được thực hiện trên khía cạnh không gian, cụ thể là số lượng tham số, mà chưa xem xét đến thời gian chạy. Lý do là mục tiêu chính của các thực nghiệm tập trung vào việc đánh giá hiệu quả sử dụng tham số của kiến trúc đề xuất. Thông qua việc áp dụng chiến lược học chuyển giao (Transfer Learning) bằng cách đóng băng các backbone, mô hình chỉ cần cập nhật một lượng tham số tương đối nhỏ (khoảng 4-5M) so với tổng lượng tham số mô hình (khoảng 28-40M). Cách tiếp cận này nhằm chứng minh rằng, chỉ với việc huấn luyện một phần mô hình có quy mô gọn nhẹ, hệ thống vẫn có thể xử lý hiệu quả tri thức từ các mạng tiền huấn luyện lớn để đạt được độ chính xác cao, đồng thời giảm đáng kể chi phí tính toán trong giai đoạn huấn luyện. Trên thực tế, tốc độ tính toán còn phụ thuộc nhiều vào mức độ tối ưu hóa phần mềm cũng như việc khai thác CUDA, vốn chưa được tối ưu hoàn toàn trong phiên bản hiện tại của thư viện FastKAN.

III. PHẦN KẾT LUẬN

1. Kết quả đạt được

- **Xây dựng thành công kiến trúc đồ thị đa phương thức:** Đề tài đã đề xuất và cài đặt hoàn chỉnh mô hình học sâu kết hợp giữa MGAT và mạng Kolmogorov-Arnold (FastKAN). Kiến trúc này cho phép tích hợp hiệu quả ba phương thức (hình ảnh, văn bản, âm thanh) vào một không gian biểu diễn thống nhất, khắc phục được hạn chế về nhập nhằng ngữ cảnh của các phương pháp chỉ dựa trên hình ảnh truyền thống.
- **Cải thiện đáng kể kết quả phân lớp:** Kết quả thực nghiệm chứng minh mô hình đề xuất cho ra kết quả vượt trội hơn so với các mô hình CNN Baseline đơn phương thức, đặc biệt ở các lớp dữ liệu có độ nhập nhằng cao. Việc bổ sung thông tin từ văn bản và âm thanh đã giúp hệ thống đạt độ chính xác lên tới 94.35% với DenseNet121 + MGAT + FastKAN, cao hơn 4% so với MobileNetV3 Large baseline (với độ chính xác 90.28%) khẳng định tính đúng đắn và hiệu quả của hướng tiếp cận đa phương thức.
- **Triển khai ứng dụng thực tiễn:** Đề tài đã hoàn thiện ứng dụng web ICH Predictor với giao diện trực quan, cho phép người dùng tương tác linh hoạt với hệ thống (tải lên dữ liệu đa dạng, tùy chọn mô hình). Đặc biệt, tính năng trực quan hóa cấu trúc đồ thị giúp tăng tính minh bạch trong quá trình ra quyết định của mô hình, mang lại giá trị tham khảo cho người dùng.

2. Hướng phát triển

- **Mở rộng phạm vi thực nghiệm:** Tiếp tục thử nghiệm kiến trúc đề xuất trên các họ mạng trích xuất đặc trưng hiện đại khác (như EfficientNet, ConvNeXt hoặc Vision Transformer) để đánh giá khách quan hơn về tính ổn định và khả năng thích nghi của module MGAT + FastKAN/MLP đối với các dạng đặc trưng đầu vào khác nhau.
- **Làm giàu tập dữ liệu:** Tìm kiếm và thu thập thêm dữ liệu video ICH từ nhiều nguồn khác nhau để gia tăng kích thước tập dữ liệu. Việc này không chỉ giúp mô hình học được các đặc trưng tổng quát hơn mà còn đảm bảo kết quả đánh giá mang tính khách quan cao.
- **Nâng cao khả năng suy luận trên đồ thị:** Nghiên cứu các phương pháp xây dựng đồ thị đa phương thức có tính giải thích cao hơn. Thay vì chỉ học các mối quan hệ "đối kháng" hoặc "bạn bè" thông qua trọng số cạnh, hướng phát triển trong tương lai sẽ tập trung vào việc mô hình hóa các quan hệ nhân quả hoặc ngữ nghĩa được biểu diễn một cách tường minh dưới dạng đồ thị suy luận (Reasoning Graph). Cách tiếp cận này giúp mô hình khai thác tốt hơn nội hàm ngữ nghĩa của dữ liệu ICH, đồng thời mở ra khả năng thực hiện các tác vụ suy luận dựa trên cấu trúc đồ thị.

TÀI LIỆU THAM KHẢO

[1] Djork-Arné Clevert, Thomas Unterthiner, and Sepp Hochreiter. *Fast and Accurate Deep Network Learning by Exponential Linear Units (ELUs)*. 2016. arXiv: 1511.07289 [cs.LG].

[2] S. Davis and P. Mermelstein. "Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences". In: IEEE Transactions on Acoustics, Speech, and Signal Processing 28.4 (1980), pp. 357–366. DOI: 10.1109/TASSP.1980.1163420.

[3] Jacob Devlin et al. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. 2019. arXiv: 1810.04805 [cs.CL].

[4] Tao Fan, Hao Wang, and Sanhong Deng. "Intangible cultural heritage image classification with multimodal attention and hierarchical fusion". In: Expert Systems with Applications 231 (2023), p. 120555. ISSN: 0957-4174.

[5] S. Furui. "Speaker-independent isolated word recognition using dynamic features of speech spectrum". In: IEEE Transactions on Acoustics, Speech, and Signal Processing 34.1 (1986), pp. 52–59. DOI: 10.1109/TASSP.1986.1164788.

[6] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.

[7] William L Hamilton. *Graph Representation Learning*. Morgan & Claypool Publishers, 2020.

[8] Kaiming He et al. *Deep Residual Learning for Image Recognition*. 2015. arXiv: 1512.03385 [cs.CV].

[9] Andrew G. Howard et al. *MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications*. 2017. arXiv: 1704.04861 [cs.CV].

[10] Gao Huang et al. *Densely Connected Convolutional Networks*. 2018. arXiv: 1608.06993 [cs.CV].

[11] Ziyao Li. *Kolmogorov-Arnold Networks are Radial Basis Function Networks*. 2024. arXiv: 2405.06721 [cs.LG].

[12] Ziming Liu et al. *KAN: Kolmogorov-Arnold Networks*. 2025. arXiv: 2404.19756 [cs.LG].

[13] Dat Quoc Nguyen and Anh Tuan Nguyen. “PhoBERT: Pre-trained language models for Vietnamese”. In: *Findings of the Association for Computational Linguistics: EMNLP 2020*. Ed. by Trevor Cohn, Yulan He, and Yang Liu. Online: Association for Computational Linguistics, Nov. 2020, pp. 1037–1042. DOI: 10.18653/v1/2020.findings-emnlp.92.

[14] Ciyuan Peng, Jiayuan He, and Feng Xia. *Learning on Multimodal Graphs: A Survey*. 2024. arXiv: 2402.05322 [cs.LG].

[15] Nils Reimers and Iryna Gurevych. *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. 2019. arXiv: 1908.10084 [cs.CL].

[16] Ashish Vaswani et al. *Attention Is All You Need*. 2023. arXiv: 1706.03762 [cs.CL].

[17] Petar Veličković et al. *Graph Attention Networks*. 2018. arXiv: 1710.10903 [stat.ML].

[18] Wenhui Wang et al. *MiniLM: Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-Trained Transformers*. 2020. arXiv: 2002.10957 [cs.CL].

[19] Ruibin Xiong et al. *On Layer Normalization in the Transformer Architecture*. 2020. arXiv: 2002.04745 [cs.LG].

[20] Keyulu Xu et al. *How Powerful are Graph Neural Networks?* 2019. arXiv: 1810.00826 [cs.LG].

[21] Shuhei Yokoo et al. *Two-stage Discriminative Re-ranking for Large-scale Landmark Retrieval*. 2020. arXiv: 2003.11211 [cs.CV].

[22] Xiangyu Zhang et al. *ShuffleNet: An Extremely Efficient Convolutional Neural Network for Mobile Devices*. 2017. arXiv: 1707.01083 [cs.CV].